

你的第一位 AI 员工

你的第一位 AI 员工

如何把真实工作交给 AI, 检查它的产出, 并知道何时该“解雇”它

James Liu

版权所有 © 2026 James Liu

保留所有权利。未经作者事先书面许可，不得以任何形式复制、分发或传播本书的任何部分，书评中引用的简短片段除外。

本书在作者的指导、大纲设计与审阅下，借助 AI 辅助撰写完成。书中统计数据与案例研究均引自己标注来源的公开资料；任何关于亲身经历的表述均为作者本人的真实经历。

ISBN: [发行前由出版方或平台指定]

献给每一个仍未清空的收件箱。

目录

目录	5
1 委派难题	13
1.1 认识你的新员工	14
1.2 第三种方式：从第一天开始	15
1.3 面对同一款工具的两种态度	15
1.4 同一项任务，两种不同的交代方式	16
1.5 继续往下读之前，先做一次五分钟自查	17
1.6 为什么这与“技术能力”无关	17
1.7 工具难道不会自己变得更好吗？	18
1.8 这本书不会做的事	19
1.9 接下来	19
2 撰写工作说明书	21
2.1 为什么会有这种落差	21
2.2 一份真正的任务说明包含的五件事	22
2.3 赶时间的时候，这套方法要怎么用	23
2.4 另一份任务说明：一件和写邮件毫不相干的事	24
2.5 这与文笔好坏无关	24
2.6 本章不涉及的内容	25
2.7 试一试：翻页之前先做这件事	25
2.8 接下来	26
3 试运行任务	27
3.1 为什么第一个任务比看起来更重要	28
3.2 好的第一个任务应具备什么条件	28
3.3 真正跑一次试运行	29
3.4 一次完整的试运行	29

3.5	为什么这对一个小任务来说并不算小题大做	30
3.6	本章不涉及的内容	30
3.7	试一试：选出你的试运行任务	31
3.8	接下来	32
4	检查工作成果，而不是重做一遍	33
4.1	那个虚假的选择	33
4.2	聪明的中间道路为什么真的管用	34
4.3	建立一套真正的抽查方法	35
4.4	第二道接缝，另一种任务	36
4.5	这笔交易到底在权衡什么	37
4.6	本章不涉及的内容	37
4.7	试一试：为你的接缝命名	37
4.8	接下来	38
5	摸清它的失败模式	39
5.1	“AI 会犯错”这句话里藏着的误区	39
5.2	同一个矩阵的另一半	41
5.3	打造一份真正的绩效评估	41
5.4	这份清单为什么应该短	42
5.5	本章不涉及的内容	42
5.6	试一试：建立档案	43
5.7	接下来	44
6	真正管用的反馈方式	45
6.1	留不住的反馈不是免费的，它是有代价的	45
6.2	修正和更新的区别	46
6.3	写出一条能挺过单次会话的修正意见	47
6.4	堆叠到底会变成什么样子	48
6.5	什么时候一条修改意见真的只是一次性的	48
6.6	本章不涉及的内容	48
6.7	试一试：审查你的常设指令	49
6.8	接下来	50
7	何时该“解雇”它	51
7.1	该停手的四个理由，而不是一个	52
7.2	就算你每一步都做对了	52
7.3	同一个教训，在更大的舞台上重演	53
7.4	“解雇”真正意味着什么	54
7.5	本章不涉及的内容	55
7.6	试一试：运行淘汰标准清单	55

7.7 接下来	56
8 你的第二位, 第三位 “员工”	57
8.1 Why attention alone stops working past one or two	57
8.2 A roster, not a bigger memory	58
8.3 Deciding when you actually have room for another one	59
8.4 The roster making the call for you	60
8.5 What this chapter will not do	61
8.6 Try this: start your roster	61
8.7 Where this goes next	62
9 一人团队	63
9.1 为什么任务链比其中任何一步都更危险	64
9.2 解药是检查点, 不是一个编程项目	65
9.3 知道在哪里该停止串联	66
9.4 当问题出在任务链本身	66
9.5 本章不涉及的内容	67
9.6 试一试: 画出你的任务链	67
9.7 接下来	68
10 三十天委派计划	69
10.1 第一周: 一项任务, 一份真正的任务说明	69
10.2 第二周: 真正地检查一遍, 并建立清单	70
10.3 第三周: 让修正真正落地, 并跑一遍淘汰标准	70
10.4 当第三周说 “不”	71
10.5 第四周: 谨慎地增加任务, 且只有在够格时才增加	72
10.6 你的三十天, 一页纸看完	72
10.7 结束清单	73
10.8 本章不涉及的内容	73
10.9 接下来	74
11 四个完整的委派案例	75
11.1 案例一: 一位婚礼摄影师的四个月	76
11.2 案例二: 一位汽配经销商更为坎坷的历程	77
11.3 案例三: 一位保险代理人的静默成功	78
11.4 案例四: 一位特色食品生产商更缓慢的起步	79
11.5 四条路径, 并排对照	80
11.6 这四个故事真正说明了什么	80
11.7 接下来	81
12 选择你的第一个工具	83

12.1 五个不会过时的问题	84
12.2 Naomi 的实际评估	85
12.3 当没有一款工具能干净利落地通过所有测试	85
12.4 本章不涉及的内容	86
12.5 试一试：给你的候选工具打分	86
12.6 接下来	87
13 当你的团队也开始委派	89
13.1 只有团队才会出现的故障模式	89
13.2 教方法，而不只是教工具	90
13.3 三个月后，这套规范真正拦住了什么	91
13.4 你版本的第四章，升高一个层级	91
13.5 本章不涉及的内容	92
13.6 试一试：搭建一条团队标准	92
13.7 接下来	93
14 常见质疑与边界情况	95
14.1 “我没时间为每件小事都写一份五要素任务说明。”	95
14.2 “工具一夜之间就变了，我的故障模式清单已经不适用了。”	95
14.3 “我的行业受严格监管，这是不是意味着这套方法根本不适用于我？”	96
14.4 “我原则上根本不信任 AI，凭什么要把任何事交给它？”	96
14.5 “我的团队在什么时候该‘解雇’一项任务上意见不一。”	97
14.6 “对我这么大的企业来说，这套流程感觉太重了。”	97
14.7 “我之前用 AI 试过一次，结果很糟糕，这次凭什么会不一样？”	97
14.8 “涉及他人隐私或敏感信息的任务该怎么办？”	97
14.9 “AI 很快不就会强到让这一切都不再重要了吗？”	98
14.10 “这不就是常识吗？为什么要专门写一整本书？”	98
14.11 “我怎么知道一项任务是真的‘配得上’更轻的监督，还是我只是开始掉以轻心了？”	98
14.12 “不管我怎么精简，我的故障模式清单条目总是超过三四条。”	99
14.13 “我只能用一款 AI 工具，是老板选的，不是我选的。”	99
14.14 接下来	100
15 衡量委派究竟为你节省了什么	101
15.1 为什么“感觉”与“事实”会渐行渐远	102
15.2 究竟该衡量什么	102
15.3 一个说了实话的数字	103
15.4 另一个方向	103
15.5 试一试：把一项任务记录两周	104
15.6 接下来	105

16 不同任务类型的常见失败模式	107
16.1 写作与起草类任务	108
16.2 分类与分诊类任务	108
16.3 日程与日历类任务	108
16.4 研究与摘要类任务	109
16.5 链式多步骤任务	109
16.6 运用本章内容	109
16.7 试一试：先猜测，后试运行	109
16.8 接下来	110
17 重新审视一个曾被“解雇”的任务	111
17.1 为什么被“解雇”的任务默认会一直“解雇”下去	111
17.2 建立一套真正的重新审视习惯	112
17.3 六个月后，究竟发生了什么变化	112
17.4 什么时候，重新审视理应持续失败	113
17.5 试一试：安排你的第一次重新审视	113
17.6 接下来	114
18 六个行业，一套方法	115
18.1 精品服装店	116
18.2 住宅暖通空调承包商	116
18.3 独立书店	116
18.4 住宅房地产经纪人的	116
18.5 瑜伽与养生工作室	117
18.6 法律助理支持服务	117
18.7 六家企业身上不变的东西	117
18.8 试一试：找到与你最相近的那一个	118
18.9 接下来	118
19 并非所有 AI 工具都是同一类工具	119
19.1 三种形态，一种共通技能	119
19.2 形态在何处、以何种具体方式改变了这套方法	120
19.3 一个具体的对比	120
19.4 那次让她定下阈值的险情	121
19.5 试一试：给你自己的三种形态命名	121
19.6 接下来	122
20 当任务涉及金钱时，什么会变	123
20.1 为什么算术格外值得怀疑	123
20.2 核对，而非抽查	124
20.3 淘汰标准在这里变得更严格	125

20.4 一个被正确核查的报价任务	125
20.5 金钱类任务里的判断性决定	125
20.6 试一试：核对一个数字	126
20.7 接下来	127
21 从不尝试的代价	129
21.1 Yusuf 的十八个月准备期	129
21.2 等待的真正代价	130
21.3 真正的不对称	130
21.4 真正打破这十八个月僵局的是什么	131
21.5 相反的错误，简单说一句	131
21.6 试一试：说出你自己的“十八个月”	131
21.7 接下来	132
22 向客户解释这一切	133
22.1 真正重要的界线	133
22.2 前面章节其实早已划出这条界线	134
22.3 落到实践中是什么样子	135
22.4 这条界线在现实中是如何划定的	135
22.5 试一试：进行“理性人”测试	136
22.6 接下来	136
23 结语：你正在成为的那种管理者	137
23.1 不会过期的东西	138
23.2 这本书要求你放弃的东西	138
23.3 真正衡量进步的标准	138
24 模板与练习表	141
24.1 五要素任务说明（第二章）	141
24.2 试运行记录表（第三章）	142
24.3 接缝抽查练习表（第四章）	142
24.4 故障模式清单（第五章）	143
24.5 常设指令审查表（第六章）	143
24.6 四项淘汰标准检查表（第七章）	144
24.7 任务名册（第八章）	144
24.8 任务链地图（第九章）	145
24.9 工具评估记分表（第十二章）	145
24.10 团队标准（第十三章）	146
24.11 三十天计划（第十章）	146
24.12 复查追踪表（第十七章）	147
24.13 智能体行动前检查点（第十九章）	147

24.14	财务任务对账检查表（第二十章）	147
24.15	告知决策（第二十二章）	148
24.16	简明术语表	148
说明与资料来源		151
关于作者		159

第 1 章

委派难题

一周之内，两个人第一次尝试使用人工智能，各自处理一件不同的任务。两人都得出了一个结论，而这两个结论都是错的，并且错在同一个原因。

周二下午，第一个人粘贴进去一封棘手的邮件：那种客户很恼火，你需要道歉，却又不想承认你认为不该由自己承担的过错。回复写得很笼统，略显生硬，漏掉了那个真正能打动人心的细节。她干脆自己重写了一份，关闭了页面，此后一个月都没有再打开过。她的结论是：被过度炒作了，派不上任何真正要紧的用场。

在一场续约会议前一晚，第二个人粘贴进去一份四十页的供应商合同，请求生成摘要。生成结果干净利落、条理清晰、语气笃定。他把摘要原封不动地贴进了自己的笔记，走进会议室时甚至没有读过原文。这份摘要悄悄漏掉了一条关于自动续约通知窗口的条款：漏掉的细节从不会主动现身。三个月后，合同自动续约了，比预期提前了整整一年，因为没有人及时发现这个漏洞。他的结论是：这东西很危险，任何要紧的事都不能交给它。

第二个人所犯的 error，有一个真实世界里赫赫有名的版本，最终闹上了联邦法庭。一位纽约律师用 ChatGPT 协助研究一起人身伤害案件，它生成了一份法律陈述书，引用了若干支持其论点的判例。他把这份陈述书提交了上去。可那些判例根本不存在。这款工具编造出了假的案件名称、假的引用和假的引语，语气与格式都和真实判例一样自信、一样规范，而他团队里没有一个人在它呈交法官之前核实过其中任何一条。

关键洞察

一位纽约律师向法庭提交了一份法律陈述书，其中包含由 ChatGPT 生成的虚构判例，连引语和内部引注都是编造的。对方律师随后，法庭本身也未能查到任何一条被引用的判例。主审法官以向法庭提交虚假判决为由，对这名律师、他的一位同事及其律师事务所各处以五万美元罚款。

Source: Mata v. Avianca, Inc., 678 F. Supp. 3d 443 (S.D.N.Y. 2023); sanctions order June 22, 2023. (马塔诉阿维安卡航空公司案; 2023 年 6 月 22 日制裁令)

请注意，这两个人从看似截然相反的经历中，得出了截然相反的结论：一个用得太多，一个用得太多，但他们犯的其实是同一个错误。两人都把这个工具当成了自动售货机：投入一个请求，取出一件成品，双方都无需运用判断力。当成品不合格时，第一个人怪罪机器，转身离开。当成品看起来还不错时，第二个人像相信自动售货机里的商品一样彻底相信了它，因为面对自动售货机，你也没有别的办法。两人都没有做过任何“管理”这件事。他们各自只完成了一次购买，下了一个判断。

人工智能不是一台你试一次就能盖棺定论的自动售货机，它更像一名需要你在多次共事中不断管理的新员工。

这本书讲的正是第三种选择，一种几乎没有人凭直觉就会想到的选择，因为以往的软件从来不是这样运作的。

1.1 认识你的新员工

想象一下你入职培训过的最能干、上手最快的新员工。他们读过的东西比你团队里所有人加起来还要多。他们从不疲惫，从没有哪个早晨状态不佳，几乎任何东西的完整初稿都能在一分钟之内交出来。

现在再认真想象一下他们入职的第一天。他们从没见过你的客户。他们不知道你的老板讨厌“回头再聊”这种说法，也不知道你最大的客户两年前曾因账单起过纠纷，如今一提发票就敏感。他们完全不知道“完成”在你的团队里具体意味着什么，因为没有人给他们看过一个真实的范例。而真正要命的是：当他们不知道某件事的答案时，他们会用和给出正确答案时一模一样的自信流畅的语气，告诉你一个错误的答案。语气里没有一丝迟疑，没有任何破绽。

你绝不会在这样一名员工入职的第一个早晨，就把一项含糊的任务和一段无人监督的客户关系交给他，既不给他看任何一份优秀作品的范例，也不安排

任何检查节点。如果你真这么做了，结果又不理想，你也不会因此断定“雇人这件事根本行不通”。而如果这一次侥幸顺利，你也不会仅凭这一次好运，第二天早上就把公司最大的客户账户交到他手上。你会去管理他：给出清晰的任务说明，先从小风险的事情做起，密切检查早期的成果，随着他一点点赢得信任再逐步放权。

这正是开篇两个故事里都缺失的那一环，也是这本书通篇要讲的主题。不是“如何使用人工智能”，而是如何管理它，就像管理任何一位新人那样，用你很可能早已具备、只是从未想过要用在一款软件上的技能。

1.2 第三种方式：从第一天开始

开篇的两个故事都展示了跳过管理这一环所付出的代价。同样值得具体看一看的是，如果从一开始就不跳过这一环，会是什么样子，因为这本书讲的方法，不只是用来补救一次糟糕的初体验。

Ravi 在一家只有四名员工的牙科诊所负责市场营销。在他第一次请人工智能撰写社交媒体配文之前，他做了一件本章开头那两个人都没做过的事：他一开始就认定，新员工在承担真正的风险之前需要先经过入职培训。他提出的第一个请求不是“给这张照片写一条配文”，而更接近一份真正的任务说明：他附上了过去一年里自己写过、反响不错的三条配文，说明了诊所绝不会拿来开玩笑的几件事（打针、疼痛、费用），并明确要求生成同样风格的内容。第一条配文出来后接近但还不够准确，对于一家本地小诊所来说显得有点太“推销”了。他具体指出了问题，要求再改一版。第二版就成了。他并没有在当天下午就把整个诊所的社交媒体排期都交出去，而是接下来两周的配文都用同样严格的方式逐条审核，之后才放心地让一周过去，只在最后做一次简单的检查。

Ravi 的结果，并不比另外两个人更幸运。他用的是同一种工具。真正不同的是他的姿态：他把第一次尝试当作一次可以从中学习的试运行，而不是一次盖棺定论的裁决，并且他是先严格检查，后逐渐放松检查，而不是反过来。这就是整套方法的缩影，而且和另外两个故事不同的是，Ravi 不需要先被烫一次手才学会这一点。

1.3 面对同一款工具的两态度

自动售货机式思维	管理式思维
一试定成败	先试运行，再看业绩记录
要么完全信任，要么完全不信	信任随着证据一点点积累，随任务逐步建立
结果不好，就说明工具不行	结果不好，就说明少了一条指令
第一次的产出就是典型水平	经过入职培训后，第十次的产出才是典型水平

几乎每一个你听过的令人失望的 AI 故事，以及每一个 AI 恐怖故事，追根溯源都能归到左边这一栏。解决办法不是换一个更好的工具，而是有意识地、按照一套方法，转移到右边这一栏：这正是本书接下来要讲的全部内容。

1.4 同一项任务，两种不同的交代方式

下面来看这种差异在实践中究竟是什么样子，就用本章开头那封棘手邮件的任务举例。

给这封客户邮件写一条回复。要专业一些。

这就是全部的任务说明。但这根本算不上一份任务说明，只是一个任务的名称。它没有说明你到底想要什么语气，什么能承认、什么不能承认，双方的往来历史是怎样的，或者一份出自你本人之手的好回复听起来应该是什么样子。得到的结果之所以笼统，是因为这样的请求本来就只可能产生笼统的结果。它没有任何办法知道你的语气，因为你从来没有告诉过它。

给这封客户邮件写一条回复。情境说明：客户对两天的发货延迟感到不满，这是我们的履约合作方的过错，既不是他们的责任，也不完全是我们的责任。回复中要认可对方的不满情绪，但不承认不属于我们的过错。提供标准的延迟补偿（下次订单 9 折优惠）。全文控制在 120 词以内。这是我上个月发给另一位不满客户、效果很好的邮件，请匹配这种语气：[粘贴范例]。

同一项任务，完全不同的任务说明。它说明了具体的情境，划定了哪些能承认、哪些不能承认的边界，给出了具体的补偿方案，设定了字数限制，还附上了一份可供参照的、你本人语气的实例。这两次尝试之间，底层的工具没有任

何变化。唯一的变化是，第二次是真正经过管理的：就像你给新员工交代一项真实任务时该做的那样，而不是留一张写着“这个你处理一下”的便利贴。

下一章通篇讲的都是如何写出像第二份那样的任务说明，为你即将第一次委派出去的任何任务而写。就目前来说，重点更窄一些：这两份回复之间的质量差距，不是工具的差距，而是指令的差距，而指令的差距，是可以修正的，这和“工具不行”完全不同。

1.5 继续往下读之前，先做一次五分钟自查

回想一下本章开头提到的那两个人，或者更好的是，找出属于你自己的两个版本：一件你已经尝试过交给人工智能、但后来放弃了的任务，以及一件你交出去之后出了错、而你要么后来才发现、要么根本没发现的任务。

现在就试一试，写在纸上或者在脑子里过一遍，然后再往下读。针对你的这两个例子，诚实地回答以下问题：

- 我给出的是具体的情境，还是仅仅是任务的类别（比如“回复一位客户”，而不是“就这一次具体的延误，回复这一位具体的不满客户”）？
- 我有没有像给新员工划定边界那样，说明哪些内容不能承认、不能承诺、不能假设？
- 我有没有给它看一个体现你自己语气的真实优秀范例，还是只是抽象地描述了一下语气（比如“专业但不失亲切”）？
- 我有没有说清楚“完成”具体意味着什么：字数、格式，还是某个具体的交付物？
- 我有没有像检查新员工第一周的工作那样仔细检查第一次的结果，还是因为它读起来很流畅就直接相信了？

对大多数人来说，在大多数时候，这几个问题的答案大多是“没有”。这并不是什么失败的自白。这项技能从来没有人系统教过，所以几乎没有人是带着它天生具备的。这只是说明，从现在起、从下一项任务开始，就可以着手改正，而不需要你为此前做过的事做出任何弥补。

1.6 为什么这与“技术能力”无关

如果你一直在心里悄悄把自己归为“不懂技术的人”，现在正是把这个标签撕掉的时候，因为它描述的是另一个问题，而不是这本书要解决的问题。

接下来的内容，不需要你理解模型内部是如何运作的，不需要你写一行代码，也不需要你去学习某款新软件的菜单结构。这本书里的每一项技能，都是

你已经从生活中别的地方掌握了的管理技能，不管那是操持一个家庭、组织一次学校募捐活动，还是在工作中带教一名新员工：把任务讲清楚，从小事做起，仔细检查早期成果，给出具体的反馈，让信任随着表现逐步建立，并且清楚知道有些工作就是不该交给新人。唯一新鲜的部分是目标对象变了。你是在把一项早已熟悉的技能，指向一个陌生的对象，而不是从零开始学一项全新的技能。

1.7 工具难道不会自己变得更好吗？

这是一个合理的问题，也值得在要求任何人花一整本书的篇幅去学习一项管理技能之前，先正面回答：如果这些工具一直保持目前的进步速度，那交代任务说明、仔细检查这些事，最终会不会变得没有必要，就像你现在不再需要向搜索引擎解释什么是好结果一样？

有三个理由说明，这不是一个值得下的赌注。第一，即便是你遇到过的、管理得最好的员工，拿到清晰的任务说明时，做出来的东西也依然比拿到含糊说明时更好，而且这个差距不会随着能力提升而缩小，通常反而会拉大，因为一个能力更强的员工，能够凭借良好的背景信息做到更多，而不是更少。出于同样的道理，一款更聪明的模型，拿到真正的任务说明时，表现依然会比只给一个任务名称时更好。

第二，本章反复提到的那种具体的故障模式，也就是用和正确答案完全一样的自信语气给出错误答案，并不是一个会随着模型改进而被悄悄修补掉的漏洞。它是这类系统生成语言这件事本身的结构性后果：一个词接一个词地根据“哪个更可能”来选择，而不是去查一张已知事实的表格。能力更强的模型确实会更常给出正确答案，但它不会因此为自己不太确定的答案，发展出一种不一样的语气。这本书教的检查习惯，不会因为模型质量提升而有一个过期日期，因为它解决的从来就不是一个“质量问题”。

关键洞察

OpenAI 自己关于语言模型为何会产生幻觉的研究指出，这种行为并不是什么神秘的故障，而是这类系统的训练和评分方式所导致的可预见后果。标准的评测体系奖励的是一个自信、具体的猜测，而不是诚实地说一句“我不确定”，这和学生面对一场选择题考试时，宁可猜一个答案也不愿交白卷的动机如出一辙。因此，训练自然而然地产出了那些会流畅地猜测、而不是标注自身不确定性的模型。

Source: Kalai, A.T., Nachum, O., Vempala, S.S., & Zhang, E., “Why Language Models Hallucinate,” arXiv:2509.04664, September 2025 (OpenAI). (论文标题：《语言模型为何会产生幻觉》，OpenAI, 2025 年 9 月)

这项研究结论之所以重要，理由只有一个：它说明，这个问题的解决方案，从来就不可能作为“模型变得更聪明”的副产品自动出现。如果按自信的猜测给模型打分，却又期待它自发地开始变得谨慎起来，这等于是指望激励机制自己反转过来。检查这个习惯，不是行业解决“幻觉”问题之前的权宜之计，而是使用一款被训练得听起来永远很确定的工具时，永远不可或缺的另一半。

第三，也是无论工具变得多好都不会消失的一点：你的客户、你独有的标准、你上一次发票纠纷背后的来龙去脉，这些都不会因为一款通用工具整体变得更聪明，就自动变得可知。这不是能力上的差距，而是除了身处你这个具体情境中的人之外，没有人掌握的背景信息，而把这些信息交代清楚，一直是、也将永远是你自己的工作。

1.8 这本书不会做的事

一本只告诉你某种方法在哪里管用的书，不值得你据此安排自己的一整周，所以下面要说清楚这套方法的边界在哪里。

它不会让每一项任务都变得可以自动化。第七章通篇讲的都是应该留在你自己手里的任务：那些一旦出错代价高昂的任务，那些依赖于人工智能完全无法参与的人际关系的任务，还有那些无论你把任务说明写得再好、出错率就是降不下来的任务。硬要把这些任务交出去，算不上什么高阶委派，只是给风险多加了几道工序而已。

它不会在第一次尝试时就为你省下时间。写一份真正的任务说明，也就是第二个邮件例子那种，花的时间要比敲四个字碰运气长得多。回报会出现在你第五次重复使用这份任务说明的时候，而不是第一次，就像培训一名新员工，第一周会耗费你的时间，但接下来一整年都会有回报。

而且，它也不会紧跟你这个月正在用的某款具体应用的每一次更新，这是刻意为之。接下来的每一个例子，都写得足以经受住一次界面改版，因为底层的技能（把任务说明写清楚、检查早期成果、摸清具体的故障模式、给出真正管用的反馈）不会因为某家公司改了界面就跟着过期。

1.9 接下来

第二章讲的就是“职位说明书”本身：一份任务说明具体应该包含什么，才能读起来像第二个邮件范例而不是第一个，而且这套方法适用于任何任务，不只是回复邮件。第三章会带你有意地挑选你的第一项真正的试运行任务，小到即便结果不好也不会让你付出什么代价。第四章和第五章讲的是让委派真正安全的两项技能：高效地检查产出，而不是自己重做一遍，以及摸清你这项具

体任务惯常出错的那些具体的、可重复出现的方式。第六章讲如何给出真正能改变未来产出的反馈，而不是用一次就消散。第七章是淘汰清单，也就是应该始终留在你自己手里的任务。第八章和第九章讲的是如何在委派不止一项任务的情况下继续扩大规模，同时又不至于失去对自己整套系统的掌控。第十章把这一切整合成一份为期三十天的计划，一次一项任务，从你读完这本书的那一周就可以开始。

这些内容没有一个是可以当作理论读一遍就束之高阁的。每一章结尾都会给你一件真正要去尝试的事，用在你此刻收件箱或待办清单里已经有的某项任务上，再进入下一章。本章开头那两个人之间的差距，是靠一次又一次小规模、说明清楚的试运行才能一点点弥合的，而不是靠读完目录就能实现的。

要点总结

- 人工智能不是一台你试一次就能盖棺定论的自动售货机。要像管理新员工一样管理它：交代任务说明，仔细检查早期成果，随着信任被赢得而逐步放权。
- 一个糟糕的结果，几乎总是意味着少了一条指令，而不是工具坏了。
- 交代任务说明的习惯，不会因为模型变得更好而过期。一个更聪明的员工，拿到真实的背景信息时依然会做得更好，而不是更少需要它。
- 这里的一切都不需要你懂技术。这本书里的每一项技能，都是你已经具备的管理技能，只是这次指向了一个新的对象。

第 2 章

撰写工作说明书

下一次你亲自培训新员工完成某项任务时，留意一下自己是怎么说的；再留意一下下一次你把同样的任务交给 AI 时，自己又是怎么说的。这两种表现之间的落差，就是本章要谈的全部内容。

对新员工，你大概会这样说：“我们要回复一位对发货延迟感到不满的客户。这其实是我们履约合作方的错，说到底既不算他们的错也不算我们的错，所以不要摆出一副是我们的责任的姿态去道歉，但也别指名道姓地怪罪合作方，那样显得不专业。给他们标准的百分之十折价券。回复要简短，这么恼火的客户不想看一整段文字。这是我上个月针对类似情况写的一封回复，照着这个语气来。”这番话你毫不费力就能说上九十秒。

而对 AI，同样的任务通常只换来这样一句话：“回复这位生气的客户。”英文原文只有四个词。这并不是因为你不懂得该怎么做，而是因为某种悄然生效的假设：它认定机器要么已经知道其余信息，要么不需要知道，又或者提供背景是你对人才会有的礼貌，对软件却不必如此。这个假设是错的，而这正是本书试图打破的、代价最高昂的一个习惯。

2.1 为什么会有这种落差

值得弄清楚这种情况为什么会发生，因为把它说清楚，几乎就等于解决了大半问题。给人交代任务会激活一种社交本能：你会想象对方困惑的样子，想象他们做错了还得返工，而这种想象中的未来会让你自动地、不假思索地在背景信息上变得慷慨。往聊天框里打字则不会以同样的方式激活这种本能。没有一张会露出困惑表情的脸可供想象。聊天框只是照单全收，然后立刻给出结果，这就让那个四个词的版本显得已经够用了，哪怕从结构上讲根本不够。

关键洞察

2025 年一项在 GPT-4 和 O3-mini 上测试提示词具体程度对推理任务影响的研究发现，更详细、更具体的提示词能显著提升准确率，这种效应在较小模型上、以及在分步骤的程序性任务上尤为明显，而后者恰恰是大多数委派任务所属的类别。

Source: “DETAIL Matters: Measuring the Impact of Prompt Specificity on Reasoning in Large Language Models,” arXiv:2512.02246, 2025 (论文标题:《细节至关重要: 衡量提示词具体程度对大语言模型推理能力的影响》)。

工具不知道你没说出口的那部分。它会像新员工一样填补这个空白: 如果你丢下那句四个词的指令转身就走, 新员工也会靠猜测来完成任务, 而且那份自信的语气和真的知道正确答案时一模一样。四个词的任务说明之所以失败, 不是因为工具能力不足, 而是因为四个词从来都不足以让任何人 (不管是人还是别的什么) 完成你真正想要的那份工作。

2.2 一份真正的任务说明包含的五件事

回头看看开头那段说了九十秒的版本, 你会发现它的详尽并非随意为之。它每次都精准地覆盖了五个具体的方面, 而你甚至没有意识到自己在按清单逐项核对。把这份清单明确写出来, 才能把“侥幸写出一份好的任务说明”变成一种可以重复的习惯。

情境。用大白话说清楚究竟发生了什么。不是“回复客户”这种任务类别, 而是具体的情况: 客户很生气, 发货延迟, 这是谁的责任。

限制条件。不能说什么、不能做什么。你不愿意承认的事情, 哪种语气会适得其反, 以及任何单从情境本身看不出来的边界。

具体范例。一份真实的样本, 展示“做得好”是什么样子, 而且要用你自己的语气, 而不是“专业中带点温暖”这类笼统的语气描述。展示, 而不是描述。这一项单独发挥的作用, 比其余四项加起来还要大。

关键洞察

一项针对 95 种不同 AI 模型在真实临床写作任务上的大型基准测试发现，在指令之外再给模型一份范例，而不是只给指令，能在受测模型中普遍带来可观的效果提升。仅凭一份范例，Gemini-1.5-Pro 的得分就从 43.8 提升到 55.5，相对提升 27%；DeepSeek-R1 的得分从 44.2 提升到 51.4，相对提升 16%。

Source: Wu, J., et al., “BRIDGE: Benchmarking Large Language Models for Understanding Real-world Clinical Practice Text,” *Nature Biomedical Engineering*, 2026 (originally arXiv:2504.19467, 2025) (论文标题：《BRIDGE：面向真实临床实践文本理解的大语言模型基准测试》)。

注意，这一提升出现在两种截然不同的模型上，而不是只有一种。这并非某个特定工具单靠指令就会困惑的偶发怪癖。“展示胜过描述”这一点适用得足够广泛，你没有理由假设自己用的那个工具会是例外。

“完成”的标准。格式、长度、具体的交付物。“不超过 120 字”是一份任务说明。“简短一点”只是一种期望。

它自己无法知道的信息。任何属于你这个具体情境、既没写在提示词里、又猜不出来的信息：这个客户账户的历史、某项内部政策、某个关系上的细节。如果你不说出来，就当它是未知的，就像你不会指望一个新员工第一天上就能凭直觉猜出公司里那些没写下来的历史。

四个词的任务说明之所以失败，不是因为工具能力不足，而是因为四个词从来都不足以让任何人完成这份工作。

2.3 赶时间的时候，这套方法要怎么用

对于一个原本只需要四个词就能交代的任务来说，上面这份五要素任务说明听起来工作量不小，老实说，第一次写确实会花更多时间。下面这个版本更贴近真实忙碌一天的实际情况，因为一种只有在你恰好有十分钟空闲时才管用的方法，撑不过真实的一整周。

只要为一项经常出现的任务认真写过一次完整的任务说明，就把它保存下来。接下来的九次同样的任务再出现时，你不是在重新写一份任务说明，而是把唯一变化的那个变量：具体的客户、文件或数字，替换进一个你已经信得过的模板里。前期投入是真实存在的，而且每种任务类型只需要付出一次。此后

的每一次重复，成本都近乎为零，这才是第一次花那九十秒、而不是每次都用四个词打发的真正理由。

2.4 另一份任务说明：一件和写邮件毫不相干的事

这套五要素结构并非只适用于回复客户，值得看看它被用在一个完全不涉及给任何人写东西的场景里，这样才能看清这套方法是可以迁移的。

Dana 在一家有三家门店的小型五金连锁店负责库存管理，过去每逢周五，她都要花四十分钟把本周的销售终端导出数据整理成一份给店主看的、用大白话写的更新报告：哪些卖得好，哪些库存告急，哪些需要在周一之前补货。她第一次尝试把这件事委派出去时，写的是：“总结一下本周的销售数据。”结果得到的是一堆笼统的观察，“销售情况平稳”“有些商品卖得比其他商品好”，严格说来确实是在讲她的数据，但对任何真正要据此采取行动的人来说毫无用处。

下面是同样五个部分，用在一张电子表格上，而不是一段对话里。**情境**：不是“销售数据”，而是“一份面向三家门店五金连锁店店主的每周更新，要能在喝咖啡的两分钟内看完”。**限制条件**：不要给出具体的补货数量建议，那仍然是店主自己要做的决定；但凡某项商品比其四周平均值下降超过百分之三十就要标出来，这是真正能引起他注意的门槛。**具体范例**：上个月那份店主说“正合适”的更新报告，原文整段贴进去。**“完成”的标准**：三个板块，畅销商品、库存告急、异常情况，总字数不超过两百字。**它自己无法知道的信息**：油漆货架区无论需求如何，一到一月总会下滑，这是一条任何电子表格里都不会写明的季节性事实。

重写后的任务说明，第一次实际尝试就产出了一份几乎和 **Dana** 过去手写四十分钟的更新一模一样的报告。任务本身没有任何改变。改变的是：一份报告同样也是一份工作说明书，用的是同样的五个要素，只不过服务对象从客户的收件箱变成了一张电子表格。

2.5 这与文笔好坏无关

如果这套五要素结构听起来像是一种你不具备的写作技能，那就理解错了，值得直接纠正过来。一份好的任务说明完全不需要文笔优美。开头那段说了九十秒的版本，写得并不漂亮，它只是完整。这是两种不同的品质，而在这里，唯一重要的是后者。

支撑这五个部分的真正技能，其实是你一直在不断练习的，只是通常不会用在屏幕上：留意到对话中的另一个人还不知道什么，然后在对方需要开口问之前就先说出来。父母对孩子这样做。医生在状态最好的时候，也对病人这样做。

优秀的管理者对第一周上岗的新员工也是这样做的。这是一种再普通不过的人类技能，恰好也正是 AI 工具每一次都需要的东西，因为它永远不会像一位共事多年的同事那样，自己慢慢积累出那些背景信息。

2.6 本章不涉及的内容

本章不会把交代任务变成一套你必须逐字遵循的僵化脚本。这五个部分是一份完整的任务说明应当涵盖的内容，而不是规定的顺序或规定的措辞，很多好的任务说明会自然而然地把两个部分融进同一句话里。

本章也不会主张每一项任务都值得这样的前期投入。一项真正一次性的任务，一件你以后再也不会做的事，或许并不值得为它保存一份模板；对于一件永远不会重复使用的任务，粗糙地用四个词试一下、再快速修正，总体上可能比写完整的五个要素更快。第三章要谈的正是如何区分这类任务和真正值得全力投入的任务。

2.7 试一试：翻页之前先做这件事

选一项你目前正在用近似“四个词”任务说明交给 AI 处理的任务。按照下面的框架，把真正完整的版本、全部五个要素都写出来：

- **情境：**具体说清楚究竟发生了什么，而不是这项任务属于哪个类别。
- **限制条件：**什么不能说、不能提供、不能假设。
- **范例：**贴上一份真实、具体的样本，展示“做得好”是什么样子。
- **“完成”的标准：**长度、格式、具体的交付物。
- **它自己无法知道的信息：**那一条对你来说显而易见、但工具完全看不见的背景信息。

用这份任务说明和你原来那个四个词的旧版本各跑一遍这项任务，把两者的结果放在一起对比。这两份结果之间的落差，就是本章的全部论点，只不过这一次落到了你自己的工作上，而不是别人的例子里。

要点总结

- 你交代任务给人的方式，和交代给 AI 的方式之间的落差，通常就是产出质量落差的全部原因。工具需要的背景信息，和一名新员工需要的一样多，只是界面本身完全不会提醒你要给出这些信息。
- 一份完整的任务说明要涵盖五件事：情境、限制条件、一份体现你自己语气的具体范例、“完成”的标准，以及工具自己无法知道的信息。
- 具体范例发挥的作用，比其余四项加起来还要大。展示你的语气，而不是描述它。
- 每一项经常出现的任务，只需完整写一次任务说明，保存下来，之后每次只替换那个会变化的变量即可。前期成本只需支付一次，此后的每一次重复几乎都是免费的。

2.8 接下来

第三章要讨论的是如何选出第一项适合应用这套方法的任务：小到即便结果粗糙也不会有什么损失，又足够经常出现，让保存下来的任务说明真正能收回成本，同时也足够真实，能让这次试运行教会你一些四个词的版本永远教不会的东西。

第 3 章

试运行任务

设想两位经理，他们各自的新员工都将在周一入职。第一位经理把入职第一周就交给新人负责最重要的客户，那个全团队业绩都系于其上的客户关系，因为这位新人面试时看起来很聪明，而且确实有工作要做。第二位经理则把第一周留给一件小事：一份内部的常规报告，风险低、容易核查，出错的代价最多是搭进去一个下午，而不是丢掉一个客户。

你已经知道自己更愿意为哪位经理工作，也已经知道哪位经理真正在为新人的成功铺路。没有人会当真为第一位经理的做法辩护。可几乎每个人第一次把任务委派给 AI 时，做的正是同一件事：不是找一件小的、低风险的任务来试运行，而是挑最紧急、最显眼或最烦人的那件，完全不管一旦第一次结果不理想，代价究竟有多大。

3.1 为什么第一个任务比看起来更重要

关键洞察

一项针对三家医院、200 名新入职护士与护理助理的准实验研究，比较了结构化入职培训（为期三天、有导师指导、小范围任务加实操练习）与常规的无结构化入职方式。结果显示，接受结构化培训的一组在各项被测量的能力上得分显著高于直接被推上全部职责的一组，这证明了：一个经过刻意限定范围的第一项任务，能培养出能力明显更强的员工，胜过直接跳过训练、一步到位承担全部职责。

Source: Montes Muñoz, P., Cardinal-Fernández, P., Morales Rodríguez, Á., Ruiz-Zaldibar, C., & de la Cuerda López, A., “The Impact of an Onboarding Plan for Newly Hired Nurses and Nursing Assistants: Results of a Quasi-Experimental Study,” *Nursing Reports*, 15(11), Article 398, 2025 (论文标题:《新入职护士与护理助理入职计划的影响：一项准实验研究的结果》)。

这里的逻辑其实和 AI 毫无关系，而这恰恰是重点所在。新员工的第一项任务同时做着两件事：它产出了一些实际的工作成果，也让你以低成本了解到，这个具体的人具体会在哪里出错，而这时你还没有在他们身上押上任何昂贵的赌注。把任务试运行交给 AI，做的也是完全相同的两件事。产出本身只是你从中获得的一半价值，另一半是提前、低成本地看清楚这项具体任务在你手中具体会在哪里出问题：这是你目前还不掌握、也没有其他办法获得的信息。

如果跳过试运行，直接上手风险最高的任务，你就完全失去了这一半价值。你会在代价最高昂的那项任务上第一次认识到故障模式，这和第一位经理在第一周就把决定成败的客户交给新人，是同一个错误。

一项试运行任务同时做两件事：它产出工作成果，也让你以低成本了解这项具体任务的故障模式，而这时你还没有押上任何昂贵的赌注。

3.2 好的第一个任务应具备什么条件

有四项标准，真正好的试运行任务应当同时满足全部四项，而不只是一两项。
规模要小。即使试运行的结果不理想，你自己动手也能在十五分钟内完成的任务。试运行的全部意义就在于：即便结果不好，代价也几乎为零。

要是重复出现的任务。一次性的任务，不值得你花时间为它写一份认真的任务说明，也就是第二章介绍的五要素结构。而一项你下周、下下周还会再做的任务，每次重复使用同一份任务说明时，都在为你之前的投入赚回本金。

风险要低。除了你自己以外没有人会看到最初的几次尝试，或者哪怕结果平庸，后果也确实很小。把那些面向客户、关系到声誉的任务留到之后，等你已经在别的地方以更低的成本摸清这类任务的具体故障模式之后再说。

能在一分钟内核查完毕。你应该能一眼看出这个产出是对是错。如果核实答案花的时间和你自己动手做一样长，那这场试运行还没开始就已经失去了意义。

一份内部周报、一封常规邮件的初稿、给一批相似记录分类：这类任务往往能同时满足全部四项标准。而面向客户的提案、法律文件，以及任何一旦出错代价高昂或很难及时发现的任务：这些至少会在某一项标准上不达标，应该放到后面再做，等你已经在更小的任务上跑过几轮试运行之后。

3.3 真正跑一次试运行

选定任务之后，在下结论之前，先不要只跑一次。单独一次尝试几乎说明不了任何问题，就像仅凭一封邮件去判断一个新员工一样，几乎看不出什么。用同一类任务里略有不同的真实例子，跑三到五次，专门去寻找哪里出错的规律，而不只是看某一次结果是好是坏。

这个规律才是试运行真正的产出，比任何单次结果都更有价值。也许它总是在某一类细节上出错，也许它在某些输入上稳定表现出色、在另一些输入上则不稳定，而且这种差异现在你已经能够预测了。第五章整章都在教你如何读懂这种规律，而只有一次样本，你根本无从读起。

3.4 一次完整的试运行

下面来看看，把这整个流程用在一项真实任务上，会是什么样子，而不只是停留在原则层面。

Farrah 为几家小型非营利机构记账，她正在两个候选任务之间做选择，看先拿哪一个来试 **AI**：起草给捐赠人的感谢信，还是撰写每月交给各理事会的财务叙述报告。感谢信在全部四项标准上都胜出：规模小（一段话）、会重复出现（一周好几封）、风险低（一封稍显千篇一律的信，最多换来一句轻描淡写的“嗯”）、能在一分钟内核查（她一看就知道语气对不对）。而财务叙述报告在第四项标准上严重不及格：要核实一份财务摘要是否真的准确，花的时间和她自己动手写一样长，这就让试运行完全失去了意义。

她把感谢信任务跑了五次，用的是那一周实际收到的五笔不同的真实捐款。第一次和第二次都没问题。第三次，对象是一位已连续第五年捐款的捐赠人，写出来的信读起来却像是第一次收到感谢信，完全没有提及背后多年的持续捐赠。第四次在另一位老捐赠人身上重复了同样的缺口。第五次，对象是一位首次捐款人，结果又恢复正常。真正告诉她答案的，不是某一次结果，而是这五次的整体规律：这项任务在处理新捐赠人时可靠，处理老捐赠人时则不可靠，除非她每次都明确把这位捐赠人的捐款历史喂给它。这是一个具体、可以据此采取行动的事实，单独一次好结果永远不会揭示出来，而单独一次坏结果，本可能让她因为一个原本狭窄、可以修复的缺口，就此放弃整个想法。

3.5 为什么这对一个小任务来说并不算小题大做

如果“在信任一项小任务之前先把它跑五遍”听起来像是小题大做，那有必要直说：这种想法恰恰想反了。一项十五分钟的任务跑五次，加起来远远用不到两个小时，而且只需要花这一次，换来的，是你对这项任务在你手上具体表现如何的真实、有据可依的把握。看到一次好结果就直接开始信任它，并没有替你省下这些时间，它只是把“出现糟糕意外”的风险，推迟到了一个你无法自己选择的时刻，而这个时刻通常就是风险第一次真正变得重大的那一刻。

3.6 本章不涉及的内容

本章不会告诉你，每一项任务在你动手之前都需要先跑五次试运行。有大量确实无关紧要、真正一次性的任务，尝试一次、当场改正就完全没问题；试运行这套纪律，专门针对的是你即将为其建立一份保存下来的任务说明、并会反复使用的任务，在这类任务里，一旦看错了规律，每重复使用一次就会把错误再放大一次。

本章也不会承诺，一次干净的试运行就能保证结果永远干净。一项这个月在五次试运行中表现良好的任务，最终仍然可能在某个和你试运行样本完全不同的输入上给你意外。第五章通篇讲的就是在这种情况下发生时如何察觉，而不是说试运行能让你从此不必再盯着它。

3.7 试一试：选出你的试运行任务

列出两到三项你正在考虑最先委派出去的候选任务。用“是”或“否”，为每一项按四条标准打分：

任务	规模小	会重复	风险低	能快速核查

无论哪项任务在全部四条标准上都得到“是”，本周就用五个真实、各不相同的输入把它跑五次，并记录下实际发生了什么，而不只是“通过”或“不通过”，每次用几个词简单记下即可：

次数	输入	实际发生了什么
1		
2		
3		
4		
5		

这五行数据合起来呈现的规律，而不是其中任何一行，才是第四章的抽查方法和第五章的故障模式清单接下来要建立的基础。

要点总结

- 一项试运行任务同时做着两件事：它产出真正的工作成果，也让你在还没有押上任何昂贵赌注之前，以低成本了解这项具体任务的故障模式。
- 好的第一个任务应当规模小、会重复出现、风险低，并且能在一分钟内核查完毕。任何一项不满足的任务，都留到以后再做。
- 试运行不要只跑一次。单独一次尝试几乎说明不了什么；三到五次尝试才能揭示出真正值得学习的规律。
- 一项十五分钟任务跑五次试运行，只需一次投入、耗时不到两小时，换来的是真实的证据，而不是一厢情愿的猜测。这笔交易划算。

3.8 接下来

第四章和第五章，会把你在试运行中发现的规律，转化为一套持续的实践：如何在不用自己重做一遍的前提下高效核查产出，以及如何读懂一项任务的具体故障模式，读到能在它们再次出现之前就预判到的程度。

第 4 章

检查工作成果，而不是重做一遍

玛丽亚（Maria）为一家九人规模的园林绿化公司记账，每个季度她都要把三百四十笔费用明细交给 AI 去分类：燃油、设备、工资、材料，都是些常见的类别。第一次尝试用 AI 处理时，她事后把三百四十笔全部打开，一笔一笔对照收据核对，这花的时间比她自己来分类还要长。那天晚上她合上表格时，证明了 AI 确实能完成这项任务，却也证明自己没能省下一分钟。

到了第二个季度，第一次核对花掉的时间还让她心有余悸，于是她只是粗略扫了一眼分类，发现前二十行没有问题，就把整批直接归档了。到了五月，她的会计发现有十一笔被记成“设备”的项目，其实是加油站的燃油采购，这正是 AI 一直混淆的两个类别，因为同一个供应商在同一个收银台既卖燃油也卖设备。这十一笔分类错误的明细，让她季度数字出现了足够大的偏差，会计不得不重新编制折旧表。

这两个季度失败的原因看似截然相反，实际上却是同一种失败：玛丽亚始终没有找到那个真正值得核查的点。第一季度，她全部核对了一遍却什么也没发现，因为她并不是在针对什么特定问题去查，只是随机地重新验证了一遍。第二季度，她什么都没核对，结果错过了那个其实一直明摆在眼前、反复出现的错误：只要她知道该往哪里看，大概九十秒就能发现这个有规律可循的问题。

4.1 那个虚假的选择

全部重做和什么都不查，听起来是两个极端，但它们背后其实藏着同一个假设：检查 AI 的工作成果，要么就是全部读一遍，要么就是一个字都不读。这个假设是错的，也正是玛丽亚两个季度都失败的原因。真正的技能既不是前者，

也不是后者，而是知道错误最可能聚集在哪里，在那里下狠功夫核查，同时对其余部分放心地跳过，而不是心虚地敷衍一眼。

这并不是为 AI 专门发明出来的新技能。一位优秀的编辑在读一位初级作者的第五稿而非第一稿时，用的就是这个办法：不是从头到尾逐字读，而是直奔这类稿子通常出问题的地方，过渡段、结尾、那个需要注明来源的论断。一位经验丰富的护士检查新员工的用药记录单时，用的也是这个办法：不是把每一条记录都同等对待，而是先看高风险药物和不寻常的剂量。全部重做，是你对一个从未共事过、手头没有任何数据的人才会做的事。什么都不查，是你没有真凭实据的情况下，决定完全信任一个人才会做的事。带着明确目标去抽查，则是你对一个已经清楚其具体失误模式的人才会做的事：而这正是第三章的试运行任务本该把你带到的位置。

全部重做和什么都不查，听起来是两个极端。它们背后其实藏着同一个假设：检查，要么就是全部，要么就是全无。

4.2 聪明的中间道路为什么真的管用

这听起来应该比全部读一遍风险更高。但实测下来并非如此，原因在于人类审核他人工作时最古老、也最反直觉的发现之一：把每一项都审一遍，只会让你审得更差，而不是更好，因为注意力并不是一种可以平均分摊到三百四十行上的均匀资源。它是一种会耗尽的资源，审核进行得越久，审核者能捕捉到的错误比例就越低，这正是玛丽亚在第一季度撞上、却不知道该怎么命名的那个失败。一个在第三百行还在硬撑着扫视的疲惫审核者，捕捉到的错误，会比一个专门盯着那十二行最可能出错的清醒审核者少得多。

关键洞察

在一项关于持续注意力的最早、也是被引用最多的研究之一中，雷达操作员需要在两小时的时段里，观察一根没有刻度标记的时钟指针以不规则的间隔跳动，并报告每一次跳动。仅在最初半小时内，他们的检测率就下降了百分之十到十五，此后在剩余时段里继续更缓慢地下滑。任务本身从未改变，改变的是观察者本身。

Source: Mackworth, N.H., "The Breakdown of Vigilance during Prolonged Visual Search," *Quarterly Journal of Experimental Psychology*, 1, 1948, pp. 6-21. (论文标题：《长时间视觉搜索中警觉性的衰退》)。

这一下滑发生在最初三十分钟内，而不是第三个小时，这个细节值得细想。玛丽亚要核对三百四十行，所花的时间必然远远超过这三十分钟的门槛，也就是说，在她第一季度“全部核查”这一遍还没走到三分之一的时候，她的注意力其实已经在衰退了。她最有可能漏掉的那些行，分布也并非随机。它们不成比例地集中在批次靠后的位置，而那恰恰是真正的错误所在之处。

这是支持“有针对性核查”而非“全部读一遍”的理由。而反对“什么都不查”的理由，则不太关乎注意力，而更多关乎一个有充分文献记录的具体陷阱：一旦某个东西以“成品答案”的姿态出现，人们就会停止拿它和自己手头已有的其他证据做核对，哪怕那些证据恰恰与之相矛盾。

关键洞察

在一项飞行模拟器研究中，使用自动电子检查单的飞行员在收到发动机火警提示后被要求关闭发动机，尽管座舱内其他仪表显示的信息与该警报相矛盾。百分之七十五的飞行员依然选择听从自动系统的建议。而另一组对照组完成同样的任务时，用的是传统的纸质检查单，没有可依赖的自动建议，结果只有百分之二十五的人做出了同样错误的判断。

Source: Mosier, K.L., Palmer, E.A., & Degani, A., "Electronic Checklists: Implications for Decision Making," Proceedings of the Human Factors Society 36th Annual Meeting, 1992, pp. 7-11. (论文标题:《电子检查单:对决策的影响》).

请注意，真正造成这种差距的原因是什么。并不是自动化组的仪表更差，或者他们掌握的信息更少。他们坐在完全相同的座舱里，面对的是完全相同的、相互矛盾的仪表读数。只是自动系统给出的建议，让他们不再去看那些读数了。这正是玛丽亚在第二季度身上发生的事：那份已经分好类的表格看起来是个成品，于是她不再拿它去和本可以发现错误的那样东西做交叉核对，那就是同一份文件里她本来就有的供应商名称。

4.3 建立一套真正的抽查方法

以下这套方法，本可以让玛丽亚在大约两分钟内就发现那个错误，而不是让它潜伏了两个月才被发现。

找到接缝，而不是查中间。错误不会均匀地散布在整批任务里。它们会聚集在这项任务真正含糊不清的地方：两个存在重叠的类别、任务说明里没有覆盖到的边缘情况、工具很少见过的某种格式。在开始核查之前，先问一问这项具体任务最可能在哪里出错。就像玛丽亚的燃油与设备供应商问题，只要她花上十秒钟想一想，就会发现这原本就注定是那道接缝。

把接缝查全，而不是抽样查一部分。如果燃油和设备之间的混淆是风险所在，就该查看涉及那家供应商的每一笔明细，而不是从整批中随机抽取百分之十。在三百四十行里随机抽样，很可能因为运气不好，把十一笔燃油误分类全都漏掉。而针对那一家供应商的二十行做定向核查，能把这十一笔全部抓出来，所花的时间还只是读完全部三百四十行的一小部分。

对其余部分做轻量抽样，为的是另一种信心。已知的接缝查完之后，再从批次的其他地方快速扫一眼十到十五行，目的并不是去抓某个具体错误，而是去捕捉一种你没有预料到的模式，也就是你此前还不知道该去查的那道接缝。这种抽样是轻量的，不是穷举式的：你在留意的是意外，而不是在为确定性做审计。

每一次都把发现记录下来。接缝会随着工具失误模式的变化而变化，第五章通篇讲的就是如何察觉这种变化，而不是出于习惯，在一道接缝早已不再是真正风险之后，还继续无休止地查它。

4.4 第二道接缝，另一种任务

接缝并不总是分类混淆的问题。有时候，它只是一个被漏掉的词。

詹姆斯（James）负责管理一栋一百四十户公寓楼的维修请求，AI 会在租客发来的消息进入他的处理队列之前，先把它们分诊为“紧急”和“常规”。玛丽亚遇到的失误模式，是两个相似类别之间的混淆。詹姆斯遇到的情况不一样：这个工具偶尔会把某条消息归为常规，因为它字面上提到的维修类别通常属于小问题，但同一句话里其实还提到了水。“常规：厨房水龙头把手松了”和“常规：厨房水槽下方水龙头在漏水”这两句话，用关键词匹配的方式粗粗一看几乎一模一样，但其中只有一个才是“今天就得叫水管工”的问题，而不是“下周再处理也行”的问题。

把每一条消息都读一遍，就完全违背了自动分诊的初衷：一百四十户人家会产生大量常规噪音式的消息。而完全信任常规这个分类桶，也曾导致一起漏水问题在队列里躺了四天，直到楼下租客反映天花板出现水渍，才有人发现。等詹姆斯把这道接缝命名出来之后，它其实又窄又具体：常规分类桶里，任何同时含有“水”、“漏”、“滴”或“湿”这几个字的消息，不管它被归到了哪个类别下。他会把这类消息每一条都彻查一遍，一周有那么几条，同时轻量扫一眼常规分类桶里其余的消息，看有没有哪一条凭字面读起来其实紧急，却挂着“常规”的标签。真正的解决办法，不是多读消息，而是读对那四个字。

4.5 这笔交易到底在权衡什么

全面核查是用时间去换一种虚假的彻底感，因为一个已经查到第三百行的疲惫审核者，无论一开始有多认真，此刻都已经算不上真正彻底了。完全不核查，则是用时间去换真实的风险，也就是那种两个月后才会以“重编折旧表”的形式浮现出来的风险。而有针对性的抽查，两样都不用换。它只花几分钟，而不是一个下午，抓到的还是那些真正会发生的错误，而不是随机抽样也许碰得到、也许碰不到的错误。

不过，这笔交易之所以划算，前提是你已经大致知道一项任务通常在哪里出问题，而这种认知在第一天是不存在的。任何一项新委派的任务，在你头几次执行、还没建立起这幅图景之前，核查范围应该比本章建议的更广，更接近第三章所说的试运行那种严谨程度，而不是一次自信满满、范围狭窄的接缝核查。去抽查一道你其实还没真正确认过的接缝，并不是高效，那只是全面核查那种粗心大意，换了个听起来更聪明的名字而已。

4.6 本章不涉及的内容

本章不会告诉你，抽查可以取代对任何真正重要事项的最终签字确认。季度申报文件、面向客户的文档，任何一旦出错代价高昂或很难挽回的东西，在送出去之前，仍然需要由人从头到尾完整读一遍，就像医院不会对重症监护室患者的用药记录单只做抽查一样。抽查是应对大批量、反复出现、单个来看风险较低的工作的正确工具，这描述了大多数委派任务，但不是全部。

本章同样不会假装接缝会永远固定不变。那个一直混淆燃油和设备的供应商问题，也许下个季度就被彻底解决了，而另一道完全不同的接缝又会在别的地方出现。一个从不更新自己所查接缝的抽查习惯，说到底只是把第二季度的错误重新包装成一套“系统”而已。

4.7 试一试：为你的接缝命名

选一项你已经在委派、但还没有正式做过抽查的任务。在下一批工作到来之前，先回答以下问题：

- 这项任务在哪里真正含糊不清：是两个存在重叠的类别、一个边缘情况，还是工具很少见到的一种格式？
- 你能给出的那道接缝最窄、最具体的版本是什么：是某个供应商、某个关键词、某个字段，而不只是“有时候会出错”？
- 下一次这项任务运行时，你打算怎样把这道接缝查全，而不是抽样检查？

- 对其余所有内容做一次五分钟的轻量扫视，具体应该是什么样子，你在扫视时又在留意什么？

把答案写在一个你真的会再看到的地方。这其实就是第五章故障模式清单的全部内容，只是提前了一章开始动手。

要点总结

- 检查 AI 的工作成果，不是“全部读一遍”或“什么都不读”之间的二选一。这两个极端会以同样的方式失败：两者都没有真正针对最可能出现的错误去核查。
- 找到这项具体任务通常出问题的接缝，把它彻底查全，然后对其余部分做轻量抽样，留意意外情况。
- 自动化带来的风险不只是“可能出错”。它还会让你不再去核对那些其实就摆在你眼前的证据，哪怕那些证据恰恰与它相矛盾。
- 抽查只有在你已经知道一项任务通常在哪里出问题时才有效。在此之前，应该更广泛地核查，接近试运行的做法，而不是有针对性的抽查。

4.8 接下来

第五章会把“这项任务通常在哪里出问题”从一次性的发现，变成一种持续的习惯：为一项任务的故障模式建立起一幅真实、具体的图景，而不是每隔几个月又意外地重新认识同一道接缝。

第 5 章

摸清它的失败模式

Devon 经营着一家一人咨询工作室，他把同一款 AI 工具用于两项完全不同的工作。每周一，它起草客户提案的初稿：范围、时间表，再加上从他自己过往项目里挑出的几个可比案例数字。每天，它还负责管理他的日程，在客户要求改期时挪动会议安排。

三周后，日程助手把一次客户通话和一次牙医预约排到了同一时间，因为客户写的是“3pm EST”，而 Devon 的日历设置的是太平洋时区，工具却不动声色地认定两个时间是一致的。Devon 当天早上发现了问题，改约了牙医，并从这次经历中得出一个笼统的结论：这东西会犯粗心的错误，所以必须时刻盯着。接下来的一个月里，他读每一份提案初稿时，都像是在防备日历上那种粗心错误重演。

结果从没发生过。提案初稿有一个完全不同的问题，他是三个月后偶然才发现的，当时一位客户发邮件问，提案里“平均节省 40% 时间”这个数字是从哪来的。Devon 认不出这个数字。他自己没写过，过往的项目报告里也没有。这款工具在案例研究部分遇到信息缺口时，编造了一个听起来可信的统计数字，用的是和真实数字一模一样的、流畅而笃定的语气。这个失误和时区毫无关系，时区那次失误也和编造统计数字毫无关系。同一款工具，两项任务，两种完全不相关的出错方式，而 Devon 却花了一个月的时间，在错误的任务上防备错误的问题。

5.1 “AI 会犯错”这句话里藏着的误区

“AI 会犯错”这句话是对的，但几乎毫无用处，就像“员工有时表现不佳”是对的，却完全没告诉你哪个员工、在哪项任务上、以什么具体方式出错。

Devon 的失误不在于粗心。他把这款工具当成了一个整体，认为它只有一种失败模式，而实际情况是：他手上有两组完全独立的“任务加工具”组合，每一组都有自己特定的、可以学习掌握的、在很大程度上可预测的出错方式。日程任务在时区标注含糊时会出错。提案任务的出错方式，是在叙述出现缺口时编造具体数字来填补。这两种模式互不预示对方，把它们笼统地平均成一句模糊的提醒，“当心，它会犯错”，比毫无用处还要糟糕，因为它会把你本就有限的注意力，引向当下任务上错误的信号。

“AI 会犯错”这句话是对的，但几乎毫无用处。它没有告诉你，是哪项任务、用哪款工具、以什么具体方式出错。

同样的模式，在一项更为严谨、真正对此进行了测量的研究中，以大得多的规模再次出现。斯坦福大学的研究人员测试了几款 AI 法律研究工具，它们的营销诉求如出一辙：专为避免此前已让律师在法庭上出丑的 AI 幻觉引用问题而生。如果“AI 会产生幻觉”是关于 AI 这个大类的普遍事实，而不是关于具体“任务加工具”组合的事实，你会预期这些工具在同类任务上的出错率大致相近。事实并非如此。

关键洞察

研究人员测试了几款专为减少幻觉引用而设计的 AI 法律研究工具，发现 Lexis+ AI 在超过 17% 的测试查询中给出了错误或缺乏依据的答案，而 Westlaw 的 AI 辅助研究产品在同一类法律研究任务上的这一比例约为 33%，几乎是前者的两倍。第三款工具，Thomson Reuters 的 Ask Practical Law AI，则表现出几乎完全不同的失败模式：问题不在于编造，而在于不完整，在超过 60% 的查询中给出的答案不完整。

Source: Magesh, V., Surani, F., Dahl, M., Suzgun, M., Manning, C.D., & Ho, D.E., “Hallucination-Free? Assessing the Reliability of Leading AI Legal Research Tools,” *Journal of Empirical Legal Studies*, 2025 (originally released as a Stanford RegLab/HAI working paper, 2024) (论文标题：《无幻觉？评估领先 AI 法律研究工具的可靠性》)。

同一大类任务，三款专门打造的工具，三种不同的出错率，其中一款的出错方式和另外两款截然不同：不是编造，而是不完整。如果有人测试完 Lexis+ AI 后，得出一条关于“AI 法律研究工具”的笼统结论，他就会把这个站不住脚的错误假设，原样带进 Ask Practical Law AI，而在那里，真正的风险根本不是自信满满的编造，而是一个听起来言之凿凿、实际上却漏掉了完整答案一半内容的回答。这个教训不只对律师适用。它和 Devon 用真金白银换来的教训一模一

样：真正拥有失败模式的单位，是任务和工具的组合，而不是工具本身，更不是“AI”这个笼统的类别。

5.2 同一个矩阵的另一半

Devon 的故事展示的是一款工具、两项任务、两种不相关的失败模式。值得再看一看它的镜像情形：一项任务、两款工具，因为真正重要的单位是那个组合，而一个组合有两条轴线，不是一条。

Simone 为一家区域性连锁健身房负责营销工作，她在决定长期使用哪款 AI 写作工具之前，用同一项任务，也就是每周的会员通讯，测试了两款不同的工具。两款工具都把结构做对了：一条锻炼小贴士、一段会员故事、一条课程安排提醒。它们的差异之处则具体而稳定。第一款工具，运行五次，其中两次悄悄把课程安排提醒里的某个上课时间，改成了一个听起来合理但其实错误的时间，这种错误只有在你本就知道真实课表时才能发现。第二款工具在五次运行中一次都没碰过课程安排，但它在 Simone 的任务说明没有提供具体人选时，反复为会员故事部分编造出一个具体的会员姓名和一句具体的赞美之词，这是第一款工具从未出现过的编造问题。

同一项任务，同一份任务说明，同样的五次输入。却是两种真正不同的失败模式，一款工具一种。如果 Simone 只测试了第一款工具，就得出“AI 通讯工具会把课程时间弄乱”的结论，她就会把这个错误的提防原样带进第二款工具，盯防一个那款工具根本不会犯的课表错误，同时错过它实际上出现过两次的编造会员语录问题。Devon 那个故事的教训，在这里换了个方向再次出现，从相反的角度得出同一个结论：无论是任务本身，还是工具本身，单独都无法告诉你失败模式是什么。只有具体的组合才能告诉你。

5.3 打造一份真正的绩效评估

一份真正的员工绩效评估，不会只说“有时会犯错”。它会说清楚是哪一类错误，出现在哪一类工作上，出现频率如何，以及在什么条件下发生，因为只有这种版本的信息，才真正有助于你判断下次该重点核查什么。要为一项委派任务打造出同样的东西，需要三样原料，而如果你已经完成了第三章的试运行和第四章的抽查，这三样你其实早就都有了。

记录每一次失误的具体内容，而不只是失误的总次数。每当抽查发现问题，写下具体错在哪里，而不只是记下“出错了”。“编造了一个统计数字”和“搞错了时区”是两条不同的记录，哪怕你很想把两者都归到“出错了”这一栏里。

在多次失误之间找规律，而不是在单次失误里找规律。一个编造出来的数字可能只是偶然。三个编造出来的数字，都出现在同一类缺口里，比如案例研究部分缺了一个数据点，那就是一种规律：这项任务，配上这款工具，往往在输入信息有漏洞时倾向于编造内容。这正是值得记下来、并在此后每一份草稿里加以核查的东西，正是第四章讲的“接缝”，如今被明确点出了名字，而不是每次都靠意外重新发现。

把这种规律，同工具的整体口碑区分开。一款在排期上表现出色、却在编造统计数字上不靠谱的工具，既不是“一款好工具”，也不是“一款差工具”。它是一款在某项任务上表现出色、在另一项任务上需要专门、有针对性核查的工具。把这些统统合并成一个笼统的评价，正是让 Devon 白白错付一个月注意力的那个错误。

一旦你为某项任务做过几次这样的记录，你手上得到的东西，就更接近一份真正的人事档案，而不是一种模糊的印象：不再是“它会犯错”，而是“在提案初稿这项具体任务上，当输入数据存在缺口时，它大约五次里有一次会编造出一个用来支撑论点的数字，而它从没在日期或客户姓名上出过错”。后面这句话，准确告诉你下次该看哪里。前面那句话，从来做不到。

5.4 这份清单为什么应该短

一份有用的故障模式清单，每项任务通常只有两三条，而不是十条。一旦你开始追踪一项任务可能出错的十种不同方式，你就已经不再是在打造一份有针对性的核查清单，而是在重建第四章已经证明行不通的“事事核查、一概不信”的习惯，只不过换了个“尽职尽责”的说法。如果你的清单不断增长，超过三四条真实观察到的规律，诚实地讲，通常并不是因为这款工具真有那么多种不同的失败模式。而是这项任务本身太宽泛了，是好几份不同的工作披着一个名称，解决办法是把它拆分成它实际构成的那些更窄的任务，而不是为合并后的那项任务写一份更长的清单。

5.5 本章不涉及的内容

本章不会承诺给你一份一成不变的清单。今天还在编造统计数字的提案工具，可能在一次模型更新之后就不再这样做了，转而开始出现别的问题，也就是那种未经预告的版本变化却带来了实实在在的行为后果，正是本书在举例时刻意避免过度依赖的那类东西，因为它过时得实在太快。把每一份故障模式清单，都当作截至你最近几次核查为止的现状，而不是一劳永逸的定论。要像重新审视一份员工绩效评估那样，定期回顾它，而不是写一次就归档了事。

本章也不会告诉你，一份简短、具体的故障模式清单，就意味着这项任务可以完全不用再盯着了。它准确告诉你的是，接下来该继续盯防哪里，以及现在可以不必再那么用力盯防哪里，这比宣布整件事已经彻底解决，要小得多，也实在得多。

5.6 试一试：建立档案

挑一项你已经抽查过至少几次的任务。用大白话写下你能真正回忆起的每一次具体失误，而不是一种模糊的“它有时候不太对”的印象：

出了什么错	大致频率	在什么条件下

如果你列出的真实条目超过三四行，那不是这项任务的失败，而是一个信号，说明这项任务其实是好几项任务披着同一个名字。标出哪些行可以干脆利落地拆成一项独立的任务，把它当作一个标记，留到你下次按第三章的方法界定一次次运行时再处理，而不是今天就要解决的问题。

要点总结

- “AI 会犯错”这句话是对的，却毫无用处。真正的分析单位，是一项任务配上一款工具：每一种组合都有自己特定的、可以学习掌握的失败模式，一种组合的规律，很少能预示另一种组合的规律。
- 即便是为完全相同的目的打造的工具，出错率和出错方式也可能各不相同。测试过一款 AI 法律研究工具，几乎不能告诉你任何关于另一款为同样工作打造的工具的信息。
- 根据你实际做过的抽查，整理出一份简短、具体的清单：出了什么错、频率如何、在什么条件下发生，而不是一种笼统的印象，认为这款工具“还不错”或者“有点不靠谱”。
- 一份故障模式清单如果有超过三四条真实条目，通常说明这项任务实际上是好几项任务被硬拼在了一起。应该把它拆开，而不是写一份更长的核查清单。

5.7 接下来

第六章要讲的，是拿到一种已知的失败规律之后，究竟该怎么办：把它真正有效地反馈给工具，让它牢牢记住，而不是每次发生同样的错误时，都从头重新纠正一遍。

第 6 章

真正管用的反馈方式

Priya 是一名房产经纪人，每周 AI 都会为她的新房源描述起草初稿。可几乎每一周，草稿的语气都会有点过于浮夸：“令人惊艳”“不容错过”“转瞬即逝”。她不喜欢这种腔调，于是每次都会输入大致相同的修改意见：“别写得那么像推销。我的买家很务实，他们想知道的是使用面积和学区，不是形容词。”那一周的下一版草稿确实写得更好了。可再下一周，浮夸的语气又回来了，因为那条修改意见只存在于那一次对话里，下一套房源的描述开启的是全新的对话，完全不记得七天前她给过的提示。

到了第三个月，Priya 已经用各种说法把“别太推销、更务实一点”这句话打了至少十几遍，改过十几版草稿，可距离拥有一个能稳定用她的语气写作的工具，她并不比第一周更近。她一直在给出真正的反馈，具体而且前后一致的反馈，问题只在于这些反馈在两次对话之间没有地方可以留存。每一次修改意见都让这段“关系”从零开始，就像培训新员工时，如果你每天早上都重复同一场“入职第一天”的谈话，却从不把任何内容写下来留给对方，培训永远不会有进展。

6.1 留不住的反馈不是免费的，它是有代价的

人们很容易把一条没有被保留下来的修改意见当作“不亏不赚”：这一次它起了作用，然后就会淡去，没什么损失，下次再说一遍就是了。但反馈研究给出的结论并非如此，这一点值得说清楚，因为同样的失效模式，既藏在 Priya 每周重复的修改意见里，也藏在许多职场反馈被传递的方式里。

关键洞察

一项具有里程碑意义的元分析汇总了 607 个效应量、超过 23000 次观测，发现反馈干预平均而言能提升绩效，但其中超过三分之一的情况下，反馈实际上让绩效变得更差。这种负面效应无法用抽样误差或反馈方向来解释，真正起决定作用的是反馈的传递方式：含糊、一次性、脱离明确标准的反馈往往适得其反，而具体、紧扣任务本身的反馈则往往真正有帮助。

Source: Kluger, A.N., & DeNisi, A., "The Effects of Feedback Interventions on Performance: A Historical Review, a Meta-Analysis, and a Preliminary Feedback Intervention Theory," Psychological Bulletin, 119(2), 1996, pp. 254-284.
(论文标题：《反馈干预对绩效的影响：历史回顾、元分析与初步反馈干预理论》)

好消息是，Priya 的反馈并不含糊。“别太推销、更务实一点，买家想知道使用面积和学区”是一条具体的、紧扣任务的修改意见，正是那项元分析发现真正有效的那一类。坏消息是，问题从来不在“具体”本身，而在于传递方式。一条在对话结束时就消失的修改意见，并不是一条糟糕的修改意见。它是一条好的修改意见，只是没有地方可以落脚，每一次都要付出全部代价重新说一遍，中间却没有积累下任何东西。这和一开始就给出糟糕反馈是微妙不同的失效方式，但浪费掉的精力同样彻底。

一条在对话结束时就消失的修改意见，并不是一条糟糕的修改意见。它是一条好的修改意见，只是没有地方可以落脚。

6.2 修正和更新的区别

想象一下用老办法修改新员工的报告：你在上面圈圈点点，交还给对方，对方重做一遍。可如果你没有同时更新他们所依据的实际风格指南或模板，同样的错误完全有可能在下个月的报告里原样重现。大多数管理过他人的人，在某个阶段都明白了不能只停在“圈点批注”这一步。他们会去更新模板、检查清单、常设指令，让这条修正真正成为此后工作方式的一部分，而不只是打在某一份文档上的一次性补丁。

被人们真正委派实际工作的 AI 工具，几乎都提供某种版本的同样机制，无论它被称作自定义指令、系统提示词、保存的人设，还是记忆设置，机制叫什么远不如是否真的养成使用它的习惯来得重要。Priya 需要的修正方法，不是写出更好的修改意见，而是把同一条意见，一次性写进她的工具所提供的常设指令功能里，这样每一套新房源的描述都从“务实、以买家为中心、优先突出使

用面积和学区”出发，而不是从工具的通用默认设置出发，再等着本周版本的同一条提醒重新出现。

6.3 写出一条能挺过单次会话的修正意见

一条修改意见能否变成常设指令，而不是在对话结束时就烟消云散，取决于三件事。

把它写成一条规则，而不是针对某一次输出的抱怨。“这份草稿写得太推销了”描述的是一次失败。“这里的买家很务实：优先突出使用面积、地块大小和学区，避免使用‘令人惊艳’‘不容错过’这类形容词”描述的则是一个标准，工具可以把它套用到此后每一份草稿上，而不只是你眼前这一份。

关键洞察

组织心理学中被反复验证次数最多的发现之一，来自数十年间横跨极大范围任务类型的研究：具体、界定清晰的目标，可靠地带来比含糊目标更好的绩效表现，在直接对比的研究中，大约十分之九都显示它优于笼统的“尽力而为”式指令。

Source: Locke, E.A., & Latham, G.P., “Building a Practically Useful Theory of Goal Setting and Task Motivation: A 35-Year Odyssey,” American Psychologist, 57(9), 2002, pp. 705-717. (论文标题：《构建一套切实可用的目标设定与任务动机理论：35 年历程》)

这项发现来自对人的研究，而不是对 AI 工具的研究，而这恰恰是它值得放在这里的原因：这意味着“这里的买家很务实”之所以胜过“写得别那么推销”，和一个具体的销售指标之所以胜过对拿提成的销售员说“尽力而为”，是同一个结构性原因。一条指明真实标准、而不只是复述抱怨的常设指令，做的事情有真实、独立记录在案的证据支撑，而不只是对“或许这样效果更好”的猜测。

把它放在工具下一次真的会去看的地方。在本周这套房源的对话中途输入的修改意见，只对本周这套房源有帮助，之后什么都影响不到。同样的措辞，如果保存为自定义指令或系统提示词，就会自动套用到下周、再下周，你不必重新输入任何内容。

是更新它，而不是不断堆叠它。一条按你给出的先后顺序，累积了你所有曾经提出过的修改意见的常设指令，最终会变成工具不得不同等权衡的噪音，其中一些已经过时，一些又和更新的提醒相互矛盾。当一条新的修改意见取代了旧的，应当替换掉那一行旧内容，而不是在下面继续追加，就像一份好的风格指南是就地修订的，而不是在末尾不断增长出一份历年错误的流水账。

6.4 堆叠到底会变成什么样子

Priya 的问题，是修改意见没有地方可以留存。与之相反的问题同样常见，代价也同样高昂：修改意见被保存了下来，却从不曾被编辑过。

Malik 在一家小型软件公司负责客服支持，AI 会依据一条常设指令为收到的工单起草第一版回复，这条指令他已经陆陆续续加了六个月。每次出了岔子，他就在后面添一行新内容：未经批准不得承诺超过五十美元的退款；在确认之前不要说“这应该很好修”；遇到显示类的 bug 一律要求用户提供截图；绝不直接点名竞品；诸如此类，又添了十几条，一条压着一条往下叠。到第六个月，这条指令已经长达整整两页，而新的回复非但没有变好，反而又开始变差：在原本不需要含糊其辞的地方畏首畏尾，而那些更新、更犀利的修正意见，则被埋在早已不再适用的旧内容之下，根本没被顾及到。

解决办法不是写出更好的修改意见，而是回头重新梳理这六个月积累下来的每一行内容，去编辑它们，而不是继续添加：其中三条已经被同一条规则后来更具体的版本取代，可以直接删除；四条涉及的产品功能早已下线，完全不再适用；剩下的内容则被压缩成一份更短的清单，按类别而不是按添加日期来组织。这条指令从两页缩减到半页，效果立刻变好了，不是因为它说了什么新内容，而是因为工具不再需要把四十行积累下来、彼此半矛盾的历史，当作每一条都同样重要来权衡。

6.5 什么时候一条修改意见真的只是一次性的

不是每一条提醒都被写进常设指令，把每一次修改意见都当作永久规则，也会制造出自己的问题：一堆臃肿、难读、套用起来又慢的规则，正是第五章那条“故障模式清单要短”背后想要避免的失效方式，只不过这一次出现在了更高的一层。一条修改意见值得拥有一个永久归宿的判断标准是：你能想象自己将来在类似任务上还会再说一遍它。“这套特定房源带泳池，记得提一下”，说的是这一套房子。“这里的买家在意学区”，说的是每一套房子。保存后一种。让前一种留在它原本所属的地方，也就是那一次对话里，不必觉得有义务把一条本来只关乎某一具体工作的提醒，硬要推广成通用规则。

6.6 本章不涉及的内容

本章不会承诺一条常设指令一旦保存，就能永远有效、无需再看。第五章关于故障模式会在模型更新后发生变化的观点，在这里同样适用：三月份解决了语气问题的那条规则，到了九月，可能就需要调整，因为某次更新在没有通知

你的情况下，改变了工具默认语气的样子。要把保存下来的这套指令，当作一份活的风格指南来对待，是你会随着察觉它在偏移而不断编辑的东西，而不是写一次就再也不打开的东西。

本章也不会告诉你每一款 AI 工具都提供同样的机制，或者这套机制在哪里都叫同一个名字。有些工具在账户层面保存指令，有些在项目层面，有些则几乎不提供这项功能。就像第五章描述的那样，学习一款新工具的一部分，就是先具体弄清楚一条修改意见究竟会在哪里被真正保留下来，然后才能放心依赖它会留存在某处。

6.7 试一试：审查你的常设指令

如果你已经为某项被委派的任务保存了常设指令，现在就把它打开，逐行检查：

- 这一行是否依然适用，还是它描述的问题已经不复存在？
- 这一行是否已经被同一条指令里，别处更晚、更具体的一行取代？
- 这一行的写法是一条规则（“这里的买家很务实”），还是仍然只是针对某一次输出的抱怨（“那份草稿写得太推销了”）？找到任何抱怨，就把它改写成规则。

如果对于一项你已经修正过不止一次的任务，你还没有保存的常设指令，现在正是写下第一条的时候，用上本章的三条原则：写成规则而不是抱怨，保存在工具真的会看到的地方，并且短到能被一口气读完。

要点总结

- 一条只在某一次对话里输入、从未被保存下来的修改意见，是白白付出的真实代价。它只在那一次起作用，然后就消失了，下一次还要花同样的力气，换来同样的结果。
- 具体的反馈往往有帮助；含糊的反馈常常适得其反。但如果反馈在两次会话之间没有地方留存，光有具体性是不够的。
- 把修改意见写成常设规则，而不是针对某一次输出的抱怨，并把它保存在工具下一次真的会看到的地方，而不只是留在本周的这次对话里。
- 当一条新的修改意见取代了旧的，要就地更新常设指令。堆积如山、从不编辑的历史修改意见，只是噪音，不是指导。

6.8 接下来

第七章会把同样这套“关注故障模式”的习惯，用在它最难的一种用法上：识别一项任务的错误，无论你把任务说明写得再好、检查得多仔细、修正得多到位，都始终降不下来，并判断什么时候正确的做法是彻底不再委派这项任务。

第 7 章

何时该“解雇”它

Renata 经营着一家小面包店，将近一年的时间里，顾客网上评价的回复初稿，都是由 AI 起草的。它做得相当不错。一条抱怨取餐排队太慢的三星评价，AI 在十五秒内就写出了一条热情、具体、贴合品牌调性的回复，而不是像 Renata 过去那样，要花上十分钟去琢磨该用什么语气。她按照第五章的建议，建立了故障模式清单，找到了唯一值得留意的那道接缝：它偶尔会过度承诺某个具体的未来改进（比如“我们已经解决了周末人手不足的问题”），而实际上什么都没有改变。她按照第六章讲的方法，把这条纠正意见写成常设指令反馈回去，然后看着这道接缝合上了。对于普通评价，这套系统的运作方式，正如本书前文所说的那样。

然后，一条评价出现了：有顾客声称吃了她家的蛋糕后生病了。AI 起草的回复同样热情、具体，但道歉的方式在 Renata 看来，已经危险地接近于承认自己在一起食源性疾病指控上有过错，而她其实根本没有证据证明这件事是真的。她及时发现了问题，自己重新写了回复，并更新了常设指令：只要评价提到生病，就标记出来，交由真人全权处理。两个月后，同一个问题换了个样子再次溜了过去：一条评价提到顾客“吃了纸杯蛋糕后肠胃不适”，措辞恰好绕开了那条标记规则，草稿又一次道歉了，她不得不再花力气去撤销。

这一次，Renata 没有再去修补它。她不再把这件事委派出去。凡是不涉及潜在法律责任的评价，仍然先经过 AI 处理；凡是涉及疾病、伤害，或任何近似法律纠纷的评价，则直接交给她本人，不经过草稿，完全跳过 AI 这一步。这并不是本书一直在搭建的这套系统出了问题，恰恰相反，这正是系统在正确地运作，因为管理任何对象，无论是人还是工具，本就包括看清楚：不管候选人在简单任务上表现得再好，有些工作就是过不了第一周。

7.1 该停手的四个理由，而不是一个

“不管用”这种说法，笼统得没法拿来采取行动，就像第五章里“它会出错”这种说法一样笼统。一项任务之所以该被列入停止委派的清单，背后其实有四种截然不同的原因，它们需要不同的应对方式，而不是一条一刀切的经验法则。

这是需要判断的事，而不是可归纳的模式。有些任务原则上就写不出一条规则，因为正确答案取决于每次都不同的具体权衡：这位顾客到底有多生气，这件事处理不好会不会演变成更大的麻烦，这段特定的关系是否值得为其破例，放宽一条原本该坚持的政策。Renata 遇到的那些涉及疾病的评价，正属于这一类。无论常设指令写得多么周密，都无法替代每一次都要重新做出的判断。

这要依赖特定的关系。有些任务依赖的是工具在结构上根本不可能拥有的历史：这位特定客户去年说过什么，这位特定供应商已经了解你的处境到什么程度，一段长期关系所携带的、从未写下来的默契。AI 可以用你的语气起草文字，但它记不住这位特定顾客两年前有过一次糟糕的经历，因此一句普通的道歉，对她而言恰恰会显得不对劲。

单单一次出错的代价，超过所有成功加在一起的价值。大多数被委派的任务，出错的代价很低：一条稍显套路的回复，多花三十秒去修正而已。但也有极少数任务，出错的代价极高：一句需要律师事后去撤销的不实担责表态，一段客户关系受损到无论后面回复得多好都弥补不回来。当一次坏结果的下行风险，超过一百次好结果的上行收益时，这笔账不会在乎坏结果发生的频率有多低。

当一次坏结果的下行风险，超过一百次好结果的上行收益时，这笔账不会在乎坏结果发生的频率有多低。

错误率始终降不下来。第五章和第六章那一整套方法，本来就是为了防止这种情况发生，而这恰恰是它值得单独列为一类的原因：有时候，你每一步都做对了，找到了真正的接缝，写出了具体的纠正意见，也妥善保存了下来，可这个模式就是合不上。这是真实的信息。它说明这项任务的难度，超出了一条常设指令能解决的范围，而不是说明你还不够努力。

7.2 就算你每一步都做对了

Renata 的故事，展示的是一项需要判断的任务，如何在两次尝试之内就被迅速识别出来。而第四条标准，也就是错误率始终无法收敛的那一种，值得放在一项从头到尾都不曾仓促行事的任务上，看它是如何呈现出来的。

Teodora 是一名独立执业的财务顾问，经营着一家小型工作室。她花了整整两个月，试图把季度投资组合再平衡说明的初稿委派出去，那是她每个季度发

给每位客户的一段简短说明，解释他们的资产配置为何发生了变动。她严格按照方法来做。一份真正完整的五要素任务说明。在信任任何结果之前，先在八个不同的客户账户上做了试运行。针对她发现的接缝做了有针对性的抽查，那道接缝出现在涉及客户债券配置的说明里：工具描述利率风险的方式，在技术上说得过去，却不是她本人真正会用的表达方式。她写了一条常设指令，随着新的债券相关失误不断出现，又修改了两次。到第八周，债券配置那道接缝依然没有合上，它只是换了三次形状。

这是真实的信息，而不是个人的失败。这两个月里，Teodora 没有做错任何事；如果她放低标准，宣称“够用了”，那就等于把一份技术上说得通、但略有偏差的说明，发给客户，去解释他们自己的钱，而这恰恰是那种“大体正确”算不上及格的任务。她把这项任务“解雇”了，但只针对债券占比高的账户；对于更简单、纯股票的再平衡说明，那道接缝其实早在第三周就已经干净地合上了，她保留了委派，只把债券相关的说明收回来自己写。两个月认真而严谨的努力，得到的是一个精确、狭窄的答案，而不是一个含糊的答案，而这正是这番努力的意义所在。

7.3 同一个教训，在更大的舞台上重演

同样这四个理由，也在近几年一次颇为引人注目的 AI 退场事件中，以更大的规模上演过。2021 年，McDonald's 开始与 IBM 合作，在得来速车道测试 AI 语音点单系统，最终在美国一百多家门店上线。它因此出了名，一种颇为尴尬的出名方式：网上疯传的视频里，系统给顾客的冰淇淋订单里加了培根，硬塞进九杯没人点的甜茶，或者在顾客反复要求停止之后，还在不断往订单里加鸡块。

关键洞察

在与 IBM 合作测试得来速自动 AI 点单大约两年之后，McDonald's 于 2024 年 6 月终止了这项试点，并开始从参与门店撤下这项技术。官方从未公布过正式的错误率数据，但这一决定是在一种持续、被广泛记录的模式之后做出的：点单出错、背景噪音和口音让系统混乱、顾客的更正被系统忽略、相邻车道的订单相互串单，这些问题在很长一段时间里反复出现在病毒式传播的视频中，而不是随着系统调优逐渐消失。

Source: “McDonald's to end AI drive-thru test with IBM,” CNBC, June 17, 2024; “McDonald's is ending its drive-thru AI test,” Restaurant Business, June 2024 (报道标题分别为《麦当劳终止与 IBM 的得来速 AI 测试》与《麦当劳正在终止其得来速 AI 测试》)。

留意一下，这里实际起作用的，是四个理由中的哪一个。它不是像 Renata 面包店那种单次代价灾难性的错误，也就是一句不实的担责表态。起作用的，单单是第四条理由：两年，对于一家拥有真正工程资源的大公司来说，是一段相当长的时间窗口，足以把差距补上，而错误的模式始终没有收敛。McDonald's 并没有说语音点单永远行不通，公司仍然对尝试其他供应商敞开了大门。终止的，是这一次具体的尝试，理由是这一款具体的工具，在这项具体的任务上，并没有朝可靠的方向收敛，而在生产环境里继续运行它，在信任成本和善后成本上付出的，已经超过了它在人力上节省下来的。

另一次大公司的退场，展示的则是第三条标准：单一类别的错误，规模大到足以抵消其他一切。

关键洞察

Zillow 经营着一项购房业务，用自动定价算法直接给房主开出现金报价，2021 年，公司不再允许自家的定价专家推翻算法给出的估值。当房价变动的速度超过算法调整的速度时，Zillow 为其房产库存计提了最高达 \$569 million 的减值，并裁减了 25% 的员工，同时彻底关闭了这项业务；等 2021 年全年业绩公布后，这个炒房部门的全年亏损约为 \$881 million。

Source: “Zillow Shuts Down Home-Flipping Business After Racking Up Losses,” Bloomberg, November 2, 2021; “Zillow to Lay Off 25% of Its Workforce and Shutter House-Flipping Service,” CBS News, November 2021; Zillow Group Q4 and full-year 2021 earnings release, February 10, 2022（报道标题分别为《Zillow 在持续亏损后关闭炒房业务》《Zillow 将裁员 25% 并关闭购房转售服务》，以及 Zillow 集团 2021 年第四季度及全年财报）。

不再让人类定价专家推翻算法这个决定，才是真正值得细想的细节。问题不在于算法总是出错，而在于取消了人工校核之后，就再没有任何东西能在算法出错的那一刻拦下它，而这恰恰发生在这样一种规模上：一种糟糕的定价模式，一旦在成千上万套房子上重复出现，就足以抵消它之前所有准确估值的价值。一条面包店评价里不实的担责表态，和大规模买入的高估房产，二者的量级天差地别。但底层的算法是一样的，正是本章前面那一条：当某一类错误的代价足够高昂时，其他地方再多的好结果，也买不回来。

7.4 “解雇”真正意味着什么

“解雇”一项任务，不等于放弃这个工具。Renata 仍然把绝大多数的评价回复委派出去。她“解雇”的，只是一项任务里极窄的一个切片，也就是涉及疾病的投诉，而不是整个评价回复系统，而这种狭窄，正是关键所在。上文那份淘

汰标准清单，针对的是某一项具体的任务，而不是对 AI 的整体裁决，这正是第五章区分过的：工具的整体声誉，和某一项具体任务的失败模式，是两回事。一项任务只要触碰到四项标准中的一项，就该被收回；其余的一切，照常运行。

值得诚实面对的是，这里有让人不好受的一面：收回一项你已经投入过心力、认真写过任务说明、抽查过、纠正过的任务，那种感觉像是一种损失，而这种感觉，是从一开始就没有委派出去所不会有的。但它并不是损失。第三章的试运行、第四章的检查、第六章的纠正，在这里都起到了各自的作用。正是它们，产生了“这项具体任务该被列入清单”的证据。一次以“这个不该委派”收尾的试运行，是一次成功的试运行，而不是一次白费的试运行，就像一段试用期，如果能在风险变大之前，就准确识别出某人不适合这份工作，那正是这个流程在起作用，而不是流程失败了。

7.5 本章不涉及的内容

本章不会告诉你，这四条标准是对一项任务的永久裁决。今天处理不好涉及疾病评价的工具，在底层模型经过真正的改进之后，或许就能妥善处理了，这正是第六章提醒你要留意、而不是想当然排除掉的那种变化。不时用一次小规模的新试运行，重新审视一项已经被“解雇”的任务，就像你会重新考虑此前认定某位员工不适合的一个职位，而不是把最初的决定当成永远固定不变的结论。

本章也不会告诉你，每一项困难的任务，都会同时触碰全部四条标准，或者说，你需要凑齐全部四条才能有理由收回一项任务。一条就够了。一项任务哪怕风险很低，只要它确实是一个没有可学习模式可循的判断题，就仍然该被列入清单；同样，一项任务哪怕存在可学习的模式，只要一次失误的代价足够高昂，也仍然该被列入清单。

7.6 试一试：运行淘汰标准清单

挑选一项你目前正在委派的任务，最好是已经运行了足够长时间、背后已经积累出真实故障模式清单的那种。诚实地回答以下问题：

问题	是 / 否
----	-------

这项任务是否有任何部分，依赖的是一个没有可学习规则可循的判断？

问题	是 / 否
它是否依赖工具在结构上根本不可能拥有的关系历史？	
单单一次失误的代价，是否会超过所有好结果加在一起的价值？	
在经过真正的试运行、真正的抽查和真正的纠正之后，错误率是否依然没有真正降下来？	

只要有一个“是”，就足以收回这项任务，或者收回其中的那一个切片，就像 Renata 收回涉及疾病的评价、而不动其余部分一样。四个“否”，则是真实的、靠证据挣来的信息，说明这项任务可以照常安全地继续运行下去，而不是一种猜测。

要点总结

- 一项任务之所以该被列入停止委派的清单，背后是四种截然不同的原因之一：它是一个没有固定规则可循的判断题；它依赖工具无法拥有的关系历史；单单一次错误的代价，超过所有成功加在一起的价值；或者，即便付出了真正的努力，错误率依然始终降不下来。
- 四条之中，有一条就够了。你不需要凑齐全部四条，才有理由收回一项任务。
- “解雇”一项任务，通常意味着缩小范围，而不是放弃这个工具。收回失败的那个具体切片，其余的继续委派。
- 一次准确识别出“这项任务不该委派”的试运行，是一次成功的试运行，而不是一次白费的试运行。它正是第三章、第四章和第六章存在的意义所在。

7.7 接下来

到目前为止，本书讲的都是如何把一项被委派的任务管理好。第八章要讲的是，当你同时管理好几项任务，而不再只是一项时，哪些会变，哪些不会变。

第 8 章

你的第二位，第三位“员工”

Marcus 经营着一家两诊室的物理治疗诊所。在使用 AI 的第一年结束时，他已经为一项任务搭建起本书描述的整套系统：把新病人的病历填写表整理成一份干净的病历摘要，存入档案。他清楚这项任务唯一真正的接缝在哪里：用药清单。表格里的用药信息如果没有按其余部分的格式填写，系统偶尔会漏掉一种药。他为此保存了一条常设指令，每次都会重点检查这个接缝，其余部分则快速浏览。这套办法很管用。

底气足了之后，他在一个月内又新增了三项任务：预约提醒短信、每月患者简报，以及保险理赔的简短摘要说明。单独来看，每一项都是不错的候选任务：规模小、会重复出现、可以核查，正是第三章所建议的那种任务。麻烦是几周后才显现的，而且出问题的不是哪一项任务本身，而是 Marcus 自己。他发现自己盯着简报那道接缝检查（偶尔夸大疗效的说法，比如“效果保证”），却把这套检查习惯用到了保险理赔说明上，而那边真正的风险其实完全是另一回事：把理赔代码从错误的就诊记录里复制了过来。他建起了四套好用的系统，然后用同一种模糊的“多留意点”心态去运转全部四套系统，而这正是第四章早已指出的那种失败：既不是事事都读，也不是什么都不读，而是这一次在错误的任务上盯错了地方，而且规模从单个条目放大到了整份名册。

8.1 Why attention alone stops working past one or two

单独看，没有一项任务变得更难。真正变化的，是 Marcus 要求自己的记忆同时装下四份独立的故障模式清单、四套独立的常设指令，以及四种关于“哪项任务目前值得信任、哪项需要多留意”的独立判断，还要在一整天里随时在它

们之间切换，却从未把这些信息写在同一个地方。这是一个认知负荷问题，不是委派问题，而这个问题在 AI 领域之外早已被充分研究过。

关键洞察

关于任务切换的研究发现，在不同任务之间转移注意力所付出的心理代价是真实且可以测量的，并不只是一种“感觉分心”的说法。根据美国心理学会（American Psychological Association）对这类研究的总结，在任务之间切换，代价可能高达一个人本可用于产出的时间的百分之四十，其根源在于每次注意力从一项任务的规则转向另一项任务的规则时，大脑都需要经历一次“重置”。

*Source: American Psychological Association, “Multitasking: Switching costs,” apa.org/topics/research/multitasking, summarizing research including Rubinstein, J.S., Meyer, D.E., & Evans, J.E., “Executive Control of Cognitive Processes in Task Switching,” *Journal of Experimental Psychology: Human Perception and Performance*, 27(4), 2001, pp. 763-797. (该总结题为《多任务处理：切换成本》，援引的研究论文题为《任务切换中认知控制过程的执行控制》)。*

一位只有一名直接下属的经理，几乎不费力就能把对方的整体表现记在脑子里。而一位有八名下属的经理做不到这一点，那些能把八个人都管好的经理，也几乎从不是单靠记忆做到的。他们会保留某种实际记录，哪怕只是非正式的：谁在哪方面表现出色，谁在哪方面需要更密切的指导，哪些反馈已经给过、哪些还没给。Marcus 恰恰为他的病历摘要任务建立起了这样的纪律，却在需要追踪的任务超过一项的那一刻，悄悄把这套纪律丢在了一边，转而依赖那种从未在超过一项任务上经受过考验的、未加辅助的记忆。

一位有八名直接下属的经理，靠的不是把全局记在脑子里。能把好几项委派任务都管好的人，靠的也不是这个。

8.2 A roster, not a bigger memory

解决办法不是管得更用力，而是把第三章到第七章早已要求你为任何单项任务准备好的那四样东西，一次性写下来，这样新增第二项、第三项任务，就变成了在名单上多加几行，而不是要求你的注意力去做本该由笔记完成的工作。对每一项委派出去的任务，只需一条记录、四个简短字段就够了。

它是什么，是怎么开始的。任务本身，加上一句关于试运行情况的简短记录，这样你就不必凭记忆重新判断这项任务到底已经赢得了真正的信任，还是仍处于早期阶段。

它已知的故障模式清单。第五章里那两三种真实、具体的模式，刻意保持简短，正是那些原本只存在于你脑子里的信息。

它当前的常设指令。不是把实际保存的提示词整个抄一遍，只是一句话指出已经修正并锁定了什么，这样你就不必去猜上个月的修正到底有没有真正保存下来。

它相对于四项淘汰标准的状态。第七章的清单，逐项打勾或标记，这样“这项任务是仍在赢得信任，还是其中某个部分已经被‘解雇’”就是一个你能读出来的事实，而不是一种你必须重新拼凑的感觉。

这不是一套要重新学习的新系统，而是你早已在按任务逐项运行的那套系统，只是一次性写在同一个地方，而不是在需要追踪的条目超过一条的那一刻，就交给记忆去承担。Marcus 的版本一页纸就能装下：四行，四个简短的列，只要有变化，一分钟之内就能更新。它的价值不在于格式本身，而在于你不必再把四项任务的全部细微差别，都塞进那种任务切换研究已经证明每次转移都会退化的、有限的注意力里。

8.3 Deciding when you actually have room for another one

名册还能回答一个仅凭注意力很难回答好的问题：你是不是真的准备好再新增第五项任务了，还是只是因为今天比较清闲，才有了这种“准备好了”的错觉。在添加任何新任务之前，先做两项诚实的检查。

现有的任务是不是还在持续教你新东西？一项刚上线几周的任务，如果还在不断暴露故障模式清单里新的角落，就仍然需要真正的注意力。在一项尚未稳定的任务之上再叠加一项新任务，会在两项任务最需要注意力的这段时间里，把注意力硬生生一分为二。

如果这项新任务的抽查出了问题，你真的会注意到吗？如果诚实的答案是“大多数星期里大概不会”，这并不是要你跳过试运行的理由，而是一个信号：你已经超出了自己真正的管理幅度。这正是每一项关于经理带太多直接下属的研究里都会出现的警示信号：不是某一个下属表现不好，而是经理自己的注意力已经在不知不觉中丧失了分辨能力。

关键洞察

一项覆盖超过二十万个由经理带领的团队的大规模分析发现，经理投入度（作为衡量经理究竟在多大程度上真正跟踪着下属工作情况的替代指标）大约在八到九名直接下属时达到峰值，超过这个幅度后就开始下降，不过技能娴熟、支持充分的经理，能够有效带领的人数可以显著超出这一中位数。

Source: Gallup, "Span of Control: What's the Optimal Team Size for Managers?", gallup.com/workplace/700718, January 2026. (题为《管理幅度：经理的最佳团队规模是多少?》)。

请注意，这项发现说的不是“八人就是上限”，而是超过这个幅度后，投入度会下降，除非有什么东西能加以弥补，而这正是名册要扮演的角色。一位持续追踪书面记录、清楚谁在哪方面表现突出的经理，能把自己真正的管理幅度拓展得比只靠记忆的经理更远，就像 Marcus 的四项任务名册，让他在第五项任务诱惑他的那一刻，仍能把四项任务都盯好，而不是四项都盯得一团糟。

这两项检查都无关某个固定的任务数量。有些人能把六项委派任务都管得很好，因为每一项都已经稳定、维护成本低。也有些人两项任务都还很新、很不稳定，就已经力不从心。名册的作用，是让这个诚实的答案变得可见，而不再是一种猜测。

8.4 The roster making the call for you

下面来看看，当一个真实的决定摆在面前时（而不只是一种假设），这一切具体是什么样子。

Priyanka 为一家小型物流经纪公司负责运营，她为五项委派任务维护着一份名册：装货确认邮件、每周承运商表现摘要、发票分类、每月客户简报，以及司机排班确认。三月份出现了第六个候选任务：新客户入职资料包的初稿，规模小、会重复出现、可以核查，单独来看完全符合第三章的所有要求。在开始试运行之前，她没有凭那一周的感觉行事，而是先调出了名册。

第四行，客户简报，才刚运行三周，还在不断暴露故障模式清单里新的角落，一连串被夸大的送达时间承诺，她还在持续修正。第二行，承运商表现摘要，已经一个多月没有真正需要她过问了：很稳定，其常设指令自二月以来就没再动过。名册让答案变得可见，而不再是猜测：她缺的不是任务总量的余力，而是分给那项真正仍需要她关注的任务的注意力。她把入职资料包又推迟了三周，直到简报那道接缝合上、第四行从她每天需要关注的清单上消失，才按原计划开始了新的试运行。这个决定没有掺杂任何直觉成分，需要的只是读一读她早已写下来的五行记录。

8.5 What this chapter will not do

这一章不会告诉你委派的任务越多越好，也不会说名册的作用是帮你尽可能多接任务。名册真正的作用恰恰相反：在你实际盯得过来的任务数量已经被超过时，用白纸黑字把这一点清清楚楚地摆出来，赶在这件事以昂贵的方式暴露之前，也就是赶在某项任务已经悄悄滑过了“还有人在检查它真正的接缝”这条线之前。

它也不会假装一份书面名册能取代第四章到第七章里那些真正的判断力。名册装的是你已经学到的东西，它自己不会学习任何新东西，而一份没人在第一周之后更新的名册，和完全没有名册一样没用，只是还多附赠了一份虚假的安全感。

8.6 Try this: start your roster

对你目前委派出去的每一项任务，写下一行：

Task	How trial went	Failure-mode list	Standing instructions	Disqualifier status
------	----------------	-------------------	-----------------------	---------------------

在往这张表格里添加任何新内容之前，先回答本章提出的那两项诚实检查：现有的某一行是不是仍在持续教你新东西，以及如果它的抽查大多数星期都出了问题，你是否真的会注意到。只要任何一个答案让你犹豫，那正说明名册在发挥作用。

要点总结

- 靠未加辅助的记忆来管理多项委派任务之所以会失败，原因和任务切换会消耗真实、可测量的注意力完全一致：在不同故障模式画面之间来回移动的心理成本累积得很快，哪怕没有任何一项任务本身变得更难。
- 维护一份简单的名册：任务是什么、它已知的故障模式清单、它当前的常设指令，以及它相对于第七章四项淘汰标准的状态。原地更新它，而不是每次都凭记忆重建一遍。
- 在新增一项任务之前，检查现有的任务是否仍在持续教你新东西，以及如果它大多数星期的抽查失败了，你是否真的会注意到。如果答案是否定的，说明你已经超出了自己真正的管理幅度。
- 一份没人更新的名册，比完全没有名册更糟。它只有在保持鲜活、持续更新时才有用，而不是写一次就放着任其过时。

8.7 Where this goes next

第九章将探讨另一种规模化方式：不是让更多独立任务并行运行，而是把若干个委派出去的小步骤串联成一条更长的工作流，也就是任务链，以及这种做法在何处会不再划算。

第 9 章

一人团队

Ola 经营着一家小型非营利组织，每个季度她都要给以往的捐赠人寄送一封筹款信。这封信需要按顺序完成三件事：研究本季度的捐赠趋势，好让信的开头能引用一些应景的内容；围绕这项研究撰写正式的募捐信；再将成稿排版，用于邮件合并，让每封信都能带上捐赠人的姓名和上一次的捐赠金额，实现个性化。以前这三件事都是她自己做，慢慢做。后来她尝试把整条链条一次性委派给 AI：先做研究，再据此撰写信件，再排版合并，一次性完成。

寄回来的信写得很漂亮。信的开头引用了一个听起来很具体的说法：四十岁以下的捐赠人中，按月捐赠的比例正在上升。整封信的情感诉求都是围绕这个趋势展开的，而且顺利合并生成了三百封个性化的信件。Ola 差点就把信发出去了。她之所以发现问题，纯粹是因为一位理事会成员碰巧问起这个“四十岁以下”的统计数字是从哪里来的，Ola 去查的时候，发现研究步骤自己的笔记里根本找不到这个说法。它是在研究和起草之间的某个环节里悄悄冒出来的，是对一个含糊得多的真实趋势的一种听起来言之有理的演绎。等它进入排版好、个性化、随时可以寄出的最终版本时，它看起来和周围所有真实的内容一样权威可信。

没有哪一个单独的步骤，是像第五章 Devon 的提案草稿那样，明摆着在一个明显的空白处塞进一个编造的数字，出了明显的错。每一个步骤，都在前一步产出的基础上，做出了看似合理的推进，而这恰恰就是问题所在：第三步完全信任第二步的产出，第二步完全信任第一步的产出，而人类也好，别的什么也好，从来没有人去看过任意两步之间的那道接缝。

9.1 为什么任务链比其中任何一步都更危险

单个被委派的任务，要么做对，要么做错，第四章讲的抽查纪律已经能拦住大部分要紧的问题。但一条任务链，环环相扣，前一步喂给下一步，它带来的风险不只是简单相加。它是复合叠加的，就像一台由好几个部件依次串联而成的机器，其可靠性取决于所有部件同时正常工作，而不是取决于表现最好的那个部件，也不是取决于平均水平。

关键洞察

关于 AI 系统在不同长度和复杂程度任务上的表现，已有研究发现了一个一致的规律：随着任务需要更多连续步骤或更长时间才能完成，可靠性会急剧下降，即便模型的整体能力逐年都在提升，这个规律依然成立。2025 年一项被广泛引用的研究测算了这一点，发现领先模型能够可靠地完成简短、简单的任务，但随着任务长度和步骤数量增加，它们在真实场景中的成功率会急剧下滑。研究者发现，这个差距一直在随时间缩小，但截至这项研究进行时，差距依然很大。

Source: METR (Model Evaluation and Threat Research), Kwa, T., et al., "Measuring AI Ability to Complete Long Tasks," arXiv:2503.14499, March 2025 (论文标题：《衡量 AI 完成长任务的能力》)。

从算术的角度想想这意味着什么，而不只是凭直觉。如果单个步骤十次里能对九次，对于一项被委派的任务而言，这已经是个不错的比率，远高于第四章那种抽查纪律要低成本拦住剩下问题所需要的水平。把这样的三个步骤串联起来，中间没有人检查，三步全部做对的概率就不再是百分之九十了。它会接近百分之七十。串联五步，会接近百分之六十。不是每个步骤本身变差了，是这条链变差了，纯粹是因为长度的缘故，而最终排版完成的成品，不会给你任何视觉上的提示，告诉你真正的错误是从哪一步悄悄溜进来的，这和 Ola 那封邮件合并出来的信一模一样：无论底层那个说法是真是假，信看起来都同样光鲜体面。

任务链失败，不是因为某一步变差了。它失败，是因为长度会让风险复合叠加，而一份光鲜的最终成品，不会给你任何线索，告诉你究竟是哪一步出了问题。

9.2 解药是检查点，不是一个编程项目

有一点值得说清楚，因为人们很容易以为，多步骤流程的解药，是一条更精密、更自动化的流水线：不是这样的，这本书也不会因此变成一本讲自动化流水线的书。要修好 Ola 那封信出的问题，你不需要学会搭建一个自主智能体，不需要写脚本，也不需要把各种 API 调用串联起来。你只需要一件事：在每一步的产出变成下一步的输入之前，让人亲自看一眼，这就是第四章讲的那套抽查纪律，只不过这次要插入到链条里的每一道接缝上，而不是只放在最后。

先跑研究这一步。读一遍，特别留意任何读起来像是硬数字，或者是那种如果理事会成员追问你也要能站得住脚的说法。确认无误之后，才把经过审核的研究交给起草这一步。对照你已经核实过的研究去读草稿，专门留意 Ola 当初漏掉的那种偏移：某个说法听起来像是出自研究，但细究起来又对不上号。确认无误之后，才把经过审核的草稿交给排版这一步，这一步通常是三步里最安全的，因为排版很少会凭空造出新的说法，它做的只是把已有的内容重新排列。

三次简短的审核，每一次成本都很低，因为每一次都只是拿一个步骤的产出，去对照它对应的输入来检查，加在一起花的时间，比把成稿从头到尾读一遍还要少，而且它们能拦住那种成稿通读法最不擅长拦住的错误：一个错误，在被真正看到之前，已经多经过两道工序，被打扮成自信而连贯的文字了。

关键洞察

软件工程领域被引用最多的发现之一是，在一个多阶段流程中，缺陷被发现得越晚，修复成本就会急剧上升，按经典数据估算，不同项目之间这个倍数从大约四倍到高达一百倍不等：在早期需求阶段修复很便宜，一旦进入设计或编码阶段就会明显更贵，一旦交付上线、在实际使用中被发现，成本又会再高出一大截。

Source: Boehm, B.W., "Software Engineering Economics," Prentice-Hall, 1981 (data originally presented in Boehm, B.W., "Software Engineering," IEEE Transactions on Computers, C-25(12), 1976) (书名：《软件工程经济学》；原始数据发表于论文《软件工程》)。

这个规律并不是软件行业独有的，这也正是为什么在每一道接缝处检查，会比只在最后检查更有效。一个编造出来的统计数字，如果在研究步骤就被抓到，Ola 花三十秒把它划掉就行了。同样的数字，如果是在它已经撑起了整封募捐信的情感核心之后才发现，代价就是要重写。如果是在排版和邮件合并之后才发现，摆在三百封已经个性化的信件里，代价要么是一封尴尬的召回邮件，要么是永远都没被发现、只能自己承担的声誉损失。这个错误本身并没有随着阶段推进变得更离谱，它只是随着阶段推进变得更贵，因为它上面又叠加了更多的工作。

9.3 知道在哪里该停止串联

不是每一个多步骤流程都值得在每个阶段都交给 AI 串联着做，第七章那份淘汰标准清单背后的那种直觉，放到这里同样适用，只是这次适用的对象是一个具体的步骤，而不是整个任务。比如，如果任务链里的某一步是个判断性的决策，比如研究该优先关注哪些内容，取决于你知道理事会这个季度真正在意打动哪些捐赠人，这样的一步或许该留给 Ola 自己来做，让 AI 在她做完这个判断之后，接手后续的起草和排版步骤，而不是试图替她做这个判断。

一条三步的任务链，每道接缝都有一个检查点，对几乎任何愿意多花几分钟在步骤之间读一读的人来说，都是可以驾驭的。而一条七步或八步的任务链，即便每道接缝都仔细检查过，花在审核上的时间也会开始超过起草环节省下的时间，这正是第四章讲过的那笔账，只不过这次是发生在一整个流程上，而不是一份文档上。当任务链变得那么长的时候，更好的解药通常不是加更多自动化，而是把任务链砍到那些真正能从委派中获益的步骤，剩下的自己做，这正是第七章已经教过你的那套分诊逻辑。

9.4 当问题出在任务链本身

有时候，解药不是加更多检查点，而是把任务链缩短。

Desmond 经营着一家小型活动公司，他曾尝试把活动结束后给客户的总结报告，自动化成七个串联的步骤：拉取出席人数、汇总供应商反馈、起草“亮点”部分、起草“待改进”部分、把这些内容整合成面向客户的叙述、按公司模板排版、再生成一封引用这份总结的跟进邮件。他很尽责地按照本章的建议，在每一道接缝都加上了检查点，结果发现光是审核就要花掉将近一个小时一场活动，几乎和以前手写整份总结所花的时间一样长。

问题不在于哪一个检查点本身有多难，而在于七个步骤就意味着七个检查点，而第四章警告过的那笔审核时间成本，也随着任务链一起变长了，而不是保持低廉。Desmond 把它砍成了三步：第一步把原始数据和反馈一起拉取出来，第二步根据审核过的数据起草完整的叙述，把“亮点”和“待改进”放在一起写，第三步排版。两个检查点，不是六个。他之前搭建的那个七步版本，并不是一个更周全的流程。它其实是一个真正的任务，披着一条长任务链的外形，好几个子步骤根本不需要分开，只是因为串联已经变成了默认的做法，而不是一个经过深思的选择。

9.5 本章不涉及的内容

本章不会告诉你，所有多步骤任务都不适合委派，也不会说串联是一种应该避免的手法。Ola 那套三步流程，加上两个检查点之后，现在运作得很好，而且每个季度都比她自己从头写一遍这封信节省了实实在在的时间。真正的风险从来都不是任务链本身，而是让整条链跑完却没有人看过任何一道接缝，把一份光鲜的最终成品，误当成“背后每一步都做对了”的证据。

本章也不会假装，每道接缝都设检查点就能拦住一切。一个匆忙、疲惫，或者在某道接缝上检查错了地方的审核者，仍然可能漏掉那里真正出的问题。第四章讲过的那些局限，在任务链的每一道接缝上依然成立，不只是在最后一步。检查点这个习惯，能降低任务链悄无声息地复合叠加风险的可能性，但它取代不了第四章和第五章一路在建立的那种真正的判断力。

9.6 试一试：画出你的任务链

如果你已经在运行，或者正在考虑运行一个多步骤的委派流程，把实际的步骤按顺序写出来：

步骤	它产出什么	这里设一个检查点，值得花时间吗？
----	-------	------------------

数一数步骤的数量。超过三四步之后，诚实地问问自己：是不是有相邻的两个步骤，其实是同一个任务戴着两个不同的标签，就像 Desmond 的“亮点”和“待改进”两部分那样。在你加上任何一个检查点之前，先把能干净合并的步骤合并掉。

要点总结

- 一条委派任务链，比任务链里任何单独一步都更危险。错误会随着步骤层层复合叠加，就像任何一个依次串联的系统，其不可靠性会在各个部件之间复合叠加一样，即便每一个单独的步骤本身相当可靠。
- 一份光鲜、排版完整的最终成品，不会给你任何线索，告诉你错误究竟是从哪一步进来的。等你读到成品的时候，一个早期的错误已经被后面每一步都打扮成了自信满满的文字。
- 解药是在每一道接缝上设一个人工检查点，而不是搭一条更精密的自动化流水线。在每一步的产出喂给下一步之前先读一遍，能拦住那种端到端通读一遍通常会漏掉的偏移。
- 不是每一步都该交给 AI。任务链里一个真正需要判断的决策，是留给你自己来做的候选项，这正是第七章那套淘汰标准背后的逻辑，只不过这次是一步一步地用，而不是用在整个任务上。

9.7 接下来

第十章会把从写一份真正的任务说明，到知道何时该停止串联，这一路讲过的一切，整合成一份实实在在的三十天计划：第一周该做什么，第二周该加上什么，到月底怎么判断这套系统是不是真的已经在你这里扎下了根。

第 10 章

三十天委派计划

Jamie 在一家有两名兽医的动物诊所负责前台工作。一月的一个星期一早上，她打开一份标题为“AI：第一周”的空白笔记，却不知道该怎么写。这本书里的每一个想法，她都曾在网上零零散散地读到过：提示词、工具、效率讨论串，但那些始终是零散的建议，从来不是一套她今天就能真正照着做的步骤，落到一件具体的任务上，而不是“多用 AI”这种空泛的决心。这份空白笔记正是几乎每个人都会走到的、老老实实的起点。本章要讲的，就是该往这份笔记里写什么。

下面这份计划为期四周，每次只处理一项任务，按照本书其余章节搭建起来的顺序推进：任务说明、试运行、检查、学习、修正、决定。这里没有任何新东西。它就是第二章到第九章讲过的同一套方法，只是从一堆想法变成了一份日程表，因为知道一种方法和真正把它跑起来之间的差距，几乎总是缺了那个“第一个星期一”。

10.1 第一周：一项任务，一份真正的任务说明

用第三章的四条标准挑出一项任务：小、重复、低风险、能在一分钟内检查完。对 Jamie 来说，这就是她每天用邮件发给客户的复诊后总结，每天十到十二份，形式大致固定，即使出错，代价也不会大到难以收拾。

写出第二章描述的那种真正的任务说明，五个要素一个不落：情境、限制条件、一个用你自己的语气写出的具体范例、“完成”的标准，以及它自己无法知道的信息。第一次这么写会花不少力气，比处理一项任务“应该”花的时间要长。这是意料之中的。这正是第二章提到的一次性成本，从这周之后的每一次使用中都能收回来。

用三到五个真实、各不相同的例子把这项任务跑一遍，这是第三章讲的试运行纪律。先别急着下判断。你现在是在收集证据，而不是凭第一次尝试就下结论。

10.2 第二周：真正地检查一遍，并建立清单

用第四章的方法抽查第一周的产出：找到错误真正扎堆出现的接缝，而不是这批任务的中段，把接缝那部分彻底检查一遍，其余部分轻轻抽样即可。对 **Jamie** 来说，接缝出现在养了多只宠物的家庭：总结有时会把一只猫的用药记到另一只猫头上。

按第五章的方法，动手建立真正的故障模式清单，哪怕现在只有一条也要写下来：具体哪里出错、多久出一次、在什么情况下出错。这周写下的一条真实记录，胜过一种“感觉还不错”的模糊印象，那种印象到第四周你早就记不清细节了。

故障模式清单里一条真实的记录，胜过一种“感觉还不错”的模糊印象，那种印象到第四周你早就记不清细节了。

10.3 第三周：让修正真正落地，并跑一遍淘汰标准

按照第六章的方法，把第二周发现的问题写成一条常设指令，而不是一次性的修正：一条工具此后每次都能照着执行的规则，保存在下次真的会被看到的地方，而不是只打在这周的某段对话里。**Jamie** 针对多宠物家庭的指令最终变成了一句话：“如果就诊记录里提到不止一只动物，用药必须按每只宠物的名字分开列出，绝不能合并。”

接着，老老实实在用第七章的四项淘汰标准检验这项任务：其中是否有一部分属于无规律可学的主观判断；它是否依赖工具不可能拥有的关系历史；单次出错的代价是否超过了所有成功加起来的价值；即便做了刚才那次修正，出错率是否依然顽固地降不下来。大多数选得好的低风险首选任务都能干净利落地通过这份清单。如果你的任务没能通过，那也是真实有用的信息，而不是白白浪费了三周，这正是第七章想说的：一次正确淘汰掉某项任务的试运行，同样是有价值的。

关键洞察

一项被广泛引用的研究追踪了参与者养成一项新的日常习惯的过程，发现该行为平均需要六十六天才能变得自动化，具体天数因人和习惯而异，跨度从十八天到二百五十四天不等。

Source: Lally, P., van Jaarsveld, C.H.M., Potts, H.W.W., & Wardle, J., "How are habits formed: Modelling habit formation in the real world," European Journal of Social Psychology, 40, 2010, pp. 998-1009 (论文标题:《习惯是如何形成的:对现实世界中习惯形成过程的建模)。

值得老实说清楚这对这份计划意味着什么。三十天能让你为一两项任务建立起一套真正能用的系统：任务说明写得妥当，检查到位，修正落实。但它无法让你走到委派完全不再需要有意识地投入注意力的那一步。平均来看，那个里程碑还在这份计划结束之后一个多月才会到来，对某些人、某些任务来说，还要更久。不要把第三十天时那套能用的系统，误认为是一套已经完成的系统。它是一个真实的成果，只是还不是最后的成果。

10.4 当第三周说“不”

并不是每一项首选任务都能通过考验，而这个结果值得近距离看一看，而不是当作一种假设情况，因为它是一种足够常见的结果，一开始就该有所预期，而不是哪里出了问题的信号。

Owen 是一名物业经理，他选择的第一项任务是租户维修请求的分诊：小、重复、看起来风险不高。第一周和第二周都很顺利：一份真正的任务说明，五次试运行，抽查发现了一个围绕涉水关键词的狭窄接缝，与第四章的例子颇为相似。第三周老实地跑淘汰标准检查时，冒出了一个他一开始没有认真掂量过的问题：一次分诊错误的紧急情况，一根爆裂的水管被归为普通事项，绝不只是之后收拾起来麻烦而已。这正是那种单次出错代价就能超过所有成功加起来的错误：可能造成数千美元的水损，还可能引发一起站得住脚的居住条件投诉，正对应第三项淘汰标准。

Owen 没有在第四周硬撑着一项已经给出明确答案的任务。他保留了分诊工作中真正低风险的部分，也就是一般维修请求，把所有涉及用水、用电或安全的事项永久地退回给人工首先过目，而不是当作临时的权宜之计。然后他把第四周用来给一项完全不同的任务开始新的试运行：起草入住欢迎手册，这项任务完全不存在同样的出错代价问题。他的第一个月产出了一项能用、尽管范围更窄的委派任务，以及一个证据充分、干脆利落的“不行”。这两者都是计划本该有的效果，只不过其中一个看起来更像终点线。

10.5 第四周：谨慎地增加任务，且只有在够格时才增加

只有到现在，等第一项任务真正稳定下来之后，才考虑增加第二项。先老实地用第八章的两条检验标准过一遍：第一项任务是否还在持续教你新东西；如果它的抽查在大多数星期都没通过，你是否真的会注意到。如果第二个问题的答案是“大概不会”，那你就真正赢得了增加另一项任务的空间。如果答案是“说不准”，那就再给第一项任务一周时间，先别急着增加任何东西。

为你现在正在运行的任务，建立第八章讲的那份单页名册。如果有任务确实涉及多个链式步骤：先调研、再起草、后排版，就像第九章描述的那样，一定要克制住把整条链一次性全部自动化的冲动。在给任何环节添加第二步之前，先在每个接缝处加上一个检查点。

10.6 你的三十天，一页纸看完

随着进展逐行填写，而不是今晚一口气填完。

周数	你在做什么	任务名称	结果
1	挑选一项任务， 写出真正的任务 说明，进行试运行		
2	抽查接缝，建立 故障模式清单		
3	保存常设指令， 跑一遍淘汰标准		
4	若够格则增加第 二项任务，若第 三周说“不”则为 新任务开始试运 行		

10.7 结束清单

到第三十天结束时，一项运行得当的首选任务，对以下每一条都应该能答“是”。如果答不出来，这并不代表这个月失败了。它是在明确告诉你该回头重做哪一周。

- 这项任务已经有一份真正的五要素任务说明，而不是每次都临时重新打一遍任务名称。
- 你已经进行过一次真正的试运行：用真实例子尝试三到五次，而不是靠一次侥幸的结果。
- 抽查发生在错误真正扎堆的接缝处，而不是从头读到尾的全篇检查，也不是完全不检查。
- 已经有一份具体的、写下来的故障模式清单，至少包含一条真实记录，而不只是一种模糊的印象。
- 至少有一项修正已经保存为常设指令，保存在工具下次真的会看到的地方。
- 已经老老实实在地用全部四项淘汰标准检验过这项任务，包括它可能没能通过其中一项的可能性。

10.8 本章不涉及的内容

本章不会承诺三十天能让你彻底学会委派这件事。本章引用的习惯研究已经说得很清楚：对大多数人、大多数任务来说，真正的自动化需要超过一个月的时间。在这之前的每一章，也都用各自的方式说过同样的话：随着工具变化，故障模式清单需要重新审视；随着工具“漂移”，常设指令需要更新；被“解雇”的任务终究值得再看一眼。这套方法里没有任何一部分是设定一次就一劳永逸的。它注定要被不断运行、检查、再运行，就像管理任何一位真正的员工一样，从来都不会真正“结束”。

本章也不会告诉你，同样这套三十天的顺序对每一项任务、每一个人都同样有效。**Jamie** 的复诊后总结之所以能很快稳定下来，是因为接缝很窄，风险也确实很低。一项更难的首选任务，可能要花上整整一个月才能走到第二周那份老老实实在的故障模式清单，而这并不代表方法失败了。这正是方法在做第三章早就提醒过的事情：真实的证据，要慢慢收集，而不是靠一个乐观的猜测快速凑出来。

要点总结

- 第一周：挑选一项小、低风险的任务，写出一份真正的五要素任务说明。在下任何判断之前，先进行一次真正的试运行。
- 第二周：抽查错误真正扎堆的接缝，并建立一份具体的、写下来的故障模式清单。
- 第三周：把你的修正变成一条保存下来的常设指令，然后老老实实地用全部四项淘汰标准检验这项任务。
- 第四周：只有在第一项任务真正够格之后，才增加第二项任务；如果现在同时跟进不止一项任务，就建立一份简单的名册。
- 三十天能建立起一套真正能用的系统，但它无法完成整件事。真正的自动化平均需要更长时间，这套方法注定要持续运行下去，而不是设定一次就撒手不管。

10.9 接下来

至此，核心方法就完整了：任务说明、试运行、检查、学习、修正、决定，按照前十章搭建起来的顺序一一走过。本书接下来的部分，会把同一套方法带到更多真实的场景中去检验。第十一章会把四项委派任务从头到尾完整地走一遍，用一个连续的故事讲完，而不是一次只讲一项技能。再往后的几章会把视野进一步打开：如何选择工具、如何教会团队负责任地委派、这套方法通常会招来哪些站得住脚的质疑，以及从金钱到多种形态的工具，再到本书中每一条主张背后完整的信源记录，这些前十章没有篇幅细讲、值得单独深入的任务类型。

第 11 章

四个完整的委派案例

到目前为止，前面每一章都只展示一项技能：一份任务说明、一次试运行、一次抽查、一次修正。但真正的委派并不会像这样，以整齐分开的形式出现。它是与某项任务之间一段持续不断的关系，各项技能在其中相互交叠、彼此叠加，有时甚至会在同一个月里相互矛盾。本章完整讲述四个这样的案例，从头到尾，来自四家截然不同的小企业，好让整套方法作为一个整体被看见运作，而不是逐条案例孤立地展示。

关键洞察

研究人员追踪了数百万家小企业的交易数据，发现 2019 年至 2025 年间，付费 AI 的采用率大幅上升：男性所有的企业中，采用率从约 2% 升至约 19.7%；同一时期，女性所有的企业中，采用率从约 1.7% 升至约 17.2%。雇有员工的企业，采用率也明显高于没有雇员的企业，到 2025 年底达到 26.1% 对 15.3%，且这一差距自 2023 年以来不但没有缩小，反而进一步拉大。

Source: Wheat, C., Mac, C., & Passalacqua, A., “Understanding the Use of AI Among Small Businesses,” JPMorganChase Institute, May 2026. (论文标题:《小企业中的 AI 使用情况研究》)。

在阅读下面四个案例之前，值得先消化一下这些数字：即使到了 2025 年底，仍有大约五分之四的小企业完全没有采用任何付费 AI 工具，而已经采用的那些企业中，大多数也才刚刚开始弄清楚“采用”除了订阅一项服务之外究竟意味着什么。本章中的这四家企业，没有一家格外老练或先进。他们所做的事情要具体得多，也更容易被任何一位读者复制：把第二章到第九章的方法，耐心地、一次一项任务地，应用到自己真实的工作中。

11.1 案例一：一位婚礼摄影师的四个月

Bianca 独自拍摄婚礼，一年四十到五十场，而每一场婚礼周边的文书工作，不知不觉间已经变成了她的第二份工作。她按照第三章的标准，挑选了自己第一项要委派的任务：回复通过网络找到她的新人发来的咨询邮件。这类邮件一周只有几封，风险很低，一眼就能核实，正是那种即便第一次尝试不理想也不会有任何代价的任务。

第一个月，任务说明。她第一次尝试只写了四个字，“回复这条咨询”，得到的回复写得很漂亮，但十分笼统，既没提到她实际提供的具体套餐，也没提到她一个周末只接一场婚礼这件事。于是她按照第二章的五要素，把它改写成一份真正的任务说明：情境（一对新人在询问档期和价格）；限制条件（在不清楚场地之前绝不报出确定价格，并且始终要提到“一个周末只接一场”的政策）；一个她自己发出过、并促成了预订的真实范例；“完成”的标准（不超过 150 字，并给出清晰的下一步）；以及它自己无法知道的信息（她实际可用的空档日期，每次都要由她自己粘贴进去）。这份改写后的任务说明，每次只替换那一个变量，反复使用，写出的回复已经足够接近她本人的语气，以至于新人们不再追问“这是不是模板回复”。

第二个月，试运行与抽查。按照第三章的纪律，她先用八条真实咨询做了试运行，才开始信任它，并在第六次尝试中发现了接缝：有一对新人询问了一项具体的附加服务（第二名摄影师），得到的回复回答了大致的价格问题，却悄悄漏掉了那项附加服务。第四章的方法在这里被直接套用：她并不逐字重读此后的每一封回复，而是专门核查原始咨询中的每一个问题是否都得到了实际回答，这就是那道狭窄的接缝，其余部分只是略读一遍。

第三个月，修正与第一次“解雇”。附加服务这道接缝，按照第六章的规则，变成了一条一句话的常设指令：“发送之前，列出新人实际提出的每一个问题，并确认每一个都得到了回答。”这条指令在一周之内就把接缝补上了。而第二项任务，回复已预订新人提出的改期请求，情况就远没有这么顺利。四月发生的一次接近取消的改期，最终取决于某对新人的合同是否允许免除费用，这是一个关于特定关系与特定情况的判断，任何任务说明都无法提前替她做决定。Bianca 老老实实地用第七章的四项淘汰标准对它进行了检验，干脆利落地“解雇”了这项任务：从此以后，所有改期请求都先交到她本人手上，完全不再由 AI 起草，而咨询回复则继续照原样运行。

第四个月，扩展与任务链。随着咨询回复趋于稳定，她按照第八章名册纪律的实际做法，新增了第二项任务：相册交付邮件，在新人的成片准备好后发送。这项任务自然而然地形成了一条短任务链：从她的预订系统中提取新人姓名和婚礼日期，起草交付通知，再起草一封单独的、两周后发送的证言请求，属于第九章的范畴。她把它保持在两步，中间设一个检查点，而不是让它一路自动跑完，整套安排，两项任务、一页名册、一项明确标注为“已解雇”的任务，每周只花她大约九十分钟，而不是过去同样的工作要占用的六七个小时。

到第四个月结束时，Bianca 的名册上有三行，而不是她最初希望委派的四项任务：咨询回复（稳定，轻度核查）、相册交付任务链（两步，在接缝处核查）、以及改期请求（已解雇，回归完全人工）。第三行和前两行同样重要。要是没有这套方法，“AI 搞不定这个”本来会是关于改期这件事的全部结论，就是第一章开篇提到的那种自动售货机式思维。有了这套方法，结论就变得具体了：这项任务中恰好这一部分，依赖的是 AI 在结构上根本不可能具备的判断力，而其余部分照常运行。

真正的委派不会以整齐分开的技能形式出现。它是与某项任务之间一段持续不断的关系，任务说明、试运行、修正与解雇，都可能发生在同一个忙碌的月份里。

11.2 案例二：一位汽配经销商更为坎坷的历程

Hector 经营着一家独立的小型汽车配件经销企业，有六名员工，他走过同一套方法的路径看起来要混乱得多，这一点值得如实展示，而不是刻意抹平。并不是每一次委派都能像 Bianca 那样干净利落。

第一周和第二周，一份需要改两次的任务说明。他的第一项任务是给供应商发催单邮件，追讨逾期未到的零件订单。他的第一份任务说明在纸面上很周全，五要素俱全，却漏掉了一件事：对合作了十年的供应商，和对一个关系还在建立中的新供应商，该用什么样的语气。第一批试运行的邮件全都是彬彬有礼却态度强硬的风格，这在他合作多年的老供应商看来显得莫名冷淡，还招来一通困惑的电话询问。他给任务说明加了第六条非正式的补充，这不属于第二章正式的五要素之一，而是这项任务确实需要的真实补充：哪些供应商该用更温和的措辞，以及原因。下一批邮件就写对了。

第三周和第四周，一个真正“解雇”了什么的淘汰标准。他的第二项任务，是标记库存低于再订货点的商品，纸面上看起来是最安全的一类任务：规模小、经常性、容易核查。结果差点就不是了。AI 起草的再订货提醒，对每一个从他表格某一列里提取出来的 SKU，都用了同一个再订货点数字，却忽略了其中三种特定零件每年春天都会出现季节性需求高峰，这使得它们真正的再订货点大约是备案静态数字的两倍。一条本该在二月触发的提醒没有触发，Hector 差一点点，只差一周，就把一种每年三月都畅销的零件卖断了货。第七章的第三项淘汰标准，单次失误的代价超过所有成功加总，在这里完全适用：他把那三种有季节性的 SKU 彻底移出了自动标记，改为每月人工复核，其余的再订货标记则照常运行，而且现在是真正可靠，而不只是看起来可靠。

第二个月，名册在问题变成问题之前先抓住了它。当时有两项任务在运行，第三项，客户报价请求，正在考虑之中。**Hector** 的名册，也就是第八章养成的习惯，在问题变得昂贵之前先标出了一件事：他哪项再订货标记任务的常设指令，自季节性 SKU 那次修正之后就再也没被碰过，已经三个月了。他重新检查了一遍，确认那次修正依然有效，这之后才开始对报价请求做试运行，而不是在两项他其实还没确认仍然稳定的任务之上，又直接叠加第三项。

第三个月，一条被严格核查的短任务链。客户报价最终被拆成了一条两步的任务链：先提取该零件当前的成本和加价幅度，再起草实际的报价邮件。考虑到他此前差点就出现真正的库存问题，**Hector** 把第一步得出的数字，拿去对照他实际的价格表，整整核查了一个月，才放心让第二步在此基础上运行，这比第九章通常的检查点纪律要长得多，但考虑到他从第二项任务里学到的、这门特定生意失误代价的实际情况，这是一个合理的、以证据为依据的判断。

三个月过去，**Hector** 有一项任务几乎可以放手运行（供应商催单邮件，含语气补充说明），一项任务带有针对三种特定 SKU 的永久性人工例外，还有一项仍处在比平常更长的检查点周期中，随着数字持续核查无误，他正在逐步放宽这个周期。这读起来完全不像一个前后对比式的凯旋故事，本来也无意如此。它读起来更像是一位小企业主，差一周就出现真正的断货，随后作出调整，继续前行，而这比一个“一切第一次就成功”的故事，更真实地展现了这套方法在实践中的样子。

11.3 案例三：一位保险代理人的静默成功

Wren 经营着一家独立的小型财产与意外险代理机构，她走这套方法的过程之所以值得收录，恰恰是因为它是四个案例中最不戏剧化的一个。这里没有任何事情差点出岔子。而这正是重点：大多数谨慎的初次委派看起来都是这样，而不是像 **Hector** 那样险些出事，一本只展示惊险救场故事的书，会给读者一个关于实际预期的错误印象。

第一周到第三周，一份普通的任务说明与一次普通的试运行。**Wren** 的第一项任务，是在保单到期前六十天发送的续保提醒信，规模小、经常性、容易核查，是第三章的教科书式素材。她的任务说明，第二章的五要素第一次就写得很仔细，在全部五次试运行中都得出了干净的结果，除了一个她在任务说明本身就已经修正的小小排版偏好之外，没有任何值得一提的接缝，而且那个偏好在酿成真正的问题之前就已经解决了。

第二个月，第二项任务与一次诚实的淘汰标准核查。她新增了一项任务：保单对比摘要，用通俗语言向客户解释续保后的保单与去年相比有何不同。在扩大规模之前，她先用第七章的清单对这项任务做了核查，即使当时还没有出任何差错，她也发现了一件值得一提的事：任何涉及保障缺口的对比，也就是客户对某项此前有保障、如今却不再有保障的内容，都是一个关于如何传达这个

消息的判断问题，而不是一项起草任务。她提前把这项任务拆分开来，在坏结果逼她这么做之前就主动拆分：常规对比继续委派，涉及保障缺口的对比则从第一天起就直接交给她本人处理，而不是等一次失误教会她之后才拆分。

第三个月，一份小小的、被安静维护的名册。两项任务，都很稳定，都按照第四章所述的轻度节奏核查，也就是一份真正的故障模式清单收尾之后所适用的那种节奏。**Wren** 名册上这两项任务的条目，自第二个月以来只需要更新过一次，而这正是这套方法在实践中最真实、最普通的样子：不是一个惊险救命的故事，而是一种安静、称职的习惯，大多数时候就只是持续地运转着。

11.4 案例四：一位特色食品生产商更缓慢的起步

Cleo 经营着一家小批量辣酱公司，以批发方式供货给本地区大约四十家门店，在四个案例中，她的故事是这套方法花了最长时间才显出成效的一个，也正因为如此才值得收录。

第一个月，一份需要大改的任务说明。她的第一项任务，批发订单确认邮件，看起来很简单，但她实际的限制条件清单却出乎意料地长：不同门店有不同的最低起订箱数，不同的常年折扣，还有一个长期合作的客户，用的是三年前定下、从未被正式修改过的旧价格。她的第一份任务说明完全遗漏了这个旧价格问题，而这个工具，正如第一章所预言的那样，自信地用她当前的标准价格填补了这个空缺，套用到了一笔本该使用旧费率的订单上，这是一个真实存在、虽然尚可承受的开票错误，她之所以发现，只是因为那家门店的老板打电话来询问。

第二个月，一份顽固地居高不下的故障模式清单。即使修好了旧价格这个漏洞，**Cleo** 的故障模式清单仍然不断增长，超过了第五章标记为警示信号的三四条：价格例外、箱数例外、配送时间表例外，这是三个截然不同的问题群，却顶着同一个任务的名字。她没有去写一条越来越长的常设指令，而是照第五章在清单无法保持简短时真正建议的做法去做：拆分任务。标准订单，占绝大多数，继续通过一份简单的任务说明运行。少数几个有真正例外情况的客户，则被移到一份简短的、明确标注的名单上，始终直接交由她本人处理。

第三个月，稳定下来，比 Bianca 或 Hector 都要晚。一旦拆分完成，任务的两个部分都在两周之内稳定了下来。**Cleo** 对自己这三个月的诚实解读是：这份延迟不是方法失败了，而是方法正确地拒绝掩盖一个实际上是两项任务的问题，正如第五章对冗长故障模式清单的警示所说的那样，直到她愿意用这个角度去看待它，而不是在一条已经很长的常设指令上再加一行。

11.5 四条路径，并排对照

	Bianca（摄影）	Hector（汽配）	Wren（保险）	Cleo（辣酱）
第一项任务	咨询邮件回复	供应商催单邮件	续保提醒信	批发订单确认
任务说明是否需要二次修改？	否，第一次改写后就定稿	是，补充了语气说明	否，第一次尝试就很干净	是，遗漏了一项旧价格例外
值得关注的事件	“解雇”了一项判断型任务	险些断货，及时发现	在出现任何失误前就拆分了任务	一次真实的定价错误，被客户来电发现
是什么发现了问题	第七章的淘汰标准	一次险情	主动的淘汰标准核查	一份顽固地偏长的故障模式清单
达到稳定所用时间	约四个月	约三个月	约两个月	约三个月，经过必要的拆分之后

每一次的具体形态都不一样。但支撑它的那套纪律始终如一。四个人最终得到的，都是一套更小、以证据为依据的任务集合，而不是他们最初满怀期待时那个更大的任务集合，而在每一个案例中，这种收缩，或者说这种延迟，正是这套方法应当产生的结果，而不是它的不足。

11.6 这四个故事真正说明了什么

这四家企业没有一家是第一次尝试就把方法运用得完美无缺，而这正是把它们放在一起看时最值得吸取的一点。**Bianca** 的咨询回复任务，运行得很接近前面几章在抽象层面描述的样子；她的改期任务却不然，而正确地“解雇”它，与那项成功的任务一样，同样是这套方法在起作用。**Hector** 的故事补充了一次险情，以及一份名册在第二个问题出现之前，先抓住了一条过时的修正。**Wren** 的故事补充了最安静、最不戏剧化的一个版本：一次主动进行的淘汰标准核查，没有抓到任何戏剧性的东西，恰恰是因为它及早抓住了正确的那件事。**Cleo** 的

故事补充了耐心：一项花了最长时间才稳定下来的任务，恰恰是因为她让一份冗长的故障模式清单告诉她真相，也就是那一项任务其实是两项任务，而不是强迫用一条常设指令去覆盖两者。这四家企业各自的这段时期结束时，得到的都是一套比他们起初期望的更小、也更诚实的委派任务集合，而且按照上文提到的研究，在那大约五分之四完全没有开始这一进程的小企业面前，这四家企业都实实在在地领先了一大截。

要点总结

- 第二章到第九章的这些技能，在实际使用中并不会按整齐的顺序依次展开。一份任务说明正在被修改的同时，另一项任务可能已经在被“解雇”。一份名册可能在第三项任务还在试运行时，就抓住了一条过时的修正。
- 一项任务在进行到一半时未能通过淘汰清单，这并不是偏离了方法。这正是方法本身，在一项确实需要人来处理的任务上，按预期发挥作用。
- 像 Hector 的季节性再订货点漏洞这样的一次险情，往往是抽查或淘汰标准核查确实在起作用的最清晰证据，而不是系统失灵的信号。
- 最终拥有更少、但每一项都真正可靠的委派任务，胜过拥有更多、却建立在未经检验的信任之上的任务。

11.7 接下来

第十二章将转向一个始终潜藏在这四个故事之下的问题：究竟是什么，把一个真正值得托付这一切的工具，和一个不值得托付的工具区分开来，以及该如何在第一项真实任务被写成任务说明之前，就诚实地评估这一点。

第 12 章

选择你的第一个工具

Naomi 经营着一家小型辅导公司，她曾用一个周六下午打开了十一个浏览器标签页，每一个都是“2026 年小企业最佳 AI 工具”之类的榜单文章，每一篇推荐的东西都略有不同，其中大多数显然出自从未经营过博客以外任何生意的人之手。三个小时过去，她记住了十几个产品名称，却对哪一款真正适合她打开笔记本电脑想要解决的任务：每周为四十名学生撰写个性化的学习进度记录，一无所获。她合上笔记本电脑，什么都没选，而这比选错还要糟糕，因为哪怕一个不完美的初次选择，也能产生第三章“试运行”所需要用到的真实证据。

本章不会给你一份工具排行榜。任何这样的榜单都会在一年内过时，往往用不到一个季度，这正是本书前九章一直努力避免陷入的陷阱。本章要给你的，是在你亲自做选择时真正重要的东西：五个不会因产品改名或公司新增功能而过期的问题，以及一种比 Naomi 那个周六花费更少时间、就能自己回答这些问题的方法。

关键洞察

一项 2025 年针对北美和欧洲逾 1000 家企业的调查发现，42% 的企业在其大多数 AI 项目投入生产之前就已放弃，较上一年的 17% 大幅上升，被提及最多的原因是最初的适配性差、价值不明确，以及低估了持续成本。

Source: S&P Global Market Intelligence, “2025 Enterprise AI Survey (Voice of the Enterprise),” 2025. (报告标题：《2025 年企业 AI 调查（企业之声）》)

这个数字描述的是拥有专项预算和技术人员的大公司，而不是像 Naomi 这样的独立经营者，诚实的解读并不是“那小企业岂不是更难”，而是即便是资源远比小企业充足、本该有能力妥善评估一款工具的组织，也常常跳过这道评估，

之后再为此付出代价。事先做一点有条理的判断，也就是本章接下来要讲的内容，是防止自己也成为这个数字之一的廉价保险。

12.1 五个不会过时的问题

它是否真的记得你告诉过它的事？第六章的整个论点都依赖于一款工具支持某种真实的、持久性的常设指令，不论到你读到这里时它被称作自定义指令、已保存的系统提示词、项目级设置，还是别的什么名字。在把真实的、反复出现的工作托付给任何工具之前，直接测试这一点：给它一个纠正，开启一段全新的对话，检查这个纠正是否保留了下来。一款默认会遗忘的工具并不因此被淘汰，但这意味着除非你每次都重新粘贴同样的背景信息，否则每个会话都要从零开始，这是一项在你做出承诺之前、而不是之后，就该弄清楚的真实成本。

按你实际会用到的量来算，它到底要花多少钱？几乎每一款 AI 工具的免费版或入门版定价，都是为了留下良好的第一印象，而不是反映一项任务从演示时用两次变成每天都要用之后，企业实际要付出的成本。在做出选择之前，估算你真实的月使用量：对 Naomi 来说，每周四十份进度记录大约相当于每月 170 份，然后按照这个具体的量给工具定价，而不是看落地页主打价格卡上的那个数字。

你输入进去的数据会有什么遭遇？这一点对某些任务的重要性远高于其他任务。一款根据你本就拥有的数据来起草内部笔记的工具，和一款会接触到真实客户姓名、健康信息或财务细节的工具，风险完全不同。在处理任何你不希望被用来训练一个你无法控制的模型、或被分享到你意料之外的地方的信息之前，请阅读你实际要付费使用的那个套餐真正的数据处理条款，而不是营销页面上的说法。

它会有所保留，还是会瞎猜？第一章关于语言模型为何会产生幻觉的研究发现，这种行为源于模型的训练和评分方式，而不是一个可以打补丁修复的漏洞。不同的工具，乃至同一款工具的不同设置，在多大程度上会标示出真正的不确定性、还是不管三七二十一都自信作答，表现各不相同。这一点也请直接测试：问它一个只跟你的业务有关、它不可能知道的具体问题，看它是坦承不知道，还是编出一个听起来言之凿凿的答案。一款对自己不知道的事情坦诚相告的工具，比一款从不承认这一点的工具更容易安全地管理，哪怕后者在演示时看起来更令人印象深刻。

它能融入你实际的工作方式，还是会变成工作又一处不了了之的角落？一款要求你离开现有日历、收件箱或记录系统、手动把内容来回复制的工具，会悄悄多出一道工序，而这道工序往往撑不过第一个忙碌的星期就没人再做了。对一项真正会反复出现的任务而言，最好的工具通常是最贴近这项任务原本所在之处的那一个，而不是功能最多、但你永远不会点开的那一个。

一款对自己不知道的事情坦诚相告的工具，比一款从不承认这一点的工具更容易安全地管理，哪怕后者在演示时看起来更令人印象深刻。

12.2 Naomi 的实际评估

Naomi 回到了那十一个标签页，但这次带着的是这五个问题，而不是那些排行榜。她收藏的两款工具在记忆测试中直接败下阵来：处理一次性笔记还算有用，但每个会话都要重新开始，对她要每天使用的任务而言，这是一项真实的成本。第三款通过了记忆测试，但当她按真实数据认真算过、而不是凭直觉扫一眼落地页之后，发现它的可用套餐定价远高于每周四十份记录所能证明其合理性的水平。她最终选择的，是她最初根据评价热度只排到第四位的那款工具，因为它是真正记得她纠正内容的那一个，按她的真实使用量算价格合理，而且当她拿一个关于某个特定学生历史、它不可能知道的问题去测试它时，它直截了当地承认了这一点，而不是编造一个听起来可信的猜测。这一切花的时间并不比原来那个周六下午更长，只是换成了另一个周六下午，花在五个具体问题上，而不是花在十一个别人意见的标签页上。

12.3 当没有一款工具能干净利落地通过所有测试

现实中很少有真正的候选工具能毫无保留地通过全部五个问题，值得说清楚的是，一个保留意见并不会自动让工具出局：第七章的淘汰逻辑针对的是任务，而不是工具，但背后的判断方式是相通的。要把这个保留意见放到具体任务面前去权衡，而不是拿去对照一个抽象的完美标准。一款记忆支持一般的工具，对于一个月只用几次的任务来说，可能仍是正确的选择，因为每次重新打一点背景信息的代价很小。同样薄弱的记忆支持，对于一项每天都要用的任务却会造成淘汰，因为那份重新输入的成本会日复一日地累积成真正被浪费掉的时间。这五个问题不是一道及格线。它们是你拿来对照眼前这项具体任务去权衡的东西，就像第三章的四项标准也是针对具体任务去权衡，而不是当作一个抽象理想去套用一样。

12.4 本章不涉及的内容

本章不会告诉你眼下哪款工具最好，这是故意的。对这个问题的任何回答，都只是对一个每隔几个月就要重新洗牌的市场拍下的一张快照：新玩家进场、定价调整、功能忽然出现又忽然消失，而这恰恰是本书从第一章起就一直刻意不去依附的那种变动。上面这五个问题之所以能经受住这种变动，正是因为它们问的是一项任务真正需要什么，而不是哪个品牌眼下功能最多。

它也不会告诉你，你选的第一款工具就必须是最后一款。第三章“试运行”的纪律在这里同样适用：如果一款工具在纸面上通过了这五个问题、却在真实试运行中表现糟糕，那是有价值的证据，不是白白浪费的一次评估，而且在一次真正的试运行之后换掉它，代价远小于用了几个月都没认真检验之后再换掉它。

12.5 试一试：给你的候选工具打分

在打开任何一个测评网站之前，先列出你实际在考虑的两三款工具，然后针对每一款，根据你自己的测试、而不是某篇榜单文章的总结，直接回答这五个问题。

问题	候选工具 1	候选工具 2	候选工具 3
能在跨会话情况下记住一次纠正吗？			
按你实际的月使用量算，真实成本是多少			
数据处理方式是否适合这项任务？			
不知道的时候会诚实地有所保留吗？			
是否贴合工作原本所在之处？			

不管哪款候选工具在这张表上留下的真实问题最少，而不是在测评网站上星级最高，就是值得拿去做第三章那个真正试运行的那一个。

要点总结

- 工具排行榜用不到一个季度就会过时。而关于一项任务真正需要什么五个持久问题不会：它是否记得纠正、按真实使用量算要花多少钱、你的数据会有什么遭遇、它是否诚实地有所保留，以及它是否贴合工作原本所在之处。
- 在把任何反复出现的工作托付给一款工具之前，直接测试记忆这一点：给它一个纠正，开启一段新对话，看它是否保留了下来。
- 在做出任何承诺之前，按你实际的月使用量定价，而不是看落地页上的那个数字。
- 事先谨慎选择是一种廉价的保险。有相当大比例、且有据可查的组织，在没有妥善评估 AI 工具的情况下就把真实工作交给了它，最终为此付出代价。

12.6 接下来

第十三章将这套方法延伸到一个人为自己委派工作之外的场景：当你要教别人，比如一名员工或直接下属，用负责任的方式做同样的事情时，情况会有什么变化。

第 13 章

当你的团队也开始委派

Wanda 经营着一家六人规模的营销代理公司，一年来她一直亲自践行本书方法的每一步，用在自己委派出去的任务上，纪律严明。真正的意外来自一个她从未预料到的方向。一位初级客户协调员把 AI 起草的竞争分析发给了客户，而该协调员自己并没有真正核实过内容，报告里还煞有介事地引用了一家竞争对手六个月前就已经变更的定价结构。发现问题的不是协调员本人，而是客户，对方合情合理地问道：代理公司在把报告发出去之前，究竟有没有看过一眼。

Wanda 花了一年时间学会认真管理自己委派出去的工作。她却没花过一个小时去想：如果做委派的人不是她自己，会发生什么。本章要讲的正是这个缺口，而不是此前哪一环节出了差错：第二章到第九章的全部内容都假定只有一个人，既写任务说明，也做自己的核查。而一旦有第二个人进入这个循环，就会出现一种新的故障模式，那些章节本身都没有被设计来单独识别它。

13.1 只有团队才会出现的故障模式

当你把任务委派给 AI 并亲自核查结果时，信任只有一个地方可能断裂：工具和你之间。而当员工把任务委派给 AI、由你依赖她的核查而不是自己动手时，信任就有两个地方可能断裂，而且第二个地方在默认情况下你根本看不见。工具本身可能出错。与此同时，你的员工对工具产出的核查，也可能根本没做、做得仓促，或者完全没有运用本书一直在培养的那种技能。

关键洞察

2026 年一项针对美国、英国和澳大利亚 6,000 名全职数字工作者的调查发现，在使用 AI 的员工中，近七成承认曾提交过自己其实没有真正审阅过、没有完全理解、或者被问起时也无法自信地为其辩护的 AI 生成成果，研究者将这种行为称为“胡诌式提交”（botshitting）。

Source: Glean Work AI Institute, “The Work AI Index 2026,” survey conducted December 2025-January 2026. (报告标题:《2026 年工作 AI 指数》, 调查于 2025 年 12 月至 2026 年 1 月进行)。

这项统计数据，恰好就是 Wanda 的协调员身上发生的事，也有必要说清楚它不能说明什么：它不能证明更年轻或经验更浅的员工就更粗心大意。它能证明的是，第四章讲的那种核查纪律，也就是找到真正的接缝并狠狠核查它，是一项具体的、可以学会的技能，不是谁生来就会的，这正是第一章在谈到把任务委派给 AI 时提出的同一个道理。一名从未被教过如何抽查的员工，跳过这一步并不是因为懒惰。他们只是在做那件从来没有人告诉过他们不该做的事。

13.2 教方法，而不只是教工具

一旦你注意到这个缺口，本能反应是制定一条政策：“发给客户之前先核实 AI 产出。”Wanda 最初就是这么做的，但这条政策没能站住脚，原因你现在应该已经很熟悉了：“核实一下”是一个任务名称，不是任务说明，正是第二章开篇提出的那个区分。一条指令，如果没有说清楚核实到底意味着什么、该查哪个接缝、应该花多长时间、“查过了”作为一个完成状态究竟长什么样，那么它带给员工的可操作性，并不比第二章开篇那个例子里“回复这位生气的客户”带给 AI 的可操作性更多。

真正对 Wanda 的团队管用的，是把本书教的那些具体技能原封不动地教给团队，只是缩放成适合团队规模的版本：

每种重复性任务配一份共享的任务说明模板。 Wanda 没有让团队里每个人都为竞争分析这类任务临时拼凑自己的任务说明，而是按照第二章的结构，把完整的五要素任务说明做过一次，把它作为团队的起点。这样一来，没有人需要在交稿期限的压力下重新摸索一份完整任务说明该是什么样子。

每项任务指定一个具体的接缝，而不是笼统提醒“再检查一遍”。就竞争分析这项任务而言，已知的接缝是关于特定竞争对手的定价和市场定位的说法，恰恰是这类会过时、又容易被信心十足地说错的细节。团队的标准现在把这个接缝明确写了下来：发送之前，每一条关于竞争对手的说法都要对照一份三十天以内的信息来源核实一遍。这就是第四章讲的抽查，只是把它从一个人脑子里，写进了团队层面的标准。

建立一种共识：告知不等于承认失败。关于员工为什么隐瞒自己使用 AI 的研究发现，原因很少是为了欺骗本身，而是害怕一旦承认用过工具，就会被认为能力不足，或者被派更多的活。Wanda 做了一个不大但刻意的改变：团队例会现在通常会加一句话，说明哪些任务是以 AI 草稿为起点的，说法就像有人提到自己用了模板一样，而不是一种忏悔。让告知变得稀松平常，而不是需要藏起来的事，才能真正在客户发现问题之前，先让一次不牢靠的核查浮出水面。

一名从未被教过如何抽查的员工，跳过这一步并不是因为懒惰。
他们只是在做那件从来没有人告诉过他们不该做的事。

13.3 三个月后，这套规范真正拦住了什么

对 Wanda 的改变真正的检验，出现在她推行这套做法三个月之后，而且是在一项完全不同的任务上：一位资深文案在为客户的新品发布撰写广告文案的不同版本。这位文案每月的一句话告知，“标题的几个变体用了 AI 初稿，已经对照品牌指南查过”，语气很寻常，正是 Wanda 一直想建立的那种平常语气。真正起作用的不是告知本身，而是把这句话说出口、在一个房间里当众说出来，引出了一位同事的追问：“你有没有把第三个版本里的说法，对照实际的产品规格核实过，而不只是品牌语调？”这位文案没有核实过，因为团队为这类任务指定的接缝覆盖的是语调和品牌声音，不是产品事实层面的说法，这是标准本身的漏洞，而不是任何人不够尽责。他们在一个确实有误的产能数字送到客户手上之前把它拦了下来，不是因为有人在直接盯着这位文案的工作，而是因为把 AI 草拟的部分说出口这一习惯，给了另一个人一个自然的机会，去问出那个真正要紧的问题。

这正是第四章“未曾预料到的模式”在团队层面的翻版：一种轻量、平常的做法，而不是一次沉重的审查，让还没有人命名过的接缝浮出水面，恰恰是第四章那种对一批任务其余部分做轻量扫描所要提供的价值，只不过这一次，它是通过团队日常的对话流转，而不是靠一个人的清单来实现的。

13.4 你版本的第四章，升高一个层级

一旦团队开始自己写任务说明、自己做抽查，你的工作就从核查具体产出，变成偶尔核查“核查本身”：对抽查再做一次抽查，这就是第四章那套逻辑，套用在更高的一个层级上。你不需要审阅团队产出的每一份客户交付物，那样做

会让委派给人这件事失去意义，就像逐条阅读 AI 的每一份输出，会让委派给工具这件事失去意义一样。你需要的是定期核实，那个被指定的接缝是否真的有人在查，而不只是存在一条说它应该被查的政策。

对 Wanda 来说，这意味着每月花五分钟，抽出每位团队成员最近的两到三份交付物，只看团队标准里指定的那个接缝，也就是竞争对手的定价说法，别的一概不看。这和第四章为单一任务教的那套纪律是同一回事，只是这次瞄准的是一个人的工作流程，而不是一份文档的内容，它占用她一周时间的程度，和最初的抽查在单一任务里占用的时间几乎一样少。

13.5 本章不涉及的内容

本章不会告诉你，每位员工永远都需要同等程度的监督。第一章那套建立信任的逻辑，先试运行，再看业绩记录，适用于一个人学习这项技能，就像它适用于一个工具一样。一名在数月里持续展现出真正可靠核查习惯的团队成员，理应获得更轻的监督，就像一项故障模式清单已经封闭的任务，理应获得更轻的抽查一样。

本章同样不会告诉你，一条团队规范能比第七章的淘汰标准更好地解决真正需要判断力的任务。有些面向客户的工作，无论团队整体的 AI 实践运转得多好，仍然应该留给你最有经验的那个人来做。建立一套好的团队标准，替代不了第七章要求单一任务做的那种诚实的淘汰式思考，只是这一次，这种思考的对象从“这项任务该不该交给 AI”，变成了“团队里该由谁来处理哪类工作”。

13.6 试一试：搭建一条团队标准

从你的团队已经在处理的 AI 辅助任务里，挑出一项经常重复出现的。尽量以团队的方式而不是一个人闭门写下：

- 这项任务的共享任务说明，按第二章的五要素，一次性商定好，而不是由这周正赶工期的人临场发挥。
- 一个最容易被漏掉的具体接缝，具体到“查过了”这件事有一个真正明确的定义。
- 一句用大白话说清楚该如何把告知说出口的话，要足够日常，说出来不会让人觉得像是在忏悔。

一个月后回头再看一遍，用第六章对待常设指令的方式对待它：不是写一次就搁在一边，而是随着真实接缝的变化不断更新。

要点总结

- 通过团队来委派，会多出第二个信任可能断裂的地方：不只是 AI 的产出对不对，还有员工对它的核查是不是真的做了，做得是不是有效。
- “核实 AI 产出”是一个任务名称，不是任务说明。要在团队规模上，教授本书教的那些具体技能：一份共享的任务说明模板，每项任务一个具体的接缝，以及“查过了”这件事的真正定义。
- 让告知变得稀松平常，而不是承认失败。员工隐瞒使用 AI，主要是出于对被评判的恐惧，而一条把提及 AI 使用当作日常的团队规范，比一条把它当作需要忏悔之事的政策，更早地让问题浮出水面。
- 你的角色从核查具体产出，变成定期核查核查本身：对团队的流程做小规模、常态化的抽查，而不是审阅他们产出的一切。

13.7 接下来

第十四章汇总了这套方法通常会遇到的那些坦率的质疑，从“我没时间写五要素任务说明”到“受监管的工作该怎么办”，并一一正面作答，而不是假装这套方法毫无真实的摩擦点。

第 14 章

常见质疑与边界情况

本书中的每一个观点，都有一个真实、诚恳的质疑紧随其后：那种精明、审慎的同事会在喝咖啡时当面提出的质疑，而不是一戳就破的稻草人靶子。本章收集了其中最常出现的那些，并逐一正面作答，包括那些诚实的答案必须真正让步、而不是绕着走的情况。

14.1 “我没时间为每件小事都写一份五要素任务说明。”

你说得对，第二章已经明确说过这一点：真正只做一次的任务，不值得你做全套投入，先粗略试一次、再快速修正，往往才是更好的选择。五要素任务说明真正划算的地方，是在反复出现的任务上：前期成本只付一次，之后每一次重复的成本都接近于零。如果你发现自己在为一件真的以后再也不会做的事写完整的任务说明，那不是这套方法失效了，而是它被用在了一个它本就不该被用的地方。

14.2 “工具一夜之间就变了，我的故障模式清单已经不适用了。”

这种情况会不断发生，第五章和第六章都直白地说过：故障模式清单只在你最近几次检查的范围内有效，并非一劳永逸，模型更新完全可能在毫无预警的情况下改变工具的行为。解决办法不是写一份更好的清单，而是养成一个习惯：像第一次那样，定期在一项稳定的任务上重新做一次小规模试运行，把“这东西

以前一直很可靠”当成一个需要不时重新验证的假设，而不是一旦成立就永远成立的事实。

14.3 “我的行业受严格监管，这是不是意味着这套方法根本不适用于我？”

恰恰相反，通常情况下是这样。受监管行业恰恰是本书这套检查纪律最重要的地方，而且监管机构正越来越直接地要求企业做与之非常接近的事情。

关键洞察

欧盟《人工智能法案》(EU AI Act) 要求，高风险人工智能系统在设计时必须确保其在使用过程中“能够受到自然人的有效监督”，监督措施须与系统风险相称，并且被指派承担监督职责的人员，必须在依赖该系统之前，能够真正理解其实际能力与局限。

Source: Regulation (EU) 2024 / 1689 (EU Artificial Intelligence Act), Article 14, “Human Oversight,” 2024 (《欧盟人工智能法案》第 14 条“人类监督”)。

监管机构把这条要求写进法律，说的其实和第四章到第七章教的东西是一件事，只是换了一种说法：了解一个系统真实的故障模式，在它最可能出错的地方检查它的输出，让人真正留在决策回路里，而不是让“人工签字”沦为走过场。如果你的工作受监管，第七章的淘汰标准清单更应该被从严解读，而不是放宽，一些在不受监管的企业那里能够通过的任务，放到你这里理应被淘汰。这不是说这套方法不适合监管行业，恰恰相反，是这套方法正好做到了监管行业本就要求你做的事。

14.4 “我原则上根本不信任 AI，凭什么要把任何事交给它？”

这是一个正当的出发点，本书也无意用力把你说服到相反的立场上。它提供的，是一种低成本验证这个立场的方法：第三章的试运行任务，正是为了让“不信任”这件事几乎不需要付出任何代价就能付诸行动而设计的。在一件小、风险低、可核查的任务上做一次真正的试运行，让实际的证据、而不是对 AI 的笼统感觉，来决定这项具体任务是否值得任何信任。如果答案是不值得，第七章会给你一套干净、有据可依的方式来做出这个判断并继续前进，这比一概拒绝或者全盘接受都更有用。

14.5 “我的团队在什么时候该‘解雇’一项任务上意见不一。”

这种分歧通常说明的是第七章的四项淘汰标准还没有被落实成具体的东西，而不是说明这些标准本身是主观的。“这感觉有风险”和“这项任务不符合第三项淘汰标准，因为这里一次出错的代价会超过所有好结果加起来的价值”，是两种完全不同的讨论，后者可以基于证据来争论，而不是凭直觉。第十三章的团队标准正是为此而设：作为一个团队，提前用具体的语言写清楚，对这项具体任务来说，一次代价高昂的错误实际会是什么样子，而不是等分歧已经变成一场抽象的争论之后再谈。

14.6 “对我这么大的企业来说，这套流程感觉太重了。”

把整套内容一口气读完，确实会有这种感觉，这也正是第十章要以一份三十天计划、而不是一份原则清单的形式出现的原因：一项任务、一份任务说明、一次试运行，分摊在四周里，而不是一下子把这些都套用到你做的每一件事上。本书里的大部分流程，成本都集中在一项任务最初的那几周，之后会很快变得低廉。如果同一项任务做到第五次、第六次时，流程依然感觉很重，那就值得留意了：第六章讲保存下来、可复用的常设指令，核心意思正是到了那个阶段，流程本不该还让人觉得这么费劲。

14.7 “我之前用 AI 试过一次，结果很糟糕，这次凭什么会不一样？”

也许真的不会不一样，本书也不会向你保证情况一定会不同。真正值得诚实检视的是：你那次早先的尝试，更接近第一章开篇故事里那种四个词的任务说明，还是接近完整的五要素版本。相当一部分“AI 做不了这个”的结论，追根究底，源头是一次测试不充分的初次尝试，而不是这项任务本身真的不合适。用第三章讲的方法，在同一项任务上真正做一次试运行，这次配上一份完整的任务说明，然后再判断第一次尝试得出的结论是否依然成立。

14.8 “涉及他人隐私或敏感信息的任务该怎么办？”

在做任何别的事情之前，先把这类任务单独拿出来，用第七章的淘汰标准更严格地过一遍。涉及健康信息、财务细节，或者任何一个人合理期待应当保密

的信息的任务，成本结构是不同的：第三项淘汰标准，也就是一次错误的代价超过所有成功结果加起来的价值，在这里几乎是自动成立的，因为隐私方面的失误不只是修复成本高，很多时候根本无法挽回。第十二章关于数据处理方式的问题，正是要用在这里：在任何涉及敏感信息的任务接近真正的试运行之前，先弄清楚这些信息会经历什么，而不是事后才去弄清楚。

14.9 “AI 很快不就会强到让这一切都不再重要了吗？”

第一章已经详细回答过这个问题，这里值得简要重申一次，因为这个质疑总会反复出现：即便工具能力更强，一份真正完整的任务说明依然胜过一份含糊的说明；那种自信满满却给出错误答案的模式，是这些系统训练方式带来的结构性结果，而不是一个会被慢慢修补掉的缺陷；而你的具体情境、你的客户、你的标准、你的历史，无论工具变得多强大，都不会自动变成一个通用型工具天然就知道的东西。本书讲的这套管理能力，不会随着模型质量提升而过期，因为它从一开始要解决的，就从来不是一个质量问题。

14.10 “这不就是常识吗？为什么要专门写一整本书？”

在很大程度上，这确实是常识，因为你早就把这里的每一条都用在人身上了。你交代一个新员工任务时，早就不会只甩给他一个任务名称；你检查一个新员工早期的工作成果时，早就比检查一个老员工的更仔细；你也早就知道，有些工作不该交给团队里最新来的人，不管这个人看起来多机灵。这些都不是新鲜事。真正新的地方，是要记得把这些本能用到一款软件上，因为一个聊天界面不会像一个新人局促不安的第一天那样，自然而然地提醒你这么做。这本书教给你的，与其说是一项新技能，不如说是把你早就拥有的一项本能，重新引导到一个它本来不会自动延伸到的地方。

14.11 “我怎么知道一项任务是真的‘配得上’更轻的监督，还是我只是开始掉以轻心了？”

诚实的答案是，这两种感觉从内部体验起来是一样的，这也正是为什么第五章坚持要有一份写下来的、具体的故障模式清单，而不是一种“这项任务现在感觉挺靠谱”的笼统印象。掉以轻心，是一种背后没有证据支撑的感觉。而理应获得的信任，是一种背后有书面记录支撑的感觉：一次真正的试运行、一段抽

查历史、一份保持简短稳定了数周、而不是靠模糊自信撑了数月的故障模式清单。如果你说不出那份清单上具体有哪些条目、上一次检查是在什么时候，那就该把这当成掉以轻心的信号，而不是理应获得的信任，然后回去再检查一遍那道接缝，再确认是不是真的可以继续放轻监督。

14.12 “不管我怎么精简，我的故障模式清单条目总是超过三四条。”

第五章对此的回答值得重申一次，因为这一点在忙乱之中很容易被忽略：一份怎么都精简不下来的清单，通常说的不是这个工具不可靠，而是说这项任务本身其实是好几项任务共用了一个名字。在你以为自己需要一份更长的清单之前，先看看清单上具体写了什么。如果其中三条都集中在同一种特定的输入类型、同一个特定的客户、同一种特定的文档格式，或者同一类特定的边界情况上，这种聚集往往说明它是一项独立的任务，值得拥有自己的任务说明和自己的试运行，而不是继续在你最初那项任务已经很长的清单上再添一行。

14.13 “我只能用一款 AI 工具，是老板选的，不是我选的。”

第十二章的五个问题依然适用，只是这一次要瞄准的目标，是理解一款你没有选择权的工具，而不是在几个选项里挑一个。测试它是否记得住一条常设指令，弄清楚它实际的数据处理方式，留意它在不确定的时候是会坦白提示，还是会自顾自地猜。你或许没有权力换掉它，但准确知道它薄弱在哪里，依然是让你能够检查对接缝的关键，而这恰恰是本书要教的大部分内容，不管这款工具是谁选的。

要点总结

- 对这套方法的大多数质疑，都指出了某种真实存在的问题。诚实的答案通常是“没错，而这项顾虑真正适用的，是这样一个更具体、更窄的范围”，而不是矢口否认。
- 受监管的工作不是这套方法的例外情形。监管机构正越来越直接地要求企业做与之非常接近的事情。
- 团队在是否该“解雇”一项任务上出现分歧，通常说明淘汰标准还没有被落实成具体的东西，而不是说明这些标准本身不管用。
- 一次此前用 AI 失败的经历，值得先用一份真正完整的五要素任务说明和一次真正的试运行重新测试一遍，再把它当作一个永久的定论。

14.14 接下来

第十五章转向一个问题，本书此前大多只是假定了一个诚实的答案，却没有真正验证过：委派究竟为你省下了多少时间，靠数据衡量，而不是靠感觉。

第 15 章

衡量委派究竟为你节省了什么

如果你问大多数人，在把某项任务委派给 AI 三个月后，这样做是否为他们节省了时间，他们通常会给出一个自信的“是”，甚至常常在你把问题问完之前就已经答了。但如果你接着问，具体省了多少分钟，和以前相比又是多少，那份自信往往就化作了耸肩和猜测。人们对“省了时间”这件事有多确信，和他们实际测量过这件事的次数有多稀少，这两者之间的落差，正是本章要谈的内容。而事实证明，这个落差比直觉告诉你的还要大。

关键洞察

一项随机对照试验让十六名经验丰富的开源开发者完成真实的编码任务，部分任务允许使用 AI 工具，部分不允许，并直接测量完成时间。结果显示，使用 AI 的开发者完成同类任务反而多花了 19% 的时间，而不是更快；但事后他们却估计 AI 让自己快了大约 20%。实测结果与他们自信的事后估计，方向恰好相反。

Source: Becker, J., Rush, N., Barnes, E., & Rein, D., “Measuring the Impact of Early-2025 AI on Experienced Open-Source Developer Productivity,” arXiv:2507.09089, July 2025 (METR) (论文标题：《衡量 2025 年初 AI 对经验丰富的开源开发者生产力的影响》)。

那项研究测量的是经验丰富的开发者在编码任务上的表现，而不是本书所讨论的小企业委派场景，因此老实的解读并不是“委派从不省时间”：第二章到第十一章里满是委派确实省了时间的真实案例。老实的解读范围更窄，也更有用：“感觉一项任务省了时间”和“一项任务确实省了时间”，是两件需要分别测量的事实，二者之间的落差可能朝任何一个方向发展，在真正核实之前，没有人会注意到。

15.1 为什么“感觉”与“事实”会渐行渐远

“省了时间”的感觉，来自草稿几乎瞬间出现，而不是像以前那样要自己敲上二十分钟的那一刻。那一刻是真实的，也确实快。但除非你刻意把它算进去，否则它并不包括第四章到第六章所说的、叠加在那一刻之上的一切：抽查、修正，以及接缝暴露出问题时偶尔需要的整段重写。一项任务如果十秒钟就能生成草稿，但之后需要十二分钟仔细检查，那它相对于以前需要二十分钟的任务，并没有省下八分钟。只有当检查确实比原来动笔写要快时，才算省下了八分钟，而这是一个需要实证检验的问题，草稿出现的速度本身回答不了。

省了时间的感觉，来自看着草稿瞬间出现。省了时间的事实，来自测量之后发生的一切。

15.2 究竟该衡量什么

是总时间，不是起草时间。记录一项任务的完整周期，从打开任务说明开始，到成果真正完成、发出或归档为止：起草加上检查，再加上任何修正，对该任务的多个真实实例都这样记录。再把这个总数，与你对委派前这项任务耗时的诚实记忆相比较，如果能有几次记录在案的实例可比，那就更好。

要有一段真实的时期，而不是撞上了运气好的一天。一次任务做得快，并不能告诉你它真实的时间成本，就像第三章里提到的，单次试运行也说明不了任务的准确性。要在一到两周的正常时间里持续记录一项任务，包括那次恰好很棘手的实例，而不是只挑事后讲起来漂亮的干净案例。

要把一次性成本和持续性成本分开算。第二章讲的真正的任务说明，第一次写要花真实的时间；第六章讲的常设指令，搭建和修订也要花真实的时间。这两项都不应该被永远算在任务持续节省的时间账上。把它们作为搭建成本单独记一次，等搭建完成之后，再拿每次重复执行的持续节省与单次成本相比较，这和第二章论证前期任务说明值得花时间去写时用的摊销逻辑是一样的。

要看成果，不要看产量。如果一个工具能让你在原本只够写一版的时间里生成五版草稿，但五版里最终只会用上一版，那它并不会自动为你省下什么。要拿真正完成、发出、确实有用的工作量去对照花费的时间，而不是拿产出的原始数量去对照，这和“忙碌的一天”与“高产的一天”之间的区别是同一个道理，不论有没有 AI 参与都一样。

15.3 一个说了实话的数字

Renaldo 经营着一家小型餐饮公司，他一直认定（却从没真正计时过）AI 在两项任务上为他省下了实实在在的时间：给潜在客户起草活动提案，以及给以往客户写感谢便条。他把这两项任务诚实地记录了三周，记的是总时间，包括每一次修正。提案任务的结果站得住脚：平均十八分钟，比以前的大约五十分钟少了很多，即便算上第四章那套方法要求的抽查也是如此。但感谢便条没有。这些便条本来就写得快，手写每张只要四五分钟，因为他了解自己的客户，写出来的内容既私人又具体。AI 起草的版本回得很快，但通用到他还是要花七八分钟去重写大部分内容，总时间反而比自己动手写还多，只不过把时间从“写”挪到了“改”上而已。

Renaldo“解雇”了感谢便条这项任务，不是因为 AI 没能通过某种抽象的测试，而是因为真实数字一目了然地摆在那里：一项他以为在为他省时间的任务，其实正悄悄地耗费他更多时间。而用同样诚实的方法测量的提案任务，则一如既往地照常运行。这一切都不需要多复杂的追踪手段，每项任务三周简单的时间记录，告诉了他三个月自信的猜测始终没能告诉他的事。

15.4 另一个方向

Soo-ah 经营着一家小型补习中心，她遇到的是相反的问题：她一直以为，自己发给家长的 AI 起草改期邮件只是个不痛不痒的小便利，手写本来就够快，搭建自动化的功夫几乎不值得。她记录了这项任务两周，主要是在员工会议上给出一个干净的数字，并预期这会证明搭建的投入并不划算。结果并非如此。手写的旧版本比她记忆中花的时间更长：算上查找家庭当前的日程、核对是否有冲突之后，每封要四到六分钟，而这些工作，委派后的版本现在已经作为任务说明的一部分自动完成了。记录下来的平均值是每封邮件九十秒，已包含修正，对照的是她从未真正计过时、实为六分钟的真实基准。

Soo-ah 从这个数字里得到的教训，方向与 Renaldo 恰好相反：一项感觉可有可无的任务，值得为它辩护，而不是质疑它。她之所以在业务清淡的一个月里没有把它砍掉，正是因为这份记录给了她一个可以拿出来说话的真实数字，而不是“大概还行”这种含糊的感觉。测量的作用不只是揪出那些正悄悄花掉比它省下的更多时间的任务，它同样也能揪出相反的情况：一项实际价值比当下感觉到的更高的任务。而单凭记忆，这种情况同样容易被误判。

15.5 试一试：把一项任务记录两周

选一项你目前正在委派、并且认为它在为你节省时间的任务。在两周内，每一次真实执行都记录下来：

Date	Total time (draft + check + correct)	Notes
------	---	-------

两周结束后，把平均值与你对委派前耗时最诚实的估计相比较。如果这个数字无论朝哪个方向让你感到意外，那说明这个练习起作用了，而不是说明你测错了。

要点总结

- “感觉一项任务省时间”和“一项任务确实省时间”是两件不同的事实。二者之间的落差可能朝任何方向发展，而且往往比人们预期的更大，即便是在谨慎、经验丰富的使用者身上也是如此。
- 要衡量总时间：起草加检查加修正，统计一段真实的时期，而不是一次做得快的孤例。
- 把搭建成本（一份任务说明、一条常设指令）与每次重复执行的持续成本分开记录，只有在搭建完成之后，才用持续成本的数字来判断一项任务究竟省了多少时间。
- 一项任务因为产出瞬间出现而显得高效，但除非包含修正在内的完整周期确实比它取代的方式更快，否则它并不真的高效。像 Renaldo 那样去测量它，是弄清楚你实际运行的究竟是哪一种情况的唯一办法。

15.6 接下来

第十六章会从任何单一任务中抽身出来，纵览所有任务：按任务类型反复出现的故障模式，写作、分类、排期、调研，让你委派下一项任务时能带着优势起步，而不是从一张白纸开始。

第 16 章

不同任务类型的常见失败模式

到目前为止，本书的每一章都按照第五章建议的方式，逐个任务地建立故障模式清单：针对这项具体任务、这个具体工具，通过你自己的试运行发现问题。这仍然是建立那份真正管理着你手头任务的清单的正确方法。但在本书举了十几个例子之后，一个同样有用的第二种规律开始浮现：形状相近的任务，往往也会有相近的故障模式，甚至在你亲自试运行之前就已如此。本章按任务类型整理了此前已经展示过的内容，好让你下一次委派任务时，起点不再是一张白纸，而是已经领先一步。

关键洞察

一项大规模研究对 35 个数据集、83 个不同模型中的 AI 模型错误进行了自动化系统编目，结果发现，一些最常见的故障类型恰恰是最少被讨论的：在一个看似完整的答案中悄悄遗漏一项必需信息，以及误解了对方究竟在问什么；而不是人们通常假定的那种故障，即直接说出一个错误的事实。

Source: Ashury-Tahan, S., Mai, Y., Bandel, E., Shmueli-Scheuer, M., & Choshen, L., "ErrorMap and ErrorAtlas: Charting the Failure Landscape of Large Language Models," arXiv:2601.15812, January 2026 (论文标题：《ErrorMap 与 ErrorAtlas：绘制大语言模型的故障图谱》)。

这一发现，关系到你该如何看待下文列出的这些模式。人的本能是提防工具凭空捏造虚假内容，这种担心是真实的，也值得留意。只是这并非故障唯一的形态：根据这项研究，悄悄的遗漏，或是对实际需求的细微误读，至少同样常见，而且在随手一读时更容易被忽略。

16.1 写作与起草类任务

Priya 的房源描述、Renata 的点评回复、Devon 的提案草稿，这些例子里贯穿着同一种模式：流畅、结构工整的文字，其错误恰恰被这套结构本身掩盖了。一句泛泛而讨喜的句子，无论其中的事实是真还是假，读起来都一样自信；无论语气是否真的贴合你本人的声音，还是仅仅是一种看似合理的通用近似，读起来也都一样自信。要留意的是：用自信笔调包装起来的具体断言，尤其是那些填补了源材料本未涉及的空白的数字、日期和人名。本书中每一个写作类任务的例子，反复出现的解决办法都是同一个：附上你自己真实范例的具体任务说明（第二章），再加上一次专门针对“听起来比输入材料实际更具体”的断言的抽查。

16.2 分类与分诊类任务

Maria 的费用分类、James 的维修工单分诊、McDonald's 得来速的案例：这一类任务失败在边界处，而不是失败在一目了然的典型案例中间。一张明显属于常规情况的工单，几乎每次都能被正确分诊。故障会聚集在表面相似、实则不同的两个类别之间的那条边界上：燃料还是设备，常规情况还是真正的漏水紧急事件。要留意的是：任何有可能同时归入两个类别的输入内容；对这类具体的重叠区域要做完全排查，而不是对整批内容平均抽样，这正是第四章“找接缝”方法最直白的应用。

16.3 日程与日历类任务

Devon 那个搞混时区的日历助手，是这一类任务的典型案例：一个微小、无声的假设，即“下午 3 点”对交流双方来说意味着同一件事，就这样演变成一场真正的冲突，直到事情几乎无法挽回才有人注意到。这类任务的故障很少是戏剧化的。它们是一些悄无声息的默认设定，比如被假定的时区、被假定的日期格式、被假定的重复规律，之所以没人质疑，是因为输出结果表面上看不出任何问题，直到它撞上了工具原本就不知道的某个事实。要留意的是：任何依赖假设、而不是原始请求中明确说明的日期、时间或重复规律细节；把对这类细节的明确确认，直接写进任务说明本身。

16.4 研究与摘要类任务

Ola 的筹款信，以及第五章提到的 AI 法律研究工具，都体现了这一类任务的标志性故障：一个被凭空捏造或张冠李戴的具体事实，嵌入在一篇整体上听起来颇为准确的文字之中，如果不核对原始来源，几乎不可能被发现。与写作类任务那种泛泛的捏造不同，这种故障往往可以追溯到一个真实存在、却对不上号的来源：一个属于另一年的统计数字，一个属于另一宗案件的说法，听起来足够接近正确答案，错得却足以造成实质影响。要留意的是：任何能够对照具体、可查证来源核实的数字或具名事实；直接拿它去核对那个来源，而不是仅凭它听起来是否合理来判断。

16.5 链式多步骤任务

第九章已经深入讨论过这一点，为求完整，这里值得再概括一遍：任务链的故障，通常不是某一个单独步骤严重出错。而是前面某个步骤中一处平常、微小的瑕疵，被后续每一个步骤层层叠加、反复重述、并用自信的措辞包装起来，直到最终输出中已经看不出问题究竟从哪里开始。要留意的是：这是唯一一种无法靠更仔细地检查成品来发现的模式。它只能靠在每个步骤的输出成为下一步骤的输入之前逐一核查来发现，也就是第九章讲的检查点纪律，因为等到任务链的输出看起来已经完成时，问题出在哪里的证据往往早已消失。

16.6 运用本章内容

这五种模式，没有一种能取代第五章要求你针对自己具体任务和工具建立的故障模式清单。它们只是一个起始假设，不能替代真实试运行所产生的证据。一项新的写作任务，很可能会有上文所说的写作类任务模式附近出问题；用你自己三到五次的尝试去确认这一点，而不是想当然地认定它，这正是第三章从一开始就主张的那种纪律。本章能带给你的，是对“该先看哪里”这个问题更好的第一直觉，而不是让你可以跳过检查这道工序的理由。

16.7 试一试：先猜测，后试运行

在对你的下一项新任务进行试运行之前，先用一句话写下你预计它会符合上述五种模式中的哪一种，以及为什么：

实际进行试运行，然后把你的猜测和真正发生的情况对照一下。猜对了，能建立起你快速判断一项任务大致形状的信心。猜错了同样有用，这说明这项具体任务不像大多数同类任务那样符合其类别的一般规律，而这恰恰正是一份书面故障模式清单存在的意义所在。

要点总结

- 形状相近的任务，往往也有相近的基本故障模式：写作类任务会在流畅的文字中捏造具体细节，分类类任务会在类别边界处出错，日程类任务会栽在无声的假设上，研究类任务会张冠李戴地误用真实事实，而任务链则会不断放大早期一个微小的错误。
- 根据大规模错误研究，悄悄的遗漏和对实际请求的误读，至少和公然捏造一样常见，而且在随手一读时远比后者更容易被忽略。
- 把这些模式当作预判一项新任务可能出现的接缝所在的起始假设，然后用一次真实的试运行去确认或修正这个假设，也就是第三章所讲的那种纪律，而不是盲目相信这些模式。

16.8 接下来

第十七章会讲到一种纪律，本书此前已经数次顺带提及，却始终没有为它单独辟出篇幅：有意识地定期回访一项你已经“解雇”过的任务，而不是想当然地认为一扇关上的门就会永远关着。

第 17 章

重新审视一个曾被“解雇”的任务

第七章结尾留下了一个本书尚未完全兑现的承诺：“解雇”一项任务并非终审判决，一项值得重新考虑的任务，理应获得一次全新的小规模试运行，而不是被永远盖棺定论。本章就是要兑现这个承诺，因为“以后再重新审视”这句话如果没有配上一套切实可行的做法，往往就等于“永不重新审视”，正如“偶尔检查一下”在第四章给出真正的方法之前毫无意义一样。

17.1 为什么被“解雇”的任务默认会一直“解雇”下去

“解雇”一项任务，本身并不要求你以后再去想它，而这恰恰是问题所在。第七章的淘汰标准清单，是针对某个特定工具在某个特定时刻的特定表现所做的一次性判断，但你的日程表里没有任何东西会自然而然地提醒你去问：那种表现是否已经改变。第九章关于 AI 能力提升速度的研究，在这里值得重新提起，理由和最初提出时不同：一个工具在三月份稳定地做不好某项任务，并不能保证它到了十月份依然做不好，而最值得去检查的任务，恰恰就是那些你已经彻底不再去想的任务。

一个工具在三月份稳定地做不好某项任务，并不能保证它到了十月份依然做不好。最值得重新检查的任务，恰恰就是那些你已经不再去想的任务。

17.2 建立一套真正的重新审视习惯

选定一个固定周期，而不是一个你会忘记留意的触发点。等着“听说这个工具变好了”，等于是在等一个几乎从不会清晰到可以据此行动的信号。一个简单的、以日历为基础的检查，每六个月一次，和你原本就在做的其他周期性业务复盘放在一起进行，比一个你必须记住去留意的模糊触发点更管用。

真正重新做一次试运行，而不是凭记忆核对一下。重新审视一项被“解雇”的任务，意味着执行第三章那套真正的规范：用当下真实的输入，重新尝试三到五次，而不是在脑子里问一句“这感觉还是会失败吧”。一个工具在当初导致任务被“解雇”的那个具体失败点上的表现，可能已经发生了变化，这种变化，凭记忆很容易忽略，而通过一次诚实的、全新的尝试，却一目了然。

预期大多数重新审视都会确认最初的判断。这一点重要到值得直说：多数情况下，一项被“解雇”的任务，重新审视后依然会栽在当初那条淘汰标准上，而这是一次成功的重新审视，不是白费功夫，这和第七章对首次试运行的重新界定一模一样：正确地排除掉某个选项，本身就是一种成功。这套习惯的价值，不在于每一次重新审视都能带来好消息，而在于极少数情况下，一项任务真的变得可行，你会在六个月之内就发现，而不是永远不会发现。

当任务通过审视时，把它当成一项新任务，而不是一项恢复原状的旧任务。一项任务在被搁置数月之后，通过了一次全新试运行的淘汰标准检验，就应该重新从头走一遍第二章的任务说明和第四章的抽查流程，而不是凭着“解雇”之前那份旧任务说明的分量，直接恢复到完全信任的状态。当初导致它失败的原因，或许确实已经解决了。但这并不意味着这段时间里，这个工具在其他方面就什么都没变。

17.3 六个月后，究竟发生了什么变化

英格丽经营着一家小型兽医用品经销公司，一年前她“解雇”了一项任务：起草保险预授权询问的回复，这项任务被第七章的第三条淘汰标准干净利落地拦了下来，一次关于承保条款的错误答复，代价就大到足以抵消所有省下来的时间。她在日历上标了一个六个月后的检查点，但没抱太大期望。第一次重新审视是在春天，结果完全印证了当初的判断：在一次全新的五次尝试试运行中，同一类承保条款错误在第二次尝试时就再次出现。她记下这一点，结束了这次试运行，平静地继续往前走。

第二次重新审视是在秋天，情况不一样了。那个曾两次导致任务失败的具体承保条款混淆问题，这一次在五次全新尝试中一次都没有出现。英格丽没有仅凭这一点就恢复这项任务，而是从头执行了一遍第二章那套真正的任务说明流程，因为一年前她本会用的那个版本，已经不再反映她目前的供应商条款了，并且在信任任何结果之前，先按照第四章的方法对新一批尝试做了抽查。六周

之后，这项任务真正运转了起来，而这是一项在将近一年时间里都被正确地列为禁区的任务。最终的成功，靠的不是第一次就猜对。靠的是一套习惯：在决策中最令人兴奋的那部分，也就是最初的“解雇”，早已成为过去之后，依然持续检查下去。

17.4 什么时候，重新审视理应持续失败

并非每一项被“解雇”的任务都在等待工具变得更好，这里值得专门指出一种情况：重新审视这套习惯每一次都正确地得出同样的答案。前面某一章工具形态对比中出现过的奥达丽丝（Odalys），也曾“解雇”过一项任务：为订单确实延迟发货的客户，针对他们各自的具体投诉，起草个性化的道歉信。拦下这项任务的，不是第三条淘汰标准，也就是英格丽承保条款任务那种代价高昂的单次错误，而是第二条：这项任务依赖于该工具在结构上根本不可能拥有的关系历史，比如哪位客户此前已经投诉过两次，哪位客户是三年的忠实买家，理应获得和一位首次投诉、情况完全相同的新客户不一样的语气。

奥达丽丝以和她“解雇”名册上其他所有任务一样的六个月周期，重新审视这项任务，而它每一次都栽在同一条淘汰标准上，不是因为底层的写作能力变差了，而是因为一个更强的模型，也创造不出它一开始就从未被赋予访问权限的那段关系历史。这正是把重新审视这套习惯，用在一项依赖判断力或依赖客户关系的任务上，而不是用在一项依赖错误率的任务上时，会得到的诚实而有用的结果：多数重新审视都会确认当初的“解雇”，而对于因为这类具体原因被淘汰的任务来说，只要底层的局限，也就是不了解你的具体客户，始终成立，无论工具在其他方面变得多能干，这些任务都很可能会持续被确认淘汰。

17.5 试一试：安排你的第一次重新审视

对于目前在你“解雇”名册上的任何一项任务，第七章的名册条目应该已经写明了原因。在同一条目上再加一行：

下一次重新审视日期（从“解雇”之日起，或从上一次重新审视之日起算六个月）：_____

用一句话写清楚上一次具体败在哪里（这样将来的你才能清楚知道要专门测试什么，而不只是知道出过问题）：_____

等那个日期到来时，该做的准备工作其实早就做好了：执行第三章的试运行，精准针对上面写明的那个失败点，无论结果如何，都更新这份名册。

要点总结

- “解雇”一项任务并非终审判决，但这件事本身不会自然而然地促使你再看它一眼。要建立一套真正以日历为基础的习惯，而不是“以后再说”这种模糊的打算。
- 一次重新审视，指的是一场真正的试运行，也就是第三章那三到五次全新尝试，而不是凭记忆核对一下，或者抱着侥幸心理猜一猜。
- 多数重新审视都会确认最初的“解雇”决定，这说明这套习惯运转正常，而不是白费一次检查。它的价值，体现在那极少数确实发生变化的情况上。
- 一项通过重新审视的任务，需要重新走一遍全新的任务说明和全新的抽查流程，而不是直接恢复到它被“解雇”之前所拥有的信任水平。

17.6 接下来

第十八章将快速穿梭于另外六家企业之间，它们与目前为止的每一个案例都足够不同，其中至少有一个应该会让你觉得眼熟，每一个案例都展示了同一套方法，如何捕捉到一种真正不同类型的接缝。

第 18 章

六个行业，一套方法

到目前为止的每一个案例，都是一次深入研究一两家企业，这是真正学会这套方法的正确方式，但它也留下了一个现实的问题没有回答：这套方法是否也适用于那些和面包店、园艺公司完全不像的企业？本章要快速回答这个问题，一口气再讲六家企业，每一家都展示一个真实的首个任务、它撞上的真实接缝，以及同一套底层方法在做同一件底层的事。这些企业彼此差异很大，至少会有一家和你的生意相似。

关键洞察

一项 OECD 对中小企业的研究发现，各行业采用 AI 的比例差异极大：信息与通信技术行业中，近 45% 的企业已经采用了 AI；专业、科学和技术服务类企业中，这一比例超过 25%；而建筑行业的采用率只有 7.2%。

Source: OECD, "AI Adoption by Small and Medium-Sized Enterprises," December 2025 (报告标题:《中小企业的 AI 采用情况》)。

这个差距，对如何诚实地看待下面这六家企业很重要。如果你所在的行业更接近建筑业那一端，你并不是落后于某条所有人都已经在追赶的普遍曲线。你所在的行业里，像本书这样审慎、刻意的早期采用方式，依然是少数人的选择，而不是什么你该觉得自己起步太晚的事。

18.1 精品服装店

Priscilla 经营着一家拥有两家门店的女装精品店，她选择产品描述撰写作为自己的第一个任务：新货每周都会到，每一件都需要为线上商店写一段描述。她的接缝原来出在面料成分上：工具会自信地把一种混纺面料描述成“柔软透气的纯棉”，而吊牌上写的实际是 60% 棉、40% 聚酯纤维，这个细节对有面料过敏的顾客很重要，也让她在发现这个规律之前，收到过一次带着不满留言的退货。她现在的常设指令要求逐字照抄吊牌上的面料说明，而不是自行改写，从那以后这项任务就一直运行得很顺畅。

18.2 住宅暖通空调承包商

Desmond（与第九章那家活动策划公司里出现的 Desmond 是不同的人）经营着一家拥有三辆维修车的暖通空调业务，他把给客户发预约确认短信的工作委派了出去。接缝出在多元物业的地址混淆上：“123 Main St”如果没写单元号，生成的确认短信读起来没问题，却在 Desmond 注意到这个规律之前，两次把技术人员派错了门。修复的办法在任务说明里，而不是靠事后纠正：他新增了一条明确指令，要求凡是缺少单元号的地址都要标记出来交给人工核实，而不是让工具自行猜测或者干脆略过不提。

18.3 独立书店

Yuki 经营着一家单店独立书店，她委派了每周一次的“员工精选”推荐语，为每本上榜图书写一段话。这里的故障模式不是事实性的，而是语气上的漂移：几周下来，推荐语逐渐滑向那种泛泛的营销口吻，比如“该类型爱好者不容错过之作”，而这恰恰是她书店一贯的真实声音始终在避免的调调。内容本身并没有出错，这也是为什么它比 Priscilla 的面料问题花了更久才被发现。她的解决办法是每隔几个月就更新一次任务说明，而不是一次性的常设指令，因为这条接缝是渐进的漂移，不是单一的、会重复出现的错误。

18.4 住宅房地产经纪入

Marcus（与第八章那家理疗诊所里出现的 Marcus 是不同的人）从事住宅销售，他把买家咨询房源问题的初步回复委派了出去。他的接缝和“披露”沾边：

一位买家询问某处房产的洪水历史，得到的回答听起来自信、可信，实际上却引用错了洪水分区图，对于这种和法定披露义务贴得如此近的任务来说，这是一个真正危险的失误。第七章的淘汰标准在这里完全适用：这项任务里凡是涉及披露或历史记录、可能影响成交的这一小块，被整块抽出来交还给 **Marcus** 本人处理，而一般的房屋设施和看房时间安排问题，仍然继续交给工具处理。

18.5 瑜伽与养生工作室

Aditi 经营着一家单教室的瑜伽工作室，她把停课通知和代课老师通知委派给了工具，发给学员。这条接缝和第五章讲到的日程问题有些相似，但并不相同：当学员的请求里只提到星期几、没有具体日期时，比如“下周二的课”，工具有时会把停课通知发到错误的日期上，具体是哪一天，要看消息实际是在什么时候被读到的，含糊不清。她把这条接缝准确命名之后，解决办法很简单：任务说明现在要求，凡是和日程相关的草稿都必须写明具体的日历日期，绝不能只写一个相对的星期名称。

18.6 法律助理支持服务

Foster 经营着一家为独立执业律师提供支持的小型法律助理服务公司，他委派的是首轮文件格式化工作：把律师潦草的笔记转换成格式规范的诉讼文件模板。表面上看，格式化任务在本书里应该算是最安全的一类，没有真正的事实需要出错。但实际的接缝更隐蔽：工具在重新排版时，偶尔会把编号条款的顺序打乱，文字本身完全保留，但文档中其他地方指向某个条款编号的交叉引用，所指的内容却变了，除非你专门去核对交叉引用，否则光是通读文字根本发现不了这个错误。**Foster** 现在的抽查就专门针对这一点：每次重新排版之后，都要确认每一处内部交叉引用，仍然指向它本该指向的那个条款。

18.7 六家企业身上不变的东西

这六家企业表面上几乎没有共同点：零售、暖通空调、图书、房地产、养生、法律支持。但这套方法实际起作用的方式，在所有六家企业身上完全一致：一次真实的试运行，暴露出一条具体的、狭窄的接缝，而这条接缝是“AI 会犯错”这种泛泛的警告永远不会点明的，随后一次具体的修正，无论是写进任务说明

还是常设指令，把它堵上了。任务的类别各不相同，但抓住失误的那份纪律始终如一。

18.8 试一试：找到与你最相近的那一个

上面这六家企业里，哪一家最接近你自己的生意？不是按行业标签来判断，而是按你考虑委派出去的第一个任务的形态来判断：是一段文字描述、一次分类、一个和日程有关的细节，还是一次数字核对？

再读一遍那个最接近的案例，专门去看它撞上的那条接缝。这是你自己那次试运行的一个合理的初步假设，接下来要用第三章的那套纪律去验证或者修正它。

要点总结

- 本书的方法，不需要一家看起来和之前举过的例子一样的企业。六家真正不同的企业，撞上了六条真正不同的、狭窄的接缝，而同一份纪律把它们全部都抓住了。
- 一条接缝，很少是你光看任务类别就能猜到的。格式化任务真正的风险在交叉引用，不在文字本身；一份通讯真正的风险是渐进的语气漂移，不是单一的事实错误。
- 有些接缝是单一的、会重复出现的错误，一条常设指令就能一劳永逸地堵上。另一些接缝，比如语气漂移，则需要定期更新任务说明，因为问题不是同一个错误反复发生，而是一种缓慢的偏移，一次性的修正扛不住它。

18.9 接下来

第十九章会从任何单一企业的视角中跳出来，退后一步，谈一个本书至今一直含糊带过的区分：“AI 工具”这个说法，其实涵盖了几种真正不同形态的软件，知道你委派的对象属于哪一种形态，会改变本书这套方法里有几处具体的适用方式。

第 19 章

并非所有 AI 工具都是同一类工具

本书一直刻意把“AI”和“工具”当作同一种东西来谈论，因为委派背后的管理技能，不论你用的是哪一款具体产品，都是相通的。这个简化在过去九章里发挥了实实在在的作用。现在是时候把它稍微复杂化一些了，因为“AI 工具”实际上至少涵盖三类截然不同的软件，而你搞清楚自己委派的是哪一类，会直接决定这套方法里的几个环节该如何具体应用。

19.1 三种形态，一种共通技能

通用型对话助手。本书大多数例子默认采用的正是这种形态：你输入一个请求，它作出回应，对话在整个会话期间保持上下文，如果工具支持的话，会话结束后还能靠保存下来的常设指令延续下去。第二章到第七章的内容，几乎可以原封不动地套用在这种形态上。任务说明、试运行、抽查和常设指令，全都预设了一种一来一往的对话，因为这种形态本质上就是如此。

专用型工具。这类软件是为某一具体工作而打造的：给支出分类、起草某种特定文档、转录一通电话，而不是一个可以随手指向任何任务的通用对话助手。这类工具的任务说明往往不那么灵活（你可能是在填一张表单，而不是写一段上下文说明），而且常常因为它们能做的事更少，故障模式也更窄、更可预测。第三章和第四章里试运行加抽查的纪律依然完全适用。通常会有变化的是第二章讲的任务说明：专用型工具未必能容纳全部五个要素的自由文本，“情境”和“它自己无法知道的信息”这两项，很可能是体现在配置设置里，而不是一段写下来的文字。

能自主执行多个动作的智能体或自动化流程。这是三种形态里最需要把握准确的一种，也是第九章链式任务建议专门为之而写的那一种：这类系统不只

是起草一个答案，而是真正去做事，发一封邮件、更新一条记录、转一笔钱，跨越多个步骤，未必会在每一步都停下来给你看。第九章讲的检查点纪律，对这种形态来说不是可有可无的谨慎，而几乎就是整件事的关键所在。一个在你看到任何输出之前就已经完成了五个真实世界动作的智能体，等到你终于看到点什么的时候，你的检查点原本能拦下的代价，早就已经付出去了。

一个在你看到任何输出之前就已经完成了五个真实世界动作的智能体，等到你终于看到点什么的时候，你的检查点原本能拦下的代价，早就已经付出去了。

19.2 形态在何处、以何种具体方式改变了这套方法

任务说明。对话助手接受的任务说明，接近第二章那五段文字的字面写法。专用型工具往往把同样的五项信息拆散在设置、模板和配置里，而不是写成一段散文，这时候值得刻意地做一次“翻译”，而不是假设工具“自然就懂”一份五要素任务说明本该说的内容。智能体的任务说明则需要明确写出它在不停下来的前提下被允许做什么，而不只是写清楚一个好的输出长什么样，因为这里的任务说明约束的是动作，而不只是文字。

检查。对话助手的输出会安安静静地待在那里，直到你读它，这正是第四章的抽查之所以直截了当的原因：在你采取行动之前，什么都不会发生。专用型工具的输出通常也是同样的情况。而智能体的输出，等你看到的时候，可能已经不可逆转了：邮件已经发出，记录已经改动，这意味着检查点必须发生在动作之前，而不是草稿之后，这比对话助手所要求的第四章纪律要严格得多。

“解雇”。第七章的四项淘汰标准适用于全部三种形态，但其中第三项，也就是单次错误的代价超过所有成功之和，对智能体尤其需要格外看重。对话助手最坏的现实失败，是一份你在发出之前就发现的糟糕草稿。智能体最坏的现实失败，可能是一个已经付诸实施的动作，这就改变了这项淘汰标准背后的实际算账方式，哪怕表面上看，这项任务的风险级别与前者相差无几。

19.3 一个具体的对比

Odalys 经营着一家小型订阅盒子业务，三种形态的工具她在不同任务上都会用到，这让她的做法成了一个清晰的例证。一个通用对话助手负责起草客户支持回复，用的是第四章那套普通的抽查纪律：读草稿、查接缝、发出去。一

个专用型工具按下拉菜单式界面里的原因代码给退货商品分类，她给它的“任务说明”其实只是一次性的配置，规定哪些原因代码对应哪些类别，在设置时检查一次，之后只有在她新增一个代码时才会再看一眼。一套自动化流程会在库存跌破某个阈值时，自动向她的主要供应商补货低库存商品，而在她的三种工具里，唯独这一个要求检查点设在动作触发之前，而不是之后：任何超过五百美元的补货订单，都会先暂停下来等她批准，订单才会真正发出去，因为在这里，智能体的失误不是一份需要修改的糟糕草稿，而是已经花在她可能根本不想要的库存上的真金白银。

19.4 那次让她定下阈值的险情

Odalys 选定五百美元这个数字，并不单纯出于谨慎。她最早那版补货自动化流程，压根没有设定金额阈值，只有一条笼统规则：任何涉及她此前没用过的新供应商的订单，都需要审批。这条边界在她写下它的时候看似合理，结果却完全没有拦住真正的风险所在。某款产品销量出现季节性激增，把它的补货数量推到了远超她平常订单规模的水平，这笔订单通过她现有的、早已获批的供应商自动触发，最终下了一笔比她本人会选择的量足足大十一倍的真实订单，而这一切，都发生在她看到其中任何一行内容之前。这笔订单完全没有涉及新供应商。没有任何一条触发她原来设的边界。问题根本不出在供应商关系上，而是出在一个数量上，它已经悄悄地漂移到远超那款产品“正常”范围之外了。

她在一小时之内就发现了问题，取消了供应商退货窗口期内还能取消的部分，并且围绕真正出问题的地方重新写了检查点，而不是围绕她最初猜测会出问题的地方：一个针对订单总金额的金额阈值，而不是一条关于用了哪家供应商的规则。这个教训的适用范围超出了库存管理本身：一个动作前置的检查点，好坏取决于它到底在盯着哪条边界，而真正值得设定的那条边界，往往要等到第一条凭猜测设下的边界被什么东西钻了空子之后，才会变得清晰起来。

19.5 试一试：给你自己的三种形态命名

把你或你的团队目前正在使用、或者正在认真考虑使用的每一款 AI 工具都列出来。针对每一款，写下它属于三种形态里的哪一种：通用对话助手、专用型工具，还是能自主执行真实动作的智能体。

对于你标记为智能体的任何工具，写下它目前可以在没有人类先暂停审批的情况下做些什么事。如果你答不出精确的答案，那就是在你进一步向它委派任何工作之前，需要先补上的接缝。

要点总结

- “AI 工具”至少涵盖三种截然不同的形态：通用对话助手、专用型工具，以及能自主执行真实动作的智能体。三者背后的管理技能是相通的，但具体应用方式上的一些细节并不相通。
- 专用型工具的任务说明往往体现在配置和设置里，而不是散文式文字。要刻意把第二章的五个要素“翻译”过去，而不是假设工具已经自然懂得它们。
- 智能体的检查点必须发生在不可逆动作之前，而不是草稿之后，这比对话助手所要求的第四章纪律更为严格。
- 第七章里的第三项淘汰标准，也就是单次错误的代价超过所有成功之和，对任何能够不停顿就采取行动的智能体来说，都值得格外看重，因为它最坏的失败通常是一个已经付诸实施的动作，而不是一份你能及时发现的草稿。

19.6 接下来

第二十章将探讨一类本书至今刻意基本回避的任务：任何直接涉及金钱的事情，在这里，一项被委派任务的常规风险，会陡然提升一个数量级。

第 20 章

当任务涉及金钱时，什么会变

本书迄今涉及的每一类任务，都共享一个如今值得挑明的假设：一个错误的输出，只要发现得早，付出的代价不过是修正所需的时间，外加一点尴尬。而直接涉及金钱的任务，比如发票、报销核算、报价、薪资调整，会以一种特定的方式打破这个假设。错误输出的代价，不再以时间衡量，而是以已经转移出去的钱来衡量。钱一旦转移出去，想要收回，比收回一句已经发出的话要难得多。

20.1 为什么算术格外值得怀疑

写作类任务的失败方式，是编造一个看似可信的细节。金钱类任务既可能以同样的方式失败，也可能在更基本的地方出错：算错真正的算术。这是这类系统运作方式中的一处结构性弱点，而不是随着模型在其他方面不断进步就会悄悄自行解决的训练缺口。

关键洞察

一项被广泛引用的 2023 年研究测试了 GPT-4 在乘法运算中随数字位数增加时的表现，发现三位数乘法的零样本准确率为 59%，四位数乘法骤降至 4%，五位数乘法则降到 0%。这证明，随着计算变长，原始算术的可靠性会急剧且可预测地下降，这是一种与这些模型处理文本方式相关的结构性规律，而不是简单的知识缺口。此后，个别模型已有所改进，尤其是那些能够调用真正的计算器或运行代码、而非纯粹依靠习得模式进行计算的模型，但这一发现所指向的根本警示，即核实计算结果，而不是仅仅因为它读起来顺理成章就信以为真，无论你用的是哪个具体模型，依然成立。

Source: Dziri, N., et al., “Faith and Fate: Limits of Transformers on Compositionality,” *Advances in Neural Information Processing Systems 36, 2023* (originally arXiv:2305.18654) (论文标题:《信念与命运: Transformer 在组合性上的局限》)。

散文中的一个错误数字，在随手一读时往往难以察觉，而这正是第四章“检查而不重做”这一原则，在涉及金钱的任务上需要一处具体修正的地方：金钱类任务的接缝，不像 Maria 的费用明细那样，是某个主题或某个类别。它是每一个单独的数字，而每一个数字都需要能够追溯到一个你可以独立核实的来源，而不只是看起来和周围的数字对得上就算数。

20.2 核对，而非抽查

第四章那套通用的抽查方法，即找到接缝、彻底检查它、对其余部分轻度抽样，依然适用，但金钱类任务需要一种特定版本的“彻底检查”：核对，也就是拿一个独立来源去核实总数，这个来源不能来自生成这个待核数字的同一套流程。一份报价，应该能追溯到你真实的价目表，而不是听起来是否合理。一笔报销总额，应该能追溯到实际提交的收据，由你独立相加得出，而不是看工具算出来的数字内部是否自治。内部自治和正确，不是一回事。一个看起来合理、却以一种内部自治的方式出错的总数，正是那种最难仅凭阅读就发现的失败。

内部自治和正确，不是一回事。一个看起来合理、却以一种内部自治的方式出错的总数，正是那种最难仅凭阅读就发现的失败。

20.3 淘汰标准在这里变得更严格

第七章的四项淘汰标准，本身不会因为任务涉及金钱而改变。会改变的，是你运用它们时该有多保守。嵌在金钱类任务里的判断性决定，比如某笔临界费用算不算可以报销，理应得到第七章处理 **Renata** 那些涉及病情的评价时同样的“保留人工”待遇，原因也相同：没有哪条常设指令能可靠地替代对模棱两可情形的判断，而在这里判断出错，牵连的是一个实实在在的金额数字，不只是一封尴尬的邮件。第三项淘汰标准，即单次错误的代价超过所有成功案例加起来的收益，对任何以真实体量转移资金的任务而言，几乎已经默认成立，这和第七章 **Zillow** 那个例子在更大规模上展示的逻辑是一样的：一个系统性的定价错误，一旦在足够多的交易中重复出现，就能抹去所有做对了的交易所创造的全部价值。

20.4 一个被正确核查的报价任务

Felix 经营着一家小型定制家具作坊，他把给潜在客户报价的初稿委派了出去，做法是把材料成本查询和根据作品描述尺寸得出的人工估算结合起来。他的第一版直接信任了工具算出的算术，材料成本乘以数量，再加上人工系数，而且每一次读起来都很干净，总数看起来很有把握，看不出任何接缝。真正的核对，也就是针对每份报价的总数，用他真实的价目表独立重新计算一遍，而不是单看它读起来是否合理，在他检查的第四份报价里，发现了一个真实的错误：人工系数用错了尺寸，误差大到足以让一件需要一周才能完工的作品，报价比他的真实成本低了将近 30%。

Felix 没有“解雇”这项任务。他加上了真正关键的那一道检查：现在每一份报价在发出之前，最终总数都会用同样的三个数字，材料、尺寸、人工费率，独立重新计算一遍，这个动作只要九十秒，却能在报价送到客户手上之前，就拦下那份低估的报价。起草环节依然为他省下了实打实的时间，只是算术本身，再也不会仅凭自身的说法就被信任。

20.5 金钱类任务里的判断性决定

金钱类任务里的接缝，并非每一处都是算术问题，值得点名的是本章更严格的淘汰标准解读所对应的判断性决定版本。**Farrah**，她的非营利组织试运行曾在本书前面出现过，也把员工差旅报销决定的初稿委派了出去：某张收据是否在政策范围内，是否需要经理的二次签字，某个临界类别，比如一顿说是工作餐、也说得过去算是社交聚餐的饭局，究竟算不算可以报销。任何一笔单独

报销的算术都很简单，无非是把几笔明细正确相加。真正的风险，完全存在于那些临界判断里，而这些判断依赖的机构背景，是任何一张收据明细都提供不了的：某趟差旅的费用，究竟能合法地从哪些有捐赠方限制用途的资金中列支，以及哪位员工过往的临界报销记录，值得这一次更仔细地看一看。

Farrah 运用了本章对第七章第一项淘汰标准的更严格解读，把每一个临界报销决定都留给了人来做，只让工具处理机械性的部分：提取收据总额、核对基本的政策阈值、把任何模糊不清的情况标记出来交她审阅，而不是自己去猜。业务量让这种做法维持起来成本很低：绝大多数报销根本算不上临界情形，所以即便每一个真正模糊的案例都按设计被送到人工审核队列，那个队列也始终不长。真正重要的区分，不是抽象意义上的算术与判断之别，而是逐项任务地去分辨，一个单一的财务流程里，哪些部分属于哪一类，并且不让工具在容易的那九成上表现出的自信，遮住藏在另外一成里的判断性决定。

20.6 试一试：核对一个数字

挑一项金钱类任务，或者一项嵌有金钱数字、你目前不加核查就直接信任的委派任务。像 **Felix** 重新核算报价那样，从源头开始，独立地把它最近一次的输出重新算一遍。

那个数字站得住脚吗？如果站不住，这就是需要一条常设指令或一个更严格检查点的实证。如果站得住，你为这项任务往后赢得的，是一种更轻、更快的核对习惯，而不是从此不再检查。

要点总结

- 金钱类任务里错误的输出，付出的代价是已经转移出去的钱，而不只是修正所需的时间，这与本书大多数任务的风险状况有着根本的不同。
- 原始算术是一处特定的结构性弱点，而不只是又一类可能出错的地方。要用独立来源核实计算结果，不要因为它读起来顺理成章就相信它。
- 金钱类任务的接缝是每一个单独的数字，而不是某个主题或类别。要拿一个不出自同一套生成流程的来源去核对，而不是去看总数内部是否自治。
- 对任何涉及金钱的事，第七章的淘汰标准要用得更保守。第三项，即单次错误的代价超过所有成功案例的总和，对任何以真实体量运行的金钱类任务而言，几乎已经默认成立。

20.7 接下来

第二十一章点明了一种风险：如果本书自身所提倡的这份审慎，最终成了读者从中学到的唯一一课，那就会催生这种风险，也就是把审慎的评估，当作一个永远不用真正动手尝试的借口。

第 21 章

从不尝试的代价

本书前二十一章讲的都是谨慎行事：仔细核查，明确淘汰标准，“解雇”那些没有赢得信任的任务，在采信说法之前先加以核实。这种谨慎是正确的，其中任何一分都不该减弱。但你也完全可能从每一章里都学到了完全正确的教训，却最终走到这本书从未打算把你带向的地方：把所有这些谨慎当作借口，一次试运行都不真正去做。本章讲的是这本账的另一半，如果你从这本主要围绕“仔细核查”展开的书里只学到这一条，那么这另一半很容易被悄悄遮蔽。

21.1 Yusuf 的十八个月准备期

Yusuf 经营着一家小型商业清洁公司，用他自己的话说，他“打算尝试 AI”已经打算了一年半。支持和反对的论点他都读过。他见过一位同事因为早期任务说明写得很糟糕而遭遇的糟糕经历，并把这个教训认真放在了心上，或许太认真了。每一次他快要真正选定第一个任务时，第三章的标准、第七章的淘汰条件、第十二章的评估问题，都会冒出一个理由，说明时机还不太合适。这些理由没有一个是错的。但合在一起，它们已经变成了一个打扮成尽职尽责的、永久的借口。

这是一种真实而具体的失败模式，本书直到现在才把它直接点出来，也值得说清楚：第七章的淘汰逻辑，管的是你是否应该继续运行一个你已经真正试过的任务。它对“要不要一开始就去试”这件事只字未提。把第七章的谨慎，套用到第三章真正管辖的那个决定上，也就是要不要运行一次小规模、低成本、可撤销的试运行，是拿对了工具，却用错了问题。

淘汰逻辑管的是你是否应该继续运行一个你已经真正试过的任务，它对“要不要一开始就去试”这件事只字未提。

21.2 等待的真正代价

关键洞察

研究人员按小型企业的创立年份进行追踪后发现，2025 年创立的公司开业后六个月内，AI 采用率就达到了百分之十，而 2019 年创立的企业要花上六年多的时间才能达到同样的水平。在新近几批创业公司中，企业开业第一个月的 AI 采用率也大幅攀升，2025 年创立的企业约达到 6.5%。

Source: Wheat, C., Mac, C., & Passalacqua, A., “Understanding the Use of AI Among Small Businesses,” JPMorganChase Institute, May 2026 (报告标题:《小型企业中 AI 使用情况研究》)。

这组对比之所以值得细细体会，正是因为它暗示了对任何仍在等待的人意味着什么。明年新开张的竞争对手，不会像 Yusuf 这样花上十八个月来纠结要不要尝试。他们很可能在开业的头几个月内，就运行一版第三章所说的试运行，原因很简单：这样开局如今已经更接近常态，而不是例外，这正是第十九章引用的 OECD 数据所显示的那种转变，在各行各业发生的速度不一，但正在处处发生。等待并不会让你的位置在你犹豫的这段时间里保持不动。它更像是站在一条正在加速的自动人行道上，而现在踏上去的每个人，一上去就已经在往前走了。

21.3 真正的不对称

第三章已经在单次试运行的层面提出过这个论点：一次规模小、成本低、风险低的试运行即便结果不佳，代价也几乎为零，而它带来的信息，哪怕只是干脆利落的一句“这对我们目前还不适用”，也比查明这一点所付出的成本更有价值。这个论点放大到 Yusuf 实际上回避了十八个月的那个决定上，同样成立。按照第三章自己选定任务的标准，在一个小任务上运行一次真实的试运行，其下行风险按设计就是有界且很小的。而从运行哪怕一次的下行风险，却不是以同样的方式有界的。只要犹豫不决持续下去，它就在悄悄复利累积，这正是那种最容易被低估的成本形态，因为没有哪一天单独看上去像是一种损失。

21.4 真正打破这十八个月僵局的是什么

当 Yusuf 看清问题被这样点明之后，他自己给出的解法几乎有些平淡：他挑选了自己能找到的最小、最安全的任务，也就是为常规的客服排期咨询起草回复，在一个下午之内跑完了第三章所说的五次尝试试运行，到当天结束时，手里就有了真实而具体的证据，这是一年半以来再多犹豫都从未产生过的证据。这次试运行并不完美，它发现了一处真实的接缝，正是本书中每一个例子都会发现的那种东西。这不是那十八个月谨慎的失败。这恰恰是真正动手尝试的第一个下午一直都会产生的结果，它自始至终都在那里，只是被一年半来虽然论证得头头是道、却已经悄悄变成一种风险本身的迟疑给盖住了。

21.5 相反的错误，简单说一句

本章的论点并不是允许你彻底跳过试运行，另一侧的失败模式也值得直白地点出来，因为它同样真实存在。Malik，也就是那位在前面某一章中出现过、把常设指令层层叠加却从未核查的人，犯了与 Yusuf 正好相反的错误：完全没有任何犹豫，一次未经检验的尝试用在了面向客户的任务上，就被当作足够好，立刻以全量投入运行，背后既没有五次尝试的试运行，事后也没有执行抽查纪律。结果是客户先于 Malik 本人注意到了质量下滑，而这正是第三章“先试运行”的纪律专门为了防止的结果。

这两种错误看似截然相反：一个是十八个月从未开始，一个是上线前零分钟的谨慎，但它们背后有着同一个成因：Yusuf 和 Malik 都没有真正运行第三章的方法，也就是在做出任何真正承诺之前，先做一次规模小、成本低、能产生证据的试运行。Yusuf 的解药和 Malik 的解药，最终原来是同一副药：在完全信任一个任务或者判定它不适合自己的之前，先在一个小任务上运行试运行。无限期的犹豫做不到这一点，跳过试运行同样做不到。只有试运行本身能做到。

21.6 试一试：说出你自己的“十八个月”

有没有一个任务，你“打算尝试”的时间已经长到不好意思大声说出口？把它写下来，再用一句诚实的话，写出你至今没有开始的真正原因。

现在，只用第三章的标准来检验这个原因：这个任务是不是规模小、会反复出现、风险低，并且能在一分钟之内核查完毕？如果它满足这四条，那么你写下

的那个原因，多半属于第七章的淘汰标准，那是试运行之后才该问的问题，而不是之前。

要点总结

- 本书中的每一条谨慎建议，管的都是你是否应该继续运行一个你已经真正试过的任务。它们没有一条能成为一开始就不去做试运行的理由；那个决定，只归第三章的标准管辖。
- 新竞争对手采用这种“先试运行、再核查”的纪律的速度，比历史上在位企业要快得多，这意味着等待并不会让你的位置保持不动。犹豫每多持续一天，你都在悄悄地失去阵地。
- 一次规模小、成本低、风险低的试运行，按设计就有一个有界且很小的下行风险。而关于要不要运行它的无限期犹豫却没有这样的边界，这种不对称很容易被低估，因为单独看任何一天的等待，都不会让人觉得那是一种损失。
- 治好“谨慎用过头”的办法，不是以后少一点谨慎。而是去运行那次自始至终都触手可及的试运行，用你能找到的最小的任务，就在今天，而不是再多想一轮之后。

21.7 接下来

第二十二章要转向本书还没有直接谈起过的另一方：当委托方或客户并不知道一项被委派的任务是如何完成的时候，你对他们负有什么责任。

第 22 章

向客户解释这一切

第十三章讨论了团队内部的告知问题，让人们能够坦然说出哪些任务用了 AI 起草的初稿。本章讨论一个相关但截然不同的问题：当委派任务的另一端，也就是阅读回复的客户、阅读评价回应的顾客，并不知道内容是如何产生的，而他们理应有权知道时，你到底欠他们什么。

22.1 真正重要的界线

不是每一项 AI 辅助的任务都需要向接收方进行告知，把每一项都当作需要告知来处理，本身就会制造问题：一种持续不断、令人分心的免责声明，附加在普通的商业沟通上，而这类沟通如果出自人类员工之手，本就不会有人质疑。真正值得划定的界线，不是“是否用了 AI”，而是监管机构已经开始直接采用的那条界线：知道真相是否会改变一个理性的人对眼前内容的理解。

关键洞察

美国联邦贸易委员会（FTC）将现行消费者保护法，包括对不公平或欺骗性行为的一般性禁令，直接适用于 AI 的使用。该机构发布的指导意见认为，如果消费者理性地相信自己正在与真人打交道，企业明知这种认知是错误的却未加以纠正，就构成欺骗性行为；另有一项 2024 年的规则专门禁止 AI 生成的虚假评价和推荐证言，每次违规最高可处以 51,744 美元的罚款。

Source: Federal Trade Commission, AI enforcement policy and “Trade Regulation Rule on the Use of Consumer Reviews and Testimonials,” effective October 21, 2024.（美国联邦贸易委员会：AI 执法政策及《消费者评价与推荐证言使用贸易监管规则》，2024 年 10 月 21 日起生效）

这一标准恰好能清晰地映射到本书自始至终讨论的各类任务上。一封由你本人，一个真实的人，阅读过、在需要时做了修改、并最终决定发送的初稿邮件，按照这一标准并不构成欺骗，正如助理代你起草、由你签字的模板信函也从不需要告知一样：你才是为它背书的人。而评价回应、推荐证言，或任何被明确呈现为直接出自某个人本人、未经他人转手的判断的内容，则是另一回事，正是 FTC 2024 年规则直接针对的那一类。

22.2 前面章节其实早已划出这条界线

这与其说是一条新规则，不如说是为第七章淘汰逻辑早已暗含的东西起了个名字。Renata 那些涉及病情的评价之所以被抽出转交给完全由人工回复，正是因为这一类回应承载着一种分量，一种关于亲身判断和担责的隐含主张，而经过核查但由 AI 起草的回应无法完全承载这种分量。同样的逻辑可以向外延伸：任何输出内容隐含地宣称自己是某个具体的人未经中介的判断的任务，无论是推荐证言、以某位具名专业人士本人名义给出的专家意见，还是亲自核实过的主张，都应当得到第七章已经教过的那种保守处理方式：与告知相关的任务，更靠近“保留人工，或坦率告知”这一端，而不是“放心委派”那一端。

任何输出内容隐含宣称自己是某个具体的人未经中介的判断的任务，都应当得到第七章早已针对判断类任务讲过的那种保守处理方式。

22.3 落到实践中是什么样子

经过真人核查的日常商务沟通，不需要告知。一封邮件回复、一条排期确认，或一段你审阅过、愿意署上自己名字的产品描述：你对它负责的方式，和你对任何人类助理代你起草、由你签字的内容负责的方式一样，而告知法律真正关心的是这种担责，而不是起草的方式。

任何被呈现为某个具体的人亲身叙述的内容，则需要告知。推荐证言、评价、归于某个具体个人名下的第一人称叙述：如果 AI 在生成实质内容上起了作用，而不只是为某人真实给出的说法做了排版整理，那就要么背后确有真实的第一手来源，要么坦率告知它并没有。这其实又是第七章第三条淘汰标准的另一种呈现：未经告知的虚假推荐证言所带来的坏处，包括监管风险和客户信任的损失，远远超过省下真实撰写所节约的那点时间。

拿不准的时候，“清楚而显著”测试是个有用的直觉检验。一位理性的顾客读到这段内容，如果得知 AI 参与了生产过程，会感到意外或被误导吗？如果诚实的答案是会，那么这项任务就需要坦率告知，或者完全换成人工完成，而不是悄悄祈祷没人会问起。

22.4 这条界线在现实中是如何划定的

Wanda 经营着前面章节介绍过的那家小型营销代理公司，她曾直接撞上这条界线：一位客户要求她的团队为产品发布页制作一组“客户推荐证言”，素材大致来自客户在通话中随口说过的一些真实但非正式的评论，没有一个人真正审阅或认可过被引用为正式陈述的说法。把它直接交给 AI 打磨成可发布的引言，这种冲动很强烈：发布截止日期近在眼前，而原始素材从技术上说确实来自真实客户。

Wanda 的团队最终没有发布这些内容，原因正是本章直接点出的那个：一句打磨得体、具体、并以真实姓名署名的引言，而当事人根本没有看过或认可过，恰恰正是 FTC 所针对的那一类：把并非真正出自某人之口的话，呈现成他本人亲口所说。她带着起草好的引言逐一回去找每位客户，请他们在发布页上线前确认、修改或拒绝使用。两人照原样认可，一人要求修改其中一个与自己实际说法有出入的具体数字，还有一人干脆拒绝被引用。发布页因此晚了一天上线，用的是三条真实、经过确认的推荐证言，而不是按时上线却带着四条听起来像编造的证言。这中间的差别，客户从未察觉，也没让 Wanda 付出任何代价。这是与 Renata 那些涉及病情的评价同样的自律，只是规模更小：一段输出内容越是接近于宣称是某人本人未经中介的原话，这句话就越需要真正出自那个人之口。

22.5 试一试：进行“理性人”测试

从你的企业目前发送给客户或顾客、且未附带任何告知的 AI 辅助内容中，挑出一项。诚实地问自己：一个理性的人，如果确切知道这项内容是如何产生的，会感到被误导吗？

如果诚实的答案是会，或者哪怕是真心的“也许会”，这项内容就应该归到本章所划界线中“坦率告知，或让它货真价实”的那一侧，而不是你一直悄悄祈祷没人会问起的那一侧。

要点总结

- 不是每一项 AI 辅助的任务都需要向接收方告知。真正重要的界线在于：知道真相是否会改变一个理性的人对眼前内容的理解，这也是监管机构所采用的标准。
- 你审阅过、愿意为之负责的日常沟通不需要告知，正如经过修改、以你的名义发送的人类助理草稿也从不需要告知一样。
- 任何被呈现为某个具体的人亲身判断的内容，无论是推荐证言、评价，还是自称的个人经历，都应当得到第七章对判断类任务所给予的那种保守处理：要么保留真正的人工，要么坦率告知，绝不能把 AI 生成的内容呈现为某人真实的亲口所说。
- 真正拿不准的时候，问问自己一个理性的顾客如果得知内容的产生方式会不会感到被误导。这通常比猜测某项法规在技术上究竟要求什么，更快也更诚实。

22.6 接下来

结语部分会把本书第一章开启的线索收拢完整。在那之后，最后一章是参考资料：把全书的模板和工作表汇总在一处，随时可以复制下来，填入你接下来要尝试的任何任务。

第 23 章

结语：你正在成为的那种管理者

回到第一章开篇的那两个人吧。因为现在，在这里与那里之间该说的话都已经说完之后，值得诚实地再看他们一次。一个人试了一项任务，得到一个平庸的结果，转身走开，认定这整件事都被过度炒作了。另一个人试了一项任务，得到一个看起来很自信的结果，完全信任了它，结果因为一个没人核查过的错误而吃了苦头。这两个人犯了同一个错误，只是方向相反：他们只凭一次尝试就对一件工具下了判断，就像评判一台自动售货机那样，而不是像管理任何真正值得管理的人那样。

介于其间的一切，都是对这一个错误的一场长长的回答，而且值得把这个回答究竟是什么说清楚，因为它从来不是一堆技巧的集合。它是一种单一的定位，被应用到二十多种不同的情境中：写一份真正的任务说明，而不是只给一个任务起个名字。在信任一个结论之前，先做一次试运行。去检查真正要紧的那道接缝，而不是查全部或者什么都不查。去了解一项任务具体的故障模式，而不是对它抱着一种模糊的感觉。把纠正意见保存在真正会被看到的地方。清楚地知道哪些任务根本不该出现在这份名册上。谨慎地扩大规模。诚实地衡量。哪怕一个决定看起来已经尘埃落定，也要按计划持续关注。

这些都不是关于 AI 的事实。它们是关于一个人该如何把任何陌生的事物管理好的事实，只是被重新对准了一款软件，而这款软件恰好比大多数新员工更需要这些方法，因为它永远不会像一位任职多年的同事那样，靠自己慢慢积累出资历。

这一切都不是关于 AI 的事实。它是关于一个人该如何把任何陌生的事物管理好的事实，只是被重新对准了一款软件，而这款软件恰好比大多数新员工更需要这些方法。

23.1 不会过期的东西

第一章许下了一个承诺，值得拿它去检验后面所有的内容：这本书，在书中提到的那些具体工具都消失之后，依然会是对的。这些书页里提到的每一款产品，都可能在你读完这本书之前改名、停用，或者被更好的东西取代。五要素任务说明不会。先试运行、再看长期表现的这套纪律不会。找到那道关键接缝，而不是读全部或者什么都不读的这种直觉，也不会。等到书中的每一个例子都过时之后才拿起这本书的读者，应该依然能把书里的每一种方法，用在取代它们的那些新东西上，因为这套方法从来都不是真正关于工具的。它一直是关于你早已用在人身上的那种管理直觉，只是被瞄准了一个你以前没想到要瞄准的地方。

23.2 这本书要求你放弃的东西

两样东西，都值得诚实地说清楚，而不是含糊带过。第一样，是那种幻想：一件工具一旦设置好，你就再也不用去想它了。这正是那个自动售货机式的承诺，也正是它让第一章开篇故事里的那两个人，从相反的方向双双失败。这本书里的任何内容都不会把你带到那种境地，将来也永远不会，因为核查、重新审视、定期重新试运行，都不是一个你终将毕业离开的阶段。它们才是把任何事情管理好的真实、永久的样子。

第二样，是那种舒适感：对 AI 这个品类下一个单一、简单的判断，好或者不好，值得信任或者不值得，有用或者被过度炒作。这本书的每一章，都刻意用一个针对具体任务的判断，取代了一个针对整个品类的判断，因为品类层面的判断，从来就没有真正适用于任何具体的事情。真正成立的东西，范围更窄，也更有用：这项具体任务，用这个具体工具，用这种方式核查过之后，截至这一周，已经赢得了这么多信任。

23.3 真正衡量进步的标准

不是一家完全自动化的企业。不是一份从没“解雇”过任何任务的名册。也不是一份从此再也不会增长的故障模式清单。真正的衡量标准，也就是收束了第十章那份三十天计划、以及此后每一个案例研究的那同一个标准，比这些都更小、也更诚实：一批被委派出去的任务，不管数量多寡，都是你出于真实、有证据支撑的理由而信任的，而不是出于一厢情愿；与之并列的，是一份诚实的清单，列着你刻意留给自己的那些任务，理由是无论谁问起，你都能站得住脚地说清楚。

对于一本这么长的书来说，这听起来是个不起眼的目标，而值得直白地说清楚，为什么它其实并不小。小企业里 AI 出问题的大多数情况，那种失望之下的放弃、那种昂贵却没人注意到的错误、那种因为一份根本没人真正写过的任务说明而被怪罪的工具，追根溯源，都是因为跳过了这件不起眼的事，去换取一个更快、更让人兴奋的判断。这个不起眼的目标，才是那个真正难的目标。它也是唯一一个真正经得起时间考验的目标：熬过下一次模型更新，熬过下一款取代你最初所用工具的新工具，熬过从这本书写成到你读到它之间，AI 这件事本身所发生的一切变化。

第一章要求你，不再把 AI 当成一台自动售货机，而是开始像管理一名新员工那样去管理它。此后的每一章，讲的都是这件事具体是什么样子，发生在足够多不同的房间、足够多不同的企业里，以至于其中至少有一个，应该会让你觉得眼熟，像是你自己的情况。此刻正躺在你收件箱里的那项任务，那个你打开这本书就是想终于对它做点什么的任务，依然在那里等着。第十章的第一周，依然可以随时开始，只要你准备好动手；而第二十一章早就论证过，这比等一个感觉比现在更“准备好”的时刻，是更好的答案。

要点总结

- 第一章开篇故事里的那两个人，犯了同一个错误：只凭一次尝试就对 AI 下判断，就像评判一台自动售货机那样，而不是像管理任何新人那样去管理它。
- 这本书里的每一种方法，都是你早已具备的管理直觉，只是被重新指向了一个你以前没想到要指向的地方。它们都不会随着具体工具消失而过期。
- 这本书要求你放弃两样舒适感：一件你一旦设置好就再也不用去想的工具，以及对 AI 这个品类下的一个单一判断。取而代之的，是范围更窄、更诚实、也更有用的东西：一种针对具体任务的判断，靠一份又一份真实证据，一点一点赢得，又一点一点重新赢得。
- 真正衡量进步的标准，不是一家完全自动化的企业，而是一小批你信任的、有据可依的诚实任务清单，与一份同样诚实的、你刻意留给自己的任务清单并列在一起。

第 24 章

模板与练习表

本章是参考资料，不是论证。下面的每一份模板都对应本书某一章介绍的方法，按照书中讲授的顺序排列，设计成一页可以直接复制、打印，或在你工作时打开的任何文档里重新制作的实用表格。请一次只填一份，针对一项真实任务来做，而不要试图一口气把所有模板都填完。

24.1 五要素任务说明（第二章）

每项任务使用一次，完成后保存好，之后只替换每次会变化的那个变量。

任务： _____

情境。实际发生的具体情况是什么，而不是这项任务所属的类别。

限制条件。不能说什么、不能提供什么、不能假设什么。

范例。粘贴一个真实、具体、用你自己的语气写成的“好结果”样本。

“完成”的标准。篇幅、格式，一个具体的交付物。

它自己无法知道的信息。那条对你而言显而易见、但对工具来说完全看不见的
关键背景信息。

24.2 试运行记录表（第三章）

在下判断之前，先用三到五个真实、各不相同的输入把任务跑一遍。

次数	输入	实际发生的情况
1		
2		
3		
4		
5		

贯穿多次尝试的规律，而不是某一次的结果：

24.3 接缝抽查练习表（第四章）

这项任务真正模糊不清的地方在哪里（两个互相重叠的类别、一个边缘情
况，或工具很少见到的一种格式）？

把这条接缝缩到最窄、最具体的版本：

我将如何每次都对这条接缝做完整检查：

对其余内容做粗略扫描时，我要留意的是什麼：

24.4 故障模式清单（第五章）

列两到三条真实、具体的条目。如果超过四条，这项任务很可能是几项任务共用了一个名字。

出了什么问题	大致频率	在什么条件下
--------	------	--------

24.5 常设指令审查表（第六章）

针对现有常设指令中的每一条，或在写新的一条之前：

条目	是否仍然适用？	是否已被更新的 条目取代？	是规则，而不是 抱怨？
----	---------	------------------	----------------

24.6 四项淘汰标准检查表（第七章）

问题	是 / 否
这项任务是否有任何部分依赖于一个背后没有可学习规则的主观判断？	
它是否依赖于该工具在结构上不可能拥有的关系历史？	
一次失误造成的损失，是否会超过所有好结果加起来的价值？	
在经过真实的试运行、抽查和修正之后，错误率是否确实没有收敛？	

只要有一个“是”，就足以“解雇”这项任务，或其中的那一部分。

24.7 任务名册（第八章）

每项委派任务占一行。就地更新，不要凭记忆重新整理。

任务	试运行情况	故障模式清单	常设指令	淘汰标准状态
----	-------	--------	------	--------

在新增一行之前，先回答这两个问题：现有的任务是否还在持续教会我一些东西？如果它某周抽查未通过，我是否真的会注意到？

24.8 任务链地图（第九章）

针对任何包含不止一个委派步骤的任务：

步骤	产出什么	在这里设一个检查点是否值得花时间？
----	------	-------------------

一旦超过三四个步骤，检查一下是否有相邻的两步其实是同一项任务套了两个名字。

24.9 工具评估记分表（第十二章）

问题	候选工具一	候选工具二	候选工具三
能否跨会话记住一次修正？			
按你实际的月用量计算的真实成本			
数据处理方式对这项任务是否可以接受？			
在不知道答案时，是否会诚实地说明不确定？			
是否契合这项工作原本所在的场所/流程？			

24.10 团队标准（第十三章）

这类任务的共享任务说明：（使用上面的五要素模板，全团队一次性商定）
最可能被漏掉的那条接缝：

告知这件事，日常要如何说出口：

24.11 三十天计划（第十章）

周次	你在做什么	任务名称	结果
1	选定一项任务， 写出真正的任务 说明，跑一次试 运行		
2	抽查那条接缝， 开始建立故障模 式清单		
3	保存常设指令， 套用淘汰标准检 查		
4	如果第三周结果 达标，就加入第 二项任务；如果 没有通过，就重 新开始一次试运 行		

24.12 复查追踪表（第十七章）

适用于任何目前已被“解雇”的任务。每“解雇”一项任务就新增一行，每次复查时更新后两列。

任务	失败原因	下次复查日期	上次复查结果

24.13 智能体行动前检查点（第十九章）

适用于任何会在现实世界中真正采取行动、而不只是生成草稿的工具：
这个工具在不停下来等人确认的情况下，可以自行采取哪些行动？

达到多大金额，或哪一类行动，需要先暂停、等待批准才能执行？

这个暂停环节实际发生在哪里（某个设置项、一个审核队列、一道审批步骤）？确认它是真实存在并经过测试的，而不是想当然：

24.14 财务任务对账检查表（第二十章）

适用于任何会产出实际影响资金的数字的任务：

问题	是 / 否

每一个数字是否都能追溯到一个并非
由同一流程产生的独立来源？

问题	是 / 否
最终总额是否经过独立的重新计算，而不只是看起来合理就通过？	
如果这项任务中有需要主观判断的部分，它是否仍然会转交给人来处理？	
是否已按这项任务的真实业务量，核查过第三项淘汰标准（一次错误的代价超过所有成功结果之和）？	

24.15 告知决策（第二十二章）

适用于任何产出会直接送达客户或顾客手中的任务：
这是不是一份你已经审阅过、并愿意以个人名义为其背书的常规沟通内容？
如果是，就不需要告知，可以直接使用。
这份产出是否声称是某个具体的人亲自做出的判断、证言或讲述？

一个理性的人如果得知这份内容实际是如何产生的，会不会觉得被误导？如果会，那就要么用真正的第一手叙述来替换它，要么明确告知，不要原样发布。

24.16 简明术语表

任务说明。一项任务实际需要的五要素指令：情境、限制条件、范例、“完成”的标准，以及工具自己无法知道的信息。第二章。

试运行。在对一项新任务下判断之前，先用真实输入跑三到五次，寻找的是规律，而不是单次的结论。第三章。

接缝。一项任务的错误实际聚集的那个狭窄而具体的位置，值得被完整检查，其余部分则做粗略扫描即可。第四章。

故障模式清单。一份简短、书面、具体的记录，写明一项任务通常会在哪里出错、出错的频率有多高，以及在什么条件下出错。第五章。

常设指令。把一次修正保存为一条工具此后会持续套用的规则，而不是每次会话都要重新打一遍。第六章。

淘汰标准。一项任务，或其中一部分，不应再被委派出去的四个理由之一：主观判断、依赖关系历史、单次错误代价过高，或错误率始终无法收敛。第七章。

名册。一页书面记录，涵盖每一项委派任务的试运行情况、故障模式清单、常设指令和淘汰标准状态，需要持续保持更新，而不是靠记忆。第八章。

任务链。一个多步骤的委派流程，每一步的产出都会喂给下一步，并在每一条接缝处都做检查，而不是只在最后检查一次。第九章。

对账。用一个并非源自同一流程的独立来源，去核验一项财务任务的产出，而不是仅仅检查这份产出本身是否内部逻辑自治。第二十章。

复查。按照固定的时间表，对一项此前已被“解雇”的任务重新做一次真实的试运行，检查当初导致其被淘汰的问题是否依然存在。第十七章。

要点总结

- 本章中的每一份模板都直接对应某一章的方法。请针对一项真实任务填写一份，而不要一次性把所有模板都填完。
- 名册和故障模式清单是活文档，不是一次性表格。请像对待任何需要保持真实的记录一样，定期回头查看它们。
- 如果这里的某个词你没什么印象，术语表会指向真正解释了它、而不只是提到了它的那一章。

说明与资料来源

本书中除案例本身故事之外的每一项事实性主张，都在其所在章节以“关键洞察”的形式标出，且都在写作时核对过真实来源，绝非凭记忆回想后径直采信。本节按章节收录了所有这些内容，附上值得记住的事实要点和完整引用，供想要核实某项主张、进一步阅读，或在自己房间里复述某个数字之前确认来源是否仍然有效的读者查阅。

使用本节的方式，应当和第十二章要求你对待供应商自家基准测试宣称的方式一样：把它当作你自己核查的起点，而不是核查本身的替代品。这里的引用告诉你某项事实来自哪里、在何时成立，却不会告诉你某项研究后来是否被重复验证过、某项和解是否已被上诉，或者某家公司是否已悄悄改变了研究所涉及的政策。在把某个数字用在真正要紧的场合之前，先去查证原始来源。

第一章：委派难题

捏造的法律引证。一位纽约律师向法庭提交的诉状中，包含由 ChatGPT 生成的虚构判例，连带编造的引语和内部引证，无论是对方律师还是法庭都无法查证其来源。主审法官对该律师、其同事及所在律所各处处以五千元罚款。*Mata v. Avianca, Inc.*, 678 F. Supp. 3d 443 (S.D.N.Y. 2023); *sanctions order June 22, 2023*.

为什么“幻觉”是结构性问题，而非一个漏洞。OpenAI 自己的研究认为，语言模型倾向于编造自信而具体的答案，并不是什么神秘的故障。标准的训练和评估方式奖励的是自信的猜测，而不是诚实地说“我不确定”，这和选择题考试鼓励学生猜一个答案、而不是空着不答，是同一种激励机制。*Kalai, A.T., Nachum, O., Vempala, S.S., & Zhang, E., “Why Language Models Hallucinate,” arXiv:2509.04664, September 2025 (OpenAI).*

第二章：撰写工作说明书

提示的具体程度与准确性。一项 2025 年的研究在 GPT-4 和 O3-mini 上测试了推理任务中提示的具体程度，发现更详细、更具体的提示能够显著提高准确性，这一效应在较小的模型和分步骤的流程性任务上最为明显，而大多数被委派的工作恰恰属于这一类。“*DETAIL Matters: Measuring the Impact of Prompt Specificity on Reasoning in Large Language Models*,” *arXiv:2512.02246*, 2025.

范例带来的超乎比例的效果。一项在真实临床写作任务上测试 95 个 AI 模型的基准评测发现，在说明之外附上一个范例，而不是只给说明，能显著提升结果：仅仅因为加入了这个范例，Gemini-1.5-Pro 的得分从 43.8 升至 55.5（相对提升 27%），DeepSeek-R1 的得分从 44.2 升至 51.4（相对提升 16%）。Wu, J., et al., “*BRIDGE: Benchmarking Large Language Models for Understanding Real-world Clinical Practice Text*,” *Nature Biomedical Engineering*, 2026 (originally *arXiv:2504.19467*, 2025).

第三章：试运行任务

结构化入职优于直接放手上岗。一项针对三家医院 200 名新入职护士和护理助理的准实验研究，比较了结构化、小范围的入职阶段与常规的无结构上岗方式。结果显示，结构化入职组在所有被测评的能力项上得分都显著更高。Montes Muñoz, P., Cardinal-Fernández, P., Morales Rodríguez, Á., Ruiz-Zaldibar, C., & de la Cuerda López, A., “*The Impact of an Onboarding Plan for Newly Hired Nurses and Nursing Assistants: Results of a Quasi-Experimental Study*,” *Nursing Reports*, 15(11), Article 398, 2025.

第四章：检查工作成果，而不是重做一遍

最早的“警觉性衰退”研究。雷达操作员需要盯着一根无刻度的时钟指针，观察它以不规律的间隔跳动。仅在最初半小时内，他们的检出率就下降了百分之十到十五，并在整场两小时的观测中持续走低。任务从未改变，改变的是观察者本身。Mackworth, N.H., “*The Breakdown of Vigilance during Prolonged Visual Search*,” *Quarterly Journal of Experimental Psychology*, 1, 1948, pp. 6-21.

驾驶舱中的自动化偏见。当自动化检查单建议关闭一台发动机时，即便其他仪表显示的信息与之矛盾，飞行员仍有 75% 的情况下遵从了这一建议。

而使用传统纸质检查单、没有自动化建议可以依赖的对照组，做出同样错误判断的比例只有 25%。Mosier, K.L., Palmer, E.A., & Degani, A., “Electronic Checklists: Implications for Decision Making,” *Proceedings of the Human Factors Society 36th Annual Meeting*, 1992, pp. 7-11.

第五章：摸清它的失败模式

AI 法律检索工具的真实错误率。研究人员测试了几款专门用于减少引证幻觉的 AI 法律检索工具，发现 Lexis+ AI 在超过 17% 的查询中给出了错误或缺乏依据的答案，Westlaw 的 AI-Assisted Research 这一比例约为 33%，而 Ask Practical Law AI 则几乎表现出一种完全不同的失败模式：在超过 60% 的查询中，问题不是编造答案，而是答案不完整。Magesh, V., Surani, F., Dahl, M., Suzgun, M., Manning, C.D., & Ho, D.E., “Hallucination-Free? Assessing the Reliability of Leading AI Legal Research Tools,” *Journal of Empirical Legal Studies*, 2025 (originally a Stanford RegLab /HAI working paper, 2024).

第六章：真正管用的反馈方式

三分之一以上的反馈会适得其反。一项涵盖超过 23,000 个观测值、607 个效应量的元分析发现，反馈干预平均而言能改善绩效，但其中超过三分之一实际上反而使绩效变差，而决定结果好坏的是反馈的传达方式，而不是反馈指向的方向。Kluger, A.N., & DeNisi, A., “The Effects of Feedback Interventions on Performance: A Historical Review, a Meta-Analysis, and a Preliminary Feedback Intervention Theory,” *Psychological Bulletin*, 119(2), 1996, pp. 254-284.

具体目标胜过“尽力而为”。这是组织心理学中被重复验证次数最多的发现之一：具体、界定清晰的目标始终稳定地优于模糊目标。在直接比较两者的研究中，大约十项里有九项显示，具体目标胜过笼统的“尽力而为”指令。Locke, E.A., & Latham, G.P., “Building a Practically Useful Theory of Goal Setting and Task Motivation: A 35-Year Odyssey,” *American Psychologist*, 57(9), 2002, pp. 705-717.

第七章：何时该“解雇”它

麦当劳终止了得来速 AI 测试。在与 IBM 合作测试自动化 AI 点单大约两年后，麦当劳于 2024 年 6 月终止了这项试点。原因是持续出现、且被广泛记录在案的点单错误模式，即便系统不断调优，问题也始终未能解决。“*McDonald's to end AI drive-thru test with IBM,*” *CNBC, June 17, 2024*; “*McDonald's is ending its drive-thru AI test,*” *Restaurant Business, June 2024*.

Zillow 关闭房屋翻新转售业务。2021 年，Zillow 取消了对自动定价算法的人工干预权限，此后不得不再为其房产库存计提高达 5.69 亿美元的减值，并在彻底关闭该业务的过程中裁员 25%；等到 2021 年全年业绩公布时，该部门的全年亏损约为 8.81 亿美元。“*Zillow Shuts Down Home-Flipping Business After Racking Up Losses,*” *Bloomberg, November 2, 2021*; “*Zillow to Lay Off 25% of Its Workforce and Shutter House-Flipping Service,*” *CBS News, November 2021*; *Zillow Group Q4 and full-year 2021 earnings release, February 10, 2022*.

第八章：你的第二位，第三位“员工”

任务切换的真实代价。美国心理学会汇总的研究发现，在不同任务之间切换注意力所带来的心理成本是真实且可测量的，最多可能耗费一个人本可用于产出的百分之四十的时间。*American Psychological Association, “Multitasking: Switching costs,”* [apa.org/topics/research/multitasking](https://www.apa.org/topics/research/multitasking), summarizing Rubinstein, J.S., Meyer, D.E., & Evans, J.E., “*Executive Control of Cognitive Processes in Task Switching,*” *Journal of Experimental Psychology: Human Perception and Performance*, 27(4), 2001, pp. 763-797.

管理幅度与管理者投入度。一项对超过 20 万个由管理者带领的团队所做的分析发现，管理者的投入度在直接下属人数达到八到九人左右时达到顶峰，超过这个数字后便开始下降，不过技能娴熟、又得到充分支持的管理者能够胜任的人数会明显更多。*Gallup, “Span of Control: What’s the Optimal Team Size for Managers?”*, [gallup.com/workplace/700718](https://www.gallup.com/workplace/700718), January 2026.

第九章：一人团队

任务越长，AI 的可靠性越低。一项被广泛引用的 2025 年研究发现，主流 AI 模型能够可靠地完成简短、简单的任务，但随着任务时长和步骤数增加，其在真实场景中的成功率会急剧下降。这一差距虽然随时间推移在不断缩

小，但截至研究发表时依然十分显著。*METR (Model Evaluation and Threat Research)*, Kwa, T., et al., “Measuring AI Ability to Complete Long Tasks,” *arXiv:2503.14499*, March 2025.

缺陷成本的层层放大。这是软件工程领域被引用最多的发现之一：在一个多阶段流程中，一个缺陷被发现得越晚，修复它的成本就上升得越剧烈。经典数据显示，视具体项目而定，这一放大倍数从大约四倍到高达一百倍不等。*Boehm, B.W., “Software Engineering Economics,” Prentice-Hall, 1981 (data originally in Boehm, B.W., “Software Engineering,” IEEE Transactions on Computers, C-25(12), 1976).*

第十章：三十天委派计划

养成一个新习惯究竟需要多久。一项被广泛引用的研究追踪了参与者养成新的日常习惯的过程，发现平均需要六十六天才能让一个习惯变成自动行为，具体天数因人、因习惯而异，从十八天到二百五十四天不等。*Lally, P., van Jaarsveld, C.H.M., Potts, H.W.W., & Wardle, J., “How are habits formed: Modelling habit formation in the real world,” European Journal of Social Psychology, 40, 2010, pp. 998-1009.*

第十一章：四个完整的委派案例

2019 年至 2025 年小企业的 AI 采用率。研究人员通过追踪数百万家小企业的交易数据发现，2019 年至 2025 年间，付费 AI 的采用率大幅上升：男性所有的企业从约 2% 升至约 19.7%，女性所有的企业从约 1.7% 升至约 17.2%。有雇员的企业采用率也明显高于没有雇员的企业，截至 2025 年底分别为 26.1% 和 15.3%，这一差距自 2023 年以来是在扩大，而不是缩小。*Wheat, C., Mac, C., & Passalacqua, A., “Understanding the Use of AI Among Small Businesses,” JPMorganChase Institute, May 2026.*

第十二章：选择你的第一个工具

企业放弃 AI 项目的比例。一项 2025 年针对北美和欧洲超过 1,000 家企业的调查发现，42% 的企业在其大多数 AI 项目投入生产之前就已放弃，这一比例较前一年的 17% 大幅上升，主要原因是最初的契合度差、价值不明确，以及

低估了持续投入的成本。S&P Global Market Intelligence, “2025 Enterprise AI Survey (Voice of the Enterprise),” 2025.

第十三章：当你的团队也开始委派

“胡诌式提交” (botshitting)。一项 2026 年对美国、英国和澳大利亚共 6,000 名全职数字化员工的调查发现，在使用 AI 的员工中，近十分之七的人承认自己提交过 AI 生成的工作成果，而他们其实并未真正审核过、没有完全理解，或者一旦被追问也无法自信地为其辩护。Glean Work AI Institute, “The Work AI Index 2026,” survey conducted December 2025-January 2026.

第十四章：常见质疑与边界情况

欧盟《人工智能法案》的人工监督要求。高风险 AI 系统的设计必须确保其在使用期间“能够受到自然人的有效监督”，负责监督的人员必须能够在依赖该系统之前，充分理解其实际能力与局限。Regulation (EU) 2024/1689 (EU Artificial Intelligence Act), Article 14, “Human Oversight,” 2024.

第十五章：衡量委派究竟为你节省了什么

自我感觉更快，实测却更慢。一项随机对照试验让十六名经验丰富的开源开发者分别在允许使用 AI 工具和不允许使用 AI 工具的条件下完成真实的编码任务，并直接测量完成时间。结果显示，使用 AI 的开发者完成同类任务反而多花了 19% 的时间，但事后他们却估计 AI 让自己快了大约 20%。Becker, J., Rush, N., Barnes, E., & Rein, D., “Measuring the Impact of Early-2025 AI on Experienced Open-Source Developer Productivity,” arXiv:2507.09089, July 2025 (METR).

第十六章：不同任务类型的常见失败模式

遗漏与误读，而不仅仅是编造。一项对 35 个数据集、83 个模型的 AI 错误进行大规模分类整理的研究发现，一些最常见的失败类型恰恰也是最少被讨论

的：悄悄遗漏必需的信息、误解实际请求，而不是人们通常以为的那种“说错事实”式失败。*Ashury-Tahan, S., Mai, Y., Bandel, E., Shmueli-Scheuer, M., & Choshen, L., “ErrorMap and ErrorAtlas: Charting the Failure Landscape of Large Language Models,” arXiv:2601.15812, January 2026.*

第十八章：六个行业，一套方法

AI 采用率因行业而异，差异悬殊。经合组织（OECD）一项针对中小企业的研究发现，AI 采用率在不同行业之间差异悬殊：信息通信技术类企业接近 45%，专业、科学与技术服务类企业超过 25%，而建筑类企业仅为 7.2%。*OECD, “AI Adoption by Small and Medium-Sized Enterprises,” December 2025.*

第二十章：当任务涉及金钱时，什么会变

数字越长，算术可靠性越差。一项被广泛引用的 2023 年研究测试了 GPT-4 对位数递增的数字做乘法运算，发现三位数乘法的准确率为 59%，四位数降至 4%，五位数则为 0%，这是一种与这类模型处理文本的方式相关的结构性规律。此后，个别模型有所改进，尤其是那些能够调用真实计算器的模型，但其中的基本告诫依然成立：核实一次计算结果，而不是相信它读起来是对的。*Dziri, N., et al., “Faith and Fate: Limits of Transformers on Compositionality,” Advances in Neural Information Processing Systems 36, 2023 (originally arXiv:2305.18654).*

第二十一章：从不尝试的代价

新企业采用 AI 的速度远远快于老企业当年。研究人员按创立年份追踪小企业发现，2025 年创立的企业在开业后六个月内就达到了 10% 的 AI 采用率，而 2019 年创立的企业要达到同样的速度，用了六年多的时间。*Wheat, C., Mac, C., & Passalacqua, A., “Understanding the Use of AI Among Small Businesses,” JPMorganChase Institute, May 2026.*

第二十二章：向客户解释这一切

联邦贸易委员会关于 AI 与欺骗性行为的规定。美国联邦贸易委员会 (FTC) 将现行消费者保护法，包括对不公平或欺骗性行为的一般性禁令，直接适用于 AI 的使用；2024 年的一项规定特别禁止 AI 生成的虚假评论和推荐语，每项违规最高可处 51,744 美元罚款。*Federal Trade Commission, AI enforcement policy and “Trade Regulation Rule on the Use of Consumer Reviews and Testimonials,” effective October 21, 2024.*

关于作者

James Liu 多年来一直在硅谷以及包括字节跳动在内的大型科技公司从事 AI 产品开发。他持有新加坡国立大学计算机科学专业的计算学学士学位，以优异成绩毕业，主修人工智能方向，并在斯坦福大学度过了一年。